

Universidad Nacional de Asunción

Facultad Politécnica



Aplicación de modelos de inteligencia artificial para el cálculo de la probabilidad de protesta de un proceso de contratación pública utilizando el estándar de datos de contrataciones abiertas y red flags identificadas

DAVID RAMÓN NÚÑEZ BENÍTEZ
MATIAS GABRIEL LÓPEZ SAN MARTÍN

Tutores

Julio Manuel Paciello Coronel
Juan Ignacio Pane Fernández

San Lorenzo, 2024

Dedicatoria

A mis padres que siempre me brindan el apoyo fundamental y las oportunidades para lograr todo lo que me proponga. A mis hermanos que me ayudaron y acompañaron desde siempre. A mis abuelos y abuelas que me enseñaron a priorizar el estudio y son ejemplo de trabajo duro. A mis amigos y mi novia que fueron mi apoyo y ejemplo para seguir adelante. A mis compañeros de la universidad con los que estudiamos, compartimos, disfrutamos y afrontamos los desafíos. A los buenos profesores que me abrieron puertas a nuevos conocimientos y nuevas pasiones. A todos mis seres queridos que siempre me dieron cariño y me hicieron sentir acompañado. A David por ser un excelente amigo y compañero de tesis. **Matías López**

A mis padres y a mis hermanos, por su amor incondicional, apoyo constante y por ser mi mayor fuente de inspiración. A mis tíos, tías, abuelos y abuelas por siempre estar presentes y brindarme una mano de apoyo cuando más lo necesitaba. A Veronica, por su amor, apoyo y soporte en todo el proceso. A mis amigos, compañeros de estudio, profesores por brindar su granito de arena y ayudarme a cumplir mis objetivos profesionales, personales y académicos. **David Nuñez**

Agradecimientos

A nuestros padres, por la comprensión, acompañamiento y ayuda durante este importante periodo de realización académica. A los profesores Julio Paciello y Juan Pane por sus invaluable aportes y guía a lo largo del desarrollo de este trabajo, y por el tiempo que nos dedicaron.

A todos los profesores de Ingeniería en Informática de la Facultad Politécnica, por sus enseñanzas y apoyo a los estudiantes. A los compañeros de la carrera, por las horas de estudio juntos.

APLICACIÓN DE MODELOS DE INTELIGENCIA ARTIFICIAL PARA EL CÁLCULO DE LA PROBABILIDAD DE PROTESTA DE UN PROCESO DE CONTRATACIÓN PÚBLICA UTILIZANDO EL ESTÁNDAR DE DATOS DE CONTRATACIONES ABIERTAS Y RED FLAGS IDENTIFICADAS

AUTORES

DAVID RAMON NUÑEZ BENITEZ
MATIAS GABRIEL LOPEZ SAN MARTIN

RESUMEN

Las contrataciones públicas son fundamentales para el crecimiento de una sociedad y usualmente representan un gran porcentaje de la economía de un país. En Paraguay, la Dirección Nacional de Contrataciones Públicas (DNCP) regula estos procesos. Las protestas son herramientas legales que permiten a las partes interesadas o a cualquier ciudadano manifestarse contra irregularidades en los procesos de contratación. El problema que enfrenta la DNCP es la gran cantidad de procesos licitatorios a analizar, el tiempo y costo asociados para revisar casos con potenciales irregularidades.

Las protestas contra un proceso de contratación generan costos colaterales, retrasan el proceso de la contratación pública o en algunos casos lo paran indeterminadamente, requieren de tiempo y de recursos para investigación y resolución del caso, además de todo, causan que la sociedad no pueda recibir los bienes, obras y/o servicios requeridos en tiempo y forma.

Este proyecto tiene como objetivo principal generar un score que cuantifique la probabilidad de que un proceso de contratación pública sea protestado. Se utilizarán técnicas de machine learning para analizar las características de los procesos de contratación y detectar posibles anomalías. Los beneficios principales que se obtendrán con la aplicación del score van desde minimizar la probabilidad de protesta de un proceso de contratación de manera a evitar retrasos o impedimentos futuros para su ejecución, optimizar la utilización de los recursos de las entidades involucradas al minimizar contratiempos en los procesos de compra, y, aportar una herramienta que permita disminuir a mediano y largo plazo las irregularidades en los procesos de contrataciones públicas en base al análisis automatizado de los datos.

APPLICATION OF ARTIFICIAL INTELLIGENCE MODELS TO COMPUTE THE PROBABILITY OF COMPLAINTS IN A PUBLIC PROCUREMENT PROCESS USING THE OPEN CONTRACTING DATA STANDARD AND RED FLAGS

AUTHORS

DAVID RAMON NUÑEZ BENITEZ
MATIAS GABRIEL LOPEZ SAN MARTIN

ABSTRACT

Public procurement is fundamental to the growth of a society and typically represents a significant portion of a country's economy. In Paraguay, the National Directorate of Public Procurement (DNCP by its initials in Spanish) regulates these processes. Protests or challenges are legal tools that allow for objections against irregularities in procurement processes. The issue that the DNCP has is the large number of bidding processes to analyze, the time, and the associated costs of reviewing cases with potential irregularities or challenges.

Presenting a complaint against a procurement process generates collateral costs primarily due to inefficiencies in the purchasing process, either by preventing its execution or substantially delaying it, ultimately resulting in higher costs for the government and a society that cannot receive the required goods or services in a timely manner.

The main objective of this project is to generate a score that quantifies the probability of a procurement process being protested. Machine learning techniques will be used to analyze the characteristics of procurement processes and detect possible anomalies. Among the main benefits expected from the application of the complaint score are: minimizing the likelihood of a procurement process being protested and avoiding future delays or hindrances to its execution, optimizing the utilization of resources by involved entities by minimizing inefficient procurement processes, providing a tool that allows for the reduction of irregularities in public procurement processes in the medium and long term through automated data analysis.

Índice

Dedicatoria.....	1
Agradecimientos.....	2
Índice.....	5
Capítulo 1 - Introducción.....	7
1.1 Problema.....	8
1.2 Justificación.....	8
1.3 Objetivos.....	9
1.3.1 Objetivo General.....	9
1.3.2 Objetivos específicos.....	9
1.4 Organización del trabajo.....	10
Capítulo 2 - Trabajos relacionados.....	11
Capítulo 3 - Marco Teórico.....	17
3.1 OCDS y proceso de contrataciones públicas en Paraguay.....	17
3.1.1 Contrataciones públicas.....	17
3.1.2 Datos abiertos y OCDS.....	19
3.1.3 Protestas en contrataciones públicas del Paraguay.....	24
3.2 Fundamentos Teóricos de Machine Learning.....	25
3.2.1 Técnicas de Flattening de Datos.....	26
3.2.2 Técnicas de undersampling.....	29
3.2.3 Técnicas de oversampling.....	29
3.2.4 Algoritmos de aprendizaje Supervisado.....	30
3.2.5 Algoritmos de aprendizaje no Supervisado.....	31
3.2.6 Algoritmos de aprendizaje reforzado.....	32
3.2.7 Métricas para medir desempeño de modelos de aprendizaje automático de clasificación.....	33
3.2.7.1 Matriz de confusión.....	34
3.2.7.2 Precisión.....	34
3.2.7.3 Sensibilidad o Recall.....	35
3.2.7.4 F1-Score.....	35
3.2.7.5 Curva precision recall o PR Curve.....	35
Capítulo 4 - Solución Propuesta.....	37
4.1 Obtención de los datos. Generación del dataset.....	38
4.1.1 Dataset: Variables estructuradas.....	39
4.1.2 Dataset: Variables complejas.....	44
4.2 Flattening aplicado al dataset.....	47
4.3 Análisis de cardinalidad de las variables.....	47
4.3.1 Parties.....	47
4.3.2 Planning.....	53
4.3.3 Tender.....	55
4.3.4 Awards.....	63
4.3.5 Contracts.....	70
4.3.6 Otros.....	82

4.4 Anexo de red flags al dataset.....	84
4.5 Balanceo del dataset y generación de modelos.....	88
4.6 Resumen del capítulo.....	96
Capítulo 5 - Resultados Experimentales.....	97
5.1 Conjunto de datos.....	98
5.2 Modelo de clasificación.....	98
5.2.1 Resultados de las métricas de desempeño.....	99
5.3 Score de riesgo.....	100
5.4 API con Score de riesgo.....	101
Capítulo 6 - Conclusión y trabajos futuros.....	103
6.1 Posibles trabajos futuros.....	104
6.2 Publicación Científica.....	106
Bibliografía.....	107

Capítulo 1 - Introducción

La Dirección Nacional de Contrataciones Públicas (DNCP) actúa como el organismo regulador en Paraguay, supervisando y validando los procedimientos para todos los procesos de contratación pública en el país. La DNCP publica datos relacionados a los procesos de contratación pública de acuerdo con el Estándar de Datos de Contratación Abierta (OCDS). La implementación y uso del OCDS tiene como objetivo fomentar la divulgación proactiva de información y datos sobre diversas etapas de contrataciones públicas en todo el mundo.

El proceso de contrataciones públicas en Paraguay está compuesto de varias fases, entre ellas, la planificación, convocatoria, adjudicación y contrato, estas y los detalles de cada una se encuentran detallados en el OCDS¹. La DNCP publica información por cada contratación pública: los montos planificados, los bienes, obras, o servicios requeridos, las adjudicaciones, las ofertas recibidas, los entes públicos y privados involucrados, entre otros.

Los procesos de contratación pública son susceptibles a protestas, las cuales implican una extensa labor investigativa de la DNCP sobre los procesos de contratación pública, lo que conlleva retrasos de tiempo para que los bienes, obras o servicios lleguen a la entidad contratante, y generan costos adicionales para revisar y abordar el problema. Esto presenta una oportunidad para automatizar el proceso de detección temprana de las potenciales protestas utilizando técnicas de inteligencia artificial para prevenir las mismas.

Este trabajo propone la generación de un score que indica que tan probable es que una contratación pública sea objeto de una protesta. Para generar dicho score, proponemos el uso de un algoritmo de clasificación entrenado con la información obtenida de los procesos de contratación pública más antiguos en el Paraguay desde el 2015 hasta mediados de 2023. Además también agregar banderas rojas (o Red flags) las cuales son alertas de anomalías detectadas sobre cada proceso como fuente de información adicional para el entrenamiento del algoritmo. Con la implementación de este score, el personal de la DNCP podría priorizar e investigar los procesos de contratación pública que sean más susceptibles de recibir una queja en etapas posteriores del proceso.

El conjunto de datos públicos sobre los procesos de contratación pública en el Paraguay en formato OCDS proporcionado por la DNCP está compuesto por múltiples campos, algunos de los cuales no están estructurados, ya que incluyen listas de elementos cuyo tamaño varía para cada proceso. Para poder utilizar este conjunto como fuente de datos de entrenamiento se aplicaran técnicas para estructurar y transformar los datos y obtener un conjunto de datos adecuado para el análisis.

Además del score propuesto, el conjunto de datos utilizado para entrenarlo y la metodología utilizada para generar el conjunto de datos estarán disponibles para su uso en trabajos futuros.

¹ OCDS: <https://standard.open-contracting.org/latest/es/>

1.1 Problema

Las compras públicas son protagonistas dentro de la historia del desarrollo del país gracias a la promoción y establecimiento de políticas y estrategias diseñadas específicamente para consolidar y fortalecer el sistema de contrataciones del Estado.

La Dirección Nacional de Contrataciones Públicas (DNCP) es la entidad encargada de la regulación, verificación y control de los procesos de contrataciones públicas en Paraguay. Según sus datos publicados existen un promedio de 11.011 convocatorias publicadas por año. La DNCP emite un promedio de 24.245 observaciones y 7.380 retenciones en promedio ² (DNCP, 2023). Estas convocatorias equivalen, en dinero, a USD 3.246 Millones en promedio, por año.

Estos procesos retenidos y observados pueden darse por diversos motivos, uno de los principales son las protestas, las cuales crean un gran trabajo de investigación. Este trabajo retrasa el tiempo total para que el bien o servicio llegue a la entidad que lo necesita y aumenta los costos adicionales para revisar y corregir los problemas que pueda tener el proceso licitatorio. Esto genera la oportunidad de automatizar el proceso con algoritmos de inteligencia artificial para detectar casos con una probabilidad mayor de recibir una protesta en etapas tempranas del proceso de contratación.

1.2 Justificación

Como se mencionó anteriormente, para Paraguay, las compras públicas representan más de 3 mil millones anuales³, esto a su vez representa entre 5 a 10% del PIB del país⁴. De acuerdo al Fondo Monetario Internacional, los gobiernos de todo el mundo gastan cada año un estimado de entre US\$ 1,5 a 2 trillones en sobornos (Gaspar & Hagan, 2016, 102) y de acuerdo al U4 Anti Corruption Center, alrededor de 10 a 25 % de las contrataciones públicas se ven afectadas por la corrupción⁵.

Las protestas, a menudo asociadas con irregularidades o disputas en los procedimientos de adquisición, pueden ocasionar retrasos significativos en la ejecución de contratos, también sobre costos, ya que se necesitan personas, tiempo y recursos para resolverlas, lo que afecta directamente la entrega oportuna de bienes, obras y servicios a la sociedad.

La implementación de técnicas de aprendizaje automático para predecir la probabilidad de protestas en los procesos de contratación ofrece una herramienta invaluable para los organismos reguladores y las entidades gubernamentales, ya que esta implementación permitirá un uso más eficiente de recursos. En lugar de realizar una revisión manual exhaustiva de cada proceso utilizando los recursos disponibles, consumiendo tiempo a los encargados de estas verificaciones, los modelos predictivos permitirán identificar rápidamente aquellos casos con mayor probabilidad de generar protestas. Al analizar datos históricos y características específicas de los procesos de contratación, estos modelos

² <https://www.contrataciones.gov.py/t/download/BannerAdjunto/88>

³ <https://www.contrataciones.gov.py/>

⁴ <https://datos.bancomundial.org/pais/paraguay>

⁵ <https://www.u4.no/publications/the-credibility-of-corruption-statistics>

pueden identificar señales tempranas de posibles irregularidades o conflictos que podrían desencadenar protestas.

La justificación de esta tesis reside en la necesidad de optimizar los recursos y reducir los tiempos de entrega de bienes, obras y servicios en el contexto de las contrataciones públicas. La capacidad de prever protestas con anticipación permite a las autoridades competentes tomar medidas preventivas y correctivas de manera proactiva, evitando retrasos innecesarios, optimizando la utilización de recursos públicos y disminuyendo el gasto innecesario, que, como ya se mencionó, puede ser excesivo.

Además, al anticipar y mitigar los riesgos de protestas, se promueve un entorno más transparente y equitativo en los procesos de contratación, lo que contribuye a fortalecer la confianza tanto de los proveedores como de la sociedad en general. En última instancia, esta investigación busca ofrecer una contribución significativa al mejoramiento de la gestión pública, proporcionando herramientas prácticas para mejorar la eficiencia y la efectividad de las contrataciones públicas, así como para garantizar la entrega oportuna de bienes, obras y servicios requeridos por la sociedad.

1.3 Objetivos

1.3.1 Objetivo General

El objetivo general es generar un score que cuantifique la probabilidad de riesgo de protesta de un proceso de contratación pública.

1.3.2 Objetivos específicos

A partir del objetivo general podemos desglosar los siguientes objetivos específicos:

- Generar un conjunto de datos integrado de los procesos de contratación pública del Paraguay y las red flags activadas por cada proceso de contratación.
- Entrenar y comparar modelos predictivos que determinen la probabilidad de protesta de un proceso de contratación pública.
- Seleccionar el modelo más óptimo para detectar posibles protestas y usarlo para calcular el score de riesgo, teniendo como entrada el conjunto de datos transformado y las red flags activadas en cada proceso de contratación pública.

1.4 Organización del trabajo

El trabajo está estructurado de la siguiente manera, en el Capítulo 2 se tratarán los trabajos relacionados y el estado del arte elaborado previo al desarrollo del proyecto, luego, en el Capítulo 3, se abordará el marco teórico del trabajo tratando temas como el estándar OCDS, la implementación de OCDS en Paraguay, fundamentos teóricos del machine learning, además de las técnicas y métricas usadas en este trabajo. En el Capítulo 4 se expondrá la propuesta a implementar en un entorno tecnológico, los componentes y el proceso para llegar a la solución. A continuación, en el Capítulo 5 se mostrarán los resultados y los datos obtenidos con el modelo aplicado a datos que nunca antes había visto. Finalmente, en el Capítulo 6 se evaluará el cumplimiento de los objetivos propuestos, se presentarán las conclusiones finales y trabajos futuros que pudieran realizarse. Se incluirán las referencias bibliográficas utilizadas para la elaboración de este trabajo.

Capítulo 2 - Trabajos relacionados

Para cuantificar la probabilidad de una contratación pública de tener una o varias protestas, se propone utilizar los datos del proceso de contratación pública en el formato del Estándar de Datos de Contrataciones Abiertas (OCDS) publicados por la DNCP. Para la investigación y el desarrollo del trabajo propuesto, se han revisado y recopilado trabajos similares, entre estos trabajos podemos encontrar algunos que usan aprendizaje automático, otros que también trabajan con el OCDS, y algunos que también generan un score de predicción.

Inicialmente se buscaron trabajos con propuestas similares a la de este proyecto: Un score (valor numérico asignado a un proceso de contratación pública) que mida los riesgos de una contratación pública. Tal como el trabajo de Fazekas, István y King (Fazekas et al., 2016), que se enfoca en medir el nivel de corrupción en cada posible entidad licitante en convocatorias de contratación pública. Utilizando técnicas de big data, asignan un Índice de Riesgo de Corrupción (CRI, del inglés *Corruption Risk Index*) a cada entidad seleccionada para el análisis. Con el fin de abordar la falta de indicadores confiables de corrupción, el artículo desarrolla un indicador compuesto de corrupción institucionalizada a alto nivel a través de un enfoque de "Big Data".

Utilizando registros de contratación pública electrónicos disponibles públicamente en Hungría, identifican "banderas rojas" en el proceso de contratación pública y las vinculan a la competencia restringida y la adjudicación recurrente de contratos a la misma empresa. Utilizan este método para crear un indicador de corrupción a nivel de contrato que puede agregarse al nivel de organizaciones individuales, sectores, regiones y países. Este método puede generar un índice de corrupción basado en datos objetivos que es consistente a lo largo del tiempo y entre países.

El trabajo demuestra la validez del índice de riesgo de corrupción mostrando que las empresas (a las que se adjudica el contrato) con una mayor puntuación de riesgo de corrupción tenían una rentabilidad relativamente más alta, una mayor proporción de valor del contrato respecto al precio estimado inicial, una mayor probabilidad de que políticos las gestionaran o fueran propietarios de ellas, y una mayor probabilidad de registro en paraísos fiscales, en comparación con las empresas con puntuaciones más bajas en el índice. En la conclusión del documento, se discuten los usos de estos datos para la investigación académica, periodistas de investigación, grupos de la sociedad civil y pequeñas y medianas empresas.

Uno de los aportes que se toman de este trabajo es la metodología empleada para calcular el índice mediante regresión. Es bastante interesante cómo estos estudios definen el índice de corrupción, básicamente la acotan a aspectos estrictamente medibles. Como el secretismo, la rentabilidad, etc. Cabe resaltar la forma en la que evalúan sus resultados utilizando parámetros directamente relacionados con la corrupción, tales como la rentabilidad (profitability), el secretismo (secrecy), entre otros. Para este trabajo es significativa la idea de utilizar varios parámetros obtenidos de registros electrónicos de contrataciones públicas para entrenar un score o índice el cual pueda medir registros

anómalos e indicar la probabilidad de que se esté dando un caso de corrupción en dicho proceso de contratación pública.

Fazekas continúa este trabajo con Gábor Kocsis (Fazekas & Kocsis, 2017), creando nuevos índices, uno de ellos enfocado más en procesos de contratación pública con un solo oferente. El objetivo de los autores de este trabajo es el de medir la corrupción de alto nivel y el favoritismo gubernamental, lo cual ha sido objeto de un extenso interés académico y político con relativamente poco progreso en la última década.

Para abordar la falta de indicadores confiables, este artículo desarrolla dos medidas objetivas de la corrupción de alto nivel en la contratación pública: la licitación única en mercados competitivos y una puntuación compuesta de "banderas rojas" en la licitación.

Utilizando registros oficiales electrónicos disponibles públicamente de más de 2.8 millones de contratos gubernamentales en 27 estados miembros de la UE más Noruega en 2009-2014, se genera una definición común de corrupción: *la restricción injustificada del acceso a contratos públicos para favorecer a un determinado postor*. Los indicadores de corrupción se calculan a nivel de contratos, pero producen índices agregados consistentes con los indicadores de corrupción bien establecidos a nivel de país. Debido al marco regulatorio común de la Unión Europea, los indicadores son consistentes a lo largo del tiempo y entre países, mientras que las regulaciones de la OMC respaldan la generalización global. La validez del indicador está respaldada por correlaciones con indicadores de corrupción basados en percepciones bien establecidas y nuevos micro indicadores, como precios y registro de proveedores en paraísos fiscales.

La utilidad de los nuevos indicadores desarrollados en el trabajo se demuestra utilizándolos para explicar el efecto de la desregulación en los riesgos de corrupción a nivel de país. La forma en la que obtienen el score, aunque bastante similar al anterior (de hecho comparten el mismo autor), resulta interesante por su enfoque específico y la importancia que otorga a los procesos con un solo oferente.

La tesis de Alexandra Ovsyannikova y Jenny Domashova titulada "Identificación de Contratos de Contratación Pública con Alto Riesgo de Incumplimiento Basada en Redes Neuronales" (Ovsyannikova & Domashova, 2020) implementa métodos de aprendizaje automático, redes neuronales en particular, para predecir los resultados de casos de fraude e incumplimientos en la ejecución de contratos de contratación pública.

En el marco del estudio se llevó a cabo una clasificación de contratos públicos en la industria de tuberías con el fin de identificar contratos con alto riesgo de incumplimiento. Se desarrolló una aplicación en Python para la solución del problema, la cual implementó composiciones de modelos de redes neuronales de la arquitectura propuesta en este trabajo. Se describen los resultados de la aplicación de los modelos matemáticos y se analiza su precisión. Se señala que el producto de software desarrollado puede ser utilizado para resolver el problema de clasificación descrito utilizando modelos de redes neuronales con la selección adecuada de los datos de entrenamiento. Luego de testear un set de modelos, las redes neuronales fueron usadas para clasificar las contrataciones públicas riesgosas. Estas obtuvieron hasta un 76% de recall o sensibilidad, 75% de precisión y 75% nuevamente en F-measure en el set de pruebas.

Félix López-Iturriaga e Iván Pastor-Sanz, en su trabajo de título "Predicción de la Corrupción Pública con Redes Neuronales: Un Análisis de las Provincias Españolas" (López-Iturriaga & Pastor-Sanz, 2018), argumentan que la corrupción debe ser detectada lo antes posible para que se puedan tomar medidas correctivas y preventivas. Por lo tanto, en el trabajo se desarrolla un sistema de alerta temprana basado en un enfoque de redes neuronales, específicamente mapas autoorganizados, para predecir la corrupción pública en función de factores económicos y políticos. A diferencia de investigaciones anteriores, que se basan en la percepción de la corrupción, este trabajo se basa en casos reales de corrupción que llegaron a los tribunales. Luego se aplica el modelo a las provincias españolas en las que se informaron casos reales de corrupción por los medios de comunicación o llegaron a los tribunales entre 2000 y 2012. En la investigación se encuentra que la tributación de bienes inmuebles, el creciente número de instituciones de depósito y empresas no financieras, y la permanencia del mismo partido político en el poder durante largos períodos son síntomas o factores que prueban ser relevantes predictores de la corrupción pública.

El modelo presentado en el trabajo de investigación proporciona diferentes perfiles de riesgo de corrupción dependiendo de las condiciones económicas de una región en función del momento de la predicción. Además, el modelo presentado ofrece diferentes marcos temporales para predecir la corrupción hasta tres años antes de que se detecten los casos.

Cingolani, Fazekas y Tóth (Fazekas et al., 2016), el cual selecciona una aproximación numérica con el objetivo de poder cuantificar el riesgo de que exista corrupción en los procedimientos públicos, este trabajo busca obtener también una aproximación numérica para medir la probabilidad de protesta para un determinado proceso de contratación pública.

El artículo proporciona una revisión exhaustiva de los proxies cuantitativos de corrupción, también conceptualiza cómo diferentes indicadores capturan distintos aspectos de la corrupción e identifica las brechas en el panorama de la medición. La corrupción institucionalizada y establecida en la contratación gubernamental actúa eludiendo la competencia justa y abierta para asignar contratos a empresas pertenecientes al grupo corrupto. Esto requiere al menos: transacciones corruptas que permitan la generación de rentas, relaciones particularistas que sostengan la acción colectiva de los grupos corruptos; organizaciones que permitan la asignación de rentas (organizaciones públicas); y organizaciones que extraigan rentas corruptas (empresas privadas). Estos cuatro requisitos de la contratación corrupta sirven como marco para la revisión. En el artículo se encuentra que hay una sorprendente variedad de indicadores validados en contextos particulares, lo que deja la generalización poco clara. También se sugiere que la literatura académica se ha ocupado en gran medida de un tipo u otro de proxies de corrupción, como las conexiones personales, sin reconocer sus complementariedades.

Kornelije Rabuzin y Nikola Modrušan realizaron el trabajo titulado "Predicción de índices de corrupción en contrataciones públicas usando machine learning" (Rabuzin & Modrušan, 2019). El trabajo explica que la protección de los recursos financieros públicos de los ciudadanos mediante modelos avanzados de detección de corrupción en la contratación pública se ha convertido en un tema casi inevitable y en el objeto de numerosos estudios. Dado que casi siempre se enfoca en la predicción de la competencia corrupta, el cálculo de varios índices e indicaciones de corrupción a partir de los datos en sí es muy difícil de

conseguir. Estos conjuntos de datos generalmente tienen muy pocas observaciones, especialmente las etiquetadas con precisión. La prevención o detección de procesos de contratación pública comprometidos es definitivamente un paso crucial, relacionado con la fase inicial de la contratación pública, es decir, la fase de publicación del aviso.

El objetivo del artículo es comparar modelos de predicción utilizando técnicas de minería de texto y métodos de aprendizaje automático para detectar procesos de contratación sospechosos, enfocándose en procesos con una sola oferta. En consecuencia, los autores analizaron la documentación de los procesos de contratación pública, extrajeron el contenido de interés sobre los niveles de todas las ofertas y agruparon por lotes de contratación utilizando métodos de aprendizaje automático.

La experimentación logró un modelo que incluye los componentes antes mencionados utilizando los algoritmos de clasificación de texto más comunes con el propósito de predicción: Naive Bayes, regresión logística y máquinas de vectores de soporte. Los resultados de la investigación mostraron que el conocimiento en la documentación de los procesos de contratación pública puede ser utilizado para detectar procesos sospechosos.

Por otro lado, existen algunos trabajos interesantes que utilizan el OCDS como su principal fuente de datos, como el trabajo de Elisabeth Kehler (Kehler Niessen, 2020) y el trabajo de Elías Mora y Matías Rivas (Mora & Rivas, 2022), que se realizaron en el contexto de Paraguay. Elisabeth Kehler propuso el uso de árboles de aislamiento como medida para detectar anomalías en un proceso de contratación pública, esto resulta en tasas para clasificar casos de contratación como anómalos o no anómalos. En el trabajo se comenta que la contratación pública típicamente es una fuente potencial de corrupción. Por esta razón, Elisabeth argumenta que la detección de anomalías en las contrataciones públicas puede mejorar la calidad de las compras y, consecuentemente, permitir una mejor calidad de vida en el país a través del uso correcto de los fondos públicos.

En el artículo, se utiliza como caso de estudio a las contrataciones públicas de Paraguay, que están en el formato de datos abiertos del Estándar de Datos de Contrataciones Abiertas (OCDS), como se mencionó anteriormente, para entrenar un modelo de aprendizaje no supervisado para la detección de anomalías, basado en el algoritmo Isolation Forest. La clasificación resultante permite obtener una medición o puntuación de los contratos que puede utilizarse para identificar valores atípicos. Dado un conjunto de datos locales de casos de procesos de contratación con protestas con fallos a favor del protestante o con quejas ciudadanas, los resultados preliminares muestran que el modelo entrenado clasifica como anómalos más del 45% del conjunto de datos potencialmente anómalos.

El trabajo también declara que es necesaria una validación detallada considerando las regulaciones locales de contrataciones públicas, con el propósito de construir una herramienta que permita un muestreo inteligente de contratos con comportamiento atípico. Lo que más destaca del trabajo de Kehler es cómo maneja y estructura los datos en el OCDS y cómo proporciona una explicación detallada del proceso de contratación basado en el contexto de Paraguay.

Elías Mora y Matías Rivas proponen la integración de un sistema de gestión de reglas de negocio en el flujo de trabajo de la DNCP para detectar irregularidades que levantan

banderas rojas en el proceso de contratación pública. Ellos argumentan que las contrataciones públicas representan una fuente importante de corrupción en los gobiernos. El trabajo también explica que organizaciones como Transparencia Internacional han demostrado que las compras públicas constituyen un porcentaje significativo del PIB del país y, por lo tanto, requieren herramientas de gobierno electrónico (e-government) para prevenir la corrupción. El trabajo alega que los Sistemas de Gestión de Reglas de Negocio son soluciones de alcance mundial aplicadas para separar la lógica empresarial del código fuente, lo que permite a un experto en el dominio escribir reglas para buscar "banderas rojas" (red flags) como indicadores de corrupción.

Este trabajo propone el uso de un motor de reglas de negocio para la detección de "banderas rojas" en las compras públicas de Paraguay. Se encontraron más de 45,000 señales de alerta utilizando datos abiertos de Paraguay desde 2016 hasta 2020. El estudio adopta un enfoque diferente al del puntaje o score que se venía utilizando en los estudios comentados anteriormente. Este trabajo demostró que las banderas rojas son una valiosa fuente de información para detectar irregularidades en el proceso de contratación pública y además abre la posibilidad que se estudiará en este trabajo de combinar el enfoque de banderas rojas con el enfoque de score para lograr resultados más precisos.

Otro trabajo interesante es el de Markus Goldstein y Seiichi Uchida (Goldstein & Uchida, 2016). El trabajo comenta que la detección de anomalías es el proceso de identificar elementos o eventos inesperados en conjuntos de datos que difieren de la norma. En contraste con las tareas de clasificación estándar, la detección de anomalías a menudo se aplica a datos no etiquetados, considerando únicamente la estructura interna del conjunto de datos. Este desafío se conoce como detección no supervisada de anomalías y se aborda en muchas aplicaciones prácticas, por ejemplo, en la detección de intrusiones en redes, la detección de fraudes, así como en el ámbito de las ciencias de la vida y la medicina. Los investigadores comentan en el documento que se han propuesto decenas de algoritmos en esta área, pero desafortunadamente la comunidad investigadora aún carece de una evaluación comparativa universal y de conjuntos de datos comunes disponibles públicamente. Estas deficiencias se abordan en el estudio, donde se evalúan 19 diferentes algoritmos de detección no supervisada de anomalías en 10 conjuntos de datos diferentes de múltiples dominios de aplicación.

Al publicar el código fuente y los conjuntos de datos, el artículo pretende ser una nueva base bien fundamentada para la investigación en detección no supervisada de anomalías. Además, la evaluación realizada en el estudio revela por primera vez las fortalezas y debilidades de los diferentes enfoques. Además del rendimiento en la detección de anomalías, se detallan el esfuerzo computacional, el impacto de la configuración de parámetros, así como el comportamiento de detección de anomalías global/local. Como conclusión, el trabajo ofrece una recomendación sobre la selección de algoritmos para tareas típicas del mundo real. Comparan múltiples algoritmos de detección de anomalías no supervisadas en diferentes conjuntos de datos de prueba. Destacan los pros y contras de cada enfoque, proporcionando ideas sobre su efectividad en la detección de anomalías.

Los trabajos citados anteriormente proporcionan información valiosa sobre la posibilidad de generar un score para calcular el riesgo en contrataciones públicas. Además, demuestran que el estándar OCDS está bien documentado y cuenta con varias herramientas disponibles

para su implementación. Asimismo, los estudios mencionados han demostrado éxito al utilizar técnicas de inteligencia artificial para alcanzar sus objetivos. Estos hallazgos no solo validan la viabilidad de utilizar metodologías avanzadas para la detección de riesgos, sino que también subrayan la importancia de basarse en datos bien estructurados y estándares reconocidos. Por lo tanto, los métodos y enfoques presentados en estos trabajos son de gran utilidad e inspiración para este proyecto. Principalmente los análisis de data-mining, la aplicación de modelos de Machine Learning como las redes neuronales, los algoritmos de clasificación basados en Gradient boosting (GBM, XGBoost), los modelos basados en Generalized Linear Model (GLM), el modelo de Distributed Random Forest (DRF), y las red-flags. Estos métodos serán útiles para desarrollar un sistema propio de predicción de riesgos en contrataciones públicas.

Capítulo 3 - Marco Teórico

En este capítulo se presentan los fundamentos teóricos que sustentan esta investigación, proporcionando una base sobre los conceptos y técnicas que serán utilizadas para intentar cumplir los objetivos planteados. Se exploran diversos aspectos teóricos y metodológicos relevantes en el contexto de las contrataciones públicas y el aprendizaje automático, áreas fundamentales para el desarrollo de esta tesis.

En la primera sección, se analiza el Estándar de Datos para Contrataciones Abiertas (OCDS) y su impacto en la transparencia y eficiencia de los procesos de contratación pública, con un enfoque en las técnicas de flattening de datos y las protestas en contrataciones públicas del Paraguay. La sección siguiente se centra en los fundamentos teóricos del aprendizaje automático, describiendo técnicas de muestreo (undersampling y oversampling) y los principales algoritmos de aprendizaje: supervisado, no supervisado y reforzado. Finalmente, en la última sección, se examinan las métricas para evaluar el desempeño de los modelos de aprendizaje automático, incluyendo la matriz de confusión, precisión, sensibilidad (recall), F1-Score y la curva precision-recall (PR Curve).

3.1 OCDS y proceso de contrataciones públicas en Paraguay

En esta sección, se abordará el concepto de Datos Abiertos, las definiciones del estándar de datos abiertos y su pertinencia en el contexto del modelo de datos de Paraguay. Se analizará el caso particular de la implementación de contrataciones públicas y OCDS en Paraguay, su marco legal, la DNCP, los procedimientos y desafíos. Esto incluye un análisis del OCDS, las protestas, como se manejan en Paraguay y en el estándar. Por último, se abordarán los algoritmos de Inteligencia Artificial, modelos, métricas y técnicas a ser utilizadas en el capítulo siguiente.

3.1.1 Contrataciones públicas

Para comprender a fondo el entorno en el que se desarrolla esta investigación sobre la predicción de protestas en contrataciones públicas en Paraguay, es crucial analizar el marco de las contrataciones públicas en este país. Esta sección proporciona una visión general del contexto en el que se inscribe el estudio y destaca los aspectos clave que influyen en el proceso de adquisición pública en Paraguay.

El sistema de contrataciones públicas en Paraguay está regulado por la Dirección Nacional de Contrataciones Públicas (DNCP), la entidad encargada de supervisar y administrar los procedimientos de contratación. La DNCP desempeña un papel crucial al establecer directrices, normativas y procedimientos que rigen los procesos de adquisición gubernamental. Para entender la dinámica de las contrataciones públicas, es fundamental considerar la estructura legal y regulatoria que sustenta estos procesos.

La ley 3439 (Congreso de la Nación de Paraguay, 2008) crea oficialmente a la dirección nacional de contrataciones públicas como entidad facultada para diseñar y emitir las políticas generales que sobre la contratación pública deban observar los organismos, las entidades y las municipalidades; y dictar las disposiciones para el adecuado cumplimiento de esta ley y su reglamento. Esta ley junto con la 2051 (Congreso de la Nación de Paraguay, 2012) y la 7021 (Gobierno del Paraguay, 2022) busca actualizar y modernizar todas las compras del Estado, hacerlas más eficientes a través de una cadena de suministros con la que se pretende establecer y ordenar todas las etapas de planificación, programación, administración y evaluación de las compras, mediante mecanismos tecnológicos y normativos, con el objetivo de potenciar a la compra pública como un factor de desarrollo para el país.

En Paraguay, los tipos de procedimientos de contratación pública pueden variar, incluyendo subastas públicas, licitaciones y concesiones, entre otros. Estos procedimientos están diseñados para garantizar la competencia y la transparencia en la adquisición de bienes, obras y servicios por parte del gobierno. Cada procedimiento tiene sus propias reglas y requisitos, lo que añade complejidad al entorno de contrataciones públicas. La tabla 3.1 muestra los procesos de contratación pública que pasaron por la DNCP en los últimos años.

Año	Procesos de contratación pública
2016	13.338
2017	13.326
2018	12.872
2019	27.486
2020	10.346
2021	9.930
2022	33.357
2023	16.235

Tabla 3.1: Cantidad de procesos de contratación pública por año.

3.1.2 Datos abiertos y OCDS

Los Datos Abiertos, o "Open Data" en inglés, son datos que pueden ser utilizados, reutilizados y redistribuidos libremente por cualquier persona, y que se encuentran sujetos, cuando más, al requerimiento de atribución y de compartirse de la misma manera en que aparecen.⁶ Son un componente esencial en la era de la información y juegan un papel crucial en la investigación de irregularidades en las contrataciones públicas. Los Datos Abiertos se refieren a la idea de que ciertos tipos de datos deben estar disponibles para que cualquier persona los utilice y distribuya sin restricciones, promoviendo así la transparencia, la rendición de cuentas y la participación ciudadana en los asuntos gubernamentales.

En el ámbito de las contrataciones públicas, los datos abiertos proporcionan una valiosa fuente de información. Estos datos pueden incluir detalles sobre los procesos de contratación pública, contratos, proveedores, costos y otros aspectos de los procesos de adquisición gubernamental. La disponibilidad de estos datos en formatos abiertos y accesibles permite una mayor comprensión y análisis de estos procesos, fomentando una gestión más eficiente y transparente.

El acceso a Datos Abiertos permite a los investigadores examinar, cuestionar y evaluar la eficacia de los procesos de contratación pública, identificar posibles irregularidades y evaluar el riesgo de protestas. La transparencia de los datos abiertos también fomenta la confianza de los ciudadanos en la administración pública y mejora la toma de decisiones informadas.

El Estándar de Datos para las Contrataciones Abiertas (EDCA) (OCDS, por sus siglas en inglés Open Contracting Data Standard)⁷ Permite la divulgación de datos y documentos en todas las etapas del proceso de contratación mediante la definición de un modelo de datos común. Fue creado para ayudar a las organizaciones a aumentar la transparencia de la contratación y permitir un análisis más profundo de los datos de contratación por parte de una amplia gama de usuarios.

La documentación del OCDS se compone de varias partes, diseñadas para ayudar a utilizar el OCDS con eficacia. En esta documentación podemos observar que el OCDS tiene varios esquemas ya definidos para la publicación de datos, el esquema principal a utilizar es el de entregas ("Releases"). Cada entrega proporciona datos sobre un único proceso de contratación en un momento determinado. Las entregas se pueden utilizar para notificar a los usuarios sobre nuevos procesos de contratación pública, adjudicaciones, contratos y otras actualizaciones. Las entregas pueden repetir o actualizar la información proporcionada previamente en este proceso de contratación. Un proceso de contratación puede tener varias entregas.

El Esquema de Entrega da una especificación detallada de los campos y la estructura de datos que se deben de usar para publicar datos de contrataciones. Esquemas suplementarios muestran cómo combinar entregas en paquetes de entregas y cómo compilar entregas en registros.

⁶ <https://opendatahandbook.org/guide/es/what-is-open-data/>

⁷ <https://standard.open-contracting.org/latest/es/>

Las entregas son inmutables, presentando información sobre un evento particular en la vida de un proceso de contrataciones. Los publicadores no deben editar una entrega después de su publicación; una nueva entrega puede crearse modificando el identificador (id) y la fecha (date) de la entrega.

El OCDS define un proceso a seguir por el proceso de contratación pública, como se detalla en la Figura 3.1 este proceso se ve reflejado en los datos de cada proceso publicado en el formato definido por el estándar.




Figura 3.1: Proceso de contratación de cinco etapas según el estándar OCDS

Un documento OCDS contiene las siguientes secciones:

- **Metadata - Metadatos de la entrega:** información contextual sobre cada entrega de datos.
- **Parties - Partes:** información sobre las organizaciones y otros participantes involucrados en el proceso de contratación.
- **Planning - Planificación:** información sobre los objetivos, presupuestos y proyectos a los que se refiere un proceso de contratación.
- **Tender - Licitación:** información sobre la forma en que tendrá lugar la licitación o se ha realizado.
- **Award - Adjudicación:** información sobre las adjudicaciones otorgadas como parte de un proceso de contratación.
- **Contract - Contrato:** información sobre contratos firmados como parte de un proceso de contratación.
- **Implementation - Implementación:** información sobre el progreso de cada contrato hasta su finalización.

Para que los datos puedan cumplir con el estándar OCDS, los mismos deben estar en formato json. Existen dos esquemas para los datos OCDS: "entregas" (releases) y "registros" (records).

Los publicadores de OCDS son animados a utilizar las entregas y registros para publicar datos en tiempo real y proveer un historial de cambios. El seguimiento del cambio en el tiempo es importante para los usuarios de datos de contrataciones, debido a que pueden existir muchos cambios en el proceso de contratación.

Una entrega (release) es un dato en formato JSON que se publica cada vez que hay un cambio en un proceso de contratación. Las entregas siguen el esquema de entregas de OCDS y contienen un OCID para identificar el proceso de contratación al que se refieren. De esta manera, las entregas son inalterables, esto quiere decir que una vez publicadas no pueden ser cambiadas. Pueden existir muchas entregas por cada proceso de contratación y esa colección de entregas de un proceso de contratación constituye su historial de cambios.

Un registro (record) es un dato en formato JSON que actúa como un índice de todas las entregas de un mismo proceso de contratación. Mientras que las entregas nunca se actualizan, los registros se actualizan cada vez que hay un cambio en un proceso de contratación añadiendo una nueva entrega a este índice. Los registros siguen el esquema de registro de OCDS y, además del índice de entregas, también pueden contener:

- Una entrega compilada, la cual sigue la misma estructura de las entregas y provee el último valor de cada campo. La entrega compilada facilita a los usuarios obtener la última versión de los datos sobre un proceso de contratación.
- Una entrega versionada, la cual contiene un historial de cambios por cada atributo y que permite a los usuarios observar cómo un atributo en particular ha cambiado con el tiempo.

Como parte del proceso de apertura de datos, la DNCP decide publicar sus datos con el formato establecido por el Estándar de Datos de Contratación Abierta (OCDS), para ello la publicación y disponibilidad de los datos se dividen en dos formas distintas: una API de servicios y la descarga de archivos estáticos. El objetivo del API de servicios⁸ Es poner a disposición datos de planificación, convocatorias, adjudicaciones, contratos y modificaciones de contratos. Por otro lado, el propósito de la descarga de archivos estáticos es poner a disposición los datos históricos de los procesos de contratación pública por año en archivos JSON, a partir de 2010⁹. Esto permite obtener el historial de cambios realizados en los diferentes procesos de contratación.

La implementación del OCDS en Paraguay tiene algunas diferencias con el proceso de contratación del modelo de datos del estándar Open Contracting¹⁰, a continuación, listamos las más significativas:

⁸ <https://www.contrataciones.gov.py/datos/>

⁹ <https://www.contrataciones.gov.py/datos/data>

¹⁰ <https://www.contrataciones.gov.py/datos/open-contracting-info>

- **Convocatorias:** El modelo del estándar prevé la existencia de solo una convocatoria por cada proceso de contratación, en Paraguay puede haber varios, pero solo una puede estar activa a la vez. La solución adoptada por la implementación de Paraguay es publicar un release por cada convocatoria, dichos releases pueden agruparse por su OCID.
- **Lotes e ítems:** El modelo de datos del estándar Open Contracting tiene en cuenta la existencia de ítems, los cuales están incluidos como atributos en las etapas de convocatoria, adjudicación y contrato. Sin embargo, no se prevé la existencia de lotes. Esto difiere del modelo de Contrataciones del Paraguay, en el cual se utilizan los lotes como unidades lógicas de agrupación de ítems.

Esta agrupación lógica definida como “lotes” tiene importancia al momento de realizar las adjudicaciones, dado que las adjudicaciones a un proveedor pueden ser por lotes o por ítems. La solución consiste en agregar una clase lote que indique los ítems que le corresponden. Esta clase lote será incluida tanto en las convocatorias (tender) como en los contratos (contract) y las adjudicaciones (award).

- **Adjudicación y contrato:** En el modelo de Contrataciones de Paraguay, una convocatoria resulta en una única adjudicación. Dicha adjudicación puede involucrar a múltiples proveedores, así como lotes e ítems específicos adjudicados. Para cada uno de estos proveedores, se realizan contratos individuales.

Sin embargo, en el estándar Open Contracting, el proveedor está relacionado a nivel de adjudicación en lugar de a nivel de contrato.

La solución adoptada es agregar el atributo "proveedor" a la clase "contrato", permitiendo así identificar al proveedor de cada contrato en particular, utilizando la misma clase "proveedor" (supplier) provista por el estándar.

Además, se agrega el atributo:

- dncpContractCode: “RL-12001-12-0012”

donde dncpContractCode es el código de contratación utilizado en Paraguay por la DNCP. Por último, también se añadió el atributo url a la adjudicación, que corresponde a la URL del servicio utilizado para construir la adjudicación (award).

- **Adendas:** Las adendas en Paraguay son tratadas de una manera muy particular que difiere en gran medida con el modelo de adendas de Open Contracting. En Paraguay, las adendas son modificaciones o extensiones realizadas a los contratos. Estas adendas tienen un código de contratación nuevo y se encuentran relacionadas al contrato del cual extienden.

El OCDS tiene una gran comunidad de usuarios, investigadores, y entidades públicas y privadas que hacen uso del estándar, esta comunidad construye y publica herramientas para trabajar con datos que siguen el estándar¹¹ como las del Kingfisher, collect y process, el data review tool, el “Extension explorer”, el ocds kit, entre otras. Dos de estas

¹¹ <https://github.com/open-contracting>

herramientas son el kingfisher collect¹² y el kingfisher process¹³, usaremos ambas para el desarrollo de este trabajo y para generar el set de datos.

Kingfisher Collect es una herramienta para descargar datos OCDS y almacenarlos en disco y/o enviarlos a una instancia de Kingfisher Process para su procesamiento. Kingfisher Collect está construido sobre el framework Scrapy¹⁴. Utilizando este framework, el equipo de kingfisher ha creado "spiders" que se pueden ejecutar para "rastrear" fuentes de datos y extraer datos de OCDS. Una vez terminado, este proceso genera una serie de archivos JSON con datos semi-estructurados que representan varios procesos licitatorios. Esta serie de archivos es la entrada para el Kingfisher process.

Kingfisher Process almacena y preprocesa datos de OCDS. Recibe datos de OCDS a través de la API web (utilizada por Kingfisher Collect) o el comando de carga local. Los datos de OCDS se almacenan en una base de datos PostgreSQL y se organizan en "colecciones", como se describe en el **Modelo de Datos** y se especifica en la **estructura de la base de datos**. Se puede observar parte de la estructura principal en la Figura 3.2




Figura 3.2: Estructura de datos del Kingfisher

Los datos de OCDS se pueden publicar como entregas o registros. Las entregas muestran una actualización puntual sobre un proceso de contratación, y los registros proporcionan un índice de todas las entregas para un proceso de contratación (*Release Schema — Open Contracting Data Standard 1.1.5 Documentation*, n.d.).

Kingfisher Process puede transformar automáticamente una colección de entregas en una colección de entregas compiladas, que contiene una única entrega compilada por proceso

¹² <https://github.com/open-contracting/kingfisher-collect>

¹³ <https://github.com/open-contracting/kingfisher-process>

¹⁴ <https://scrapy.org/>

de contratación. Una entrega compilada (*compiled release*) contiene el valor más reciente de cada campo de sus lanzamientos originales.

3.1.3 Protestas en contrataciones públicas del Paraguay

Las protestas son herramientas legales que permiten manifestarse contra irregularidades en los procesos de contratación. El problema que enfrenta la DNCP es la gran cantidad de procesos licitatorios a analizar, el tiempo y costo asociados para revisar casos con potenciales irregularidades.

Una protesta en un proceso de contratación genera costos colaterales debidos principalmente a la ineficiencia en el proceso de contratación pública, ya sea impidiendo la ejecución de la misma o retrasando sustancialmente, lo cual finalmente se traslada en mayores costos para el Gobierno y una sociedad que no puede recibir los servicios que ofrece el gobierno en tiempo y forma. (Encina Perez, 2023, 10). La tabla 3.2 muestra la cantidad de protestas recibió la DNCP en los últimos años.

Año	Procesos de contratación pública	Cantidad de protestas
2016	13.338	231
2017	13.326	456
2018	12.872	938
2019	27.486	1.992
2020	10.346	1.021
2021	9.930	1.022
2022	33.357	3.542
2023	16.235	2.957

Tabla 3.2: Cantidad de protestas por año que recibió la DNCP

Existen dos tipos de protesta (Congreso de la Nación de Paraguay, 2012):

- **Contra pliego:** Si lo que se protesta son las cláusulas del Pliego de Bases y Condiciones de un proceso de contratación pública
- **Contra resultado:** Cuando la protesta se realiza contra las decisiones tomadas por la convocante en un proceso de contratación pública

Si la protesta fue Contra resultado, también existen subtipos:

- *Contra adjudicación:* Se puede protestar contra los términos de adjudicación de un proceso de contratación pública.
- *Contra cancelación:* Se puede protestar contra la resolución de declarar cancelado un proceso de contratación pública.
- *Contra declaración desierta:* Un proceso de contratación pública se declarará desierto si no se hubiera presentado ninguna oferta, si ninguna de las ofertas

reúne las condiciones exigidas o que los precios de las ofertas resulten inaceptables Se puede protestar contra la resolución de declarar desierto un proceso.

- *Contra precalificación:* Se puede protestar contra la precalificación de ciertas entidades o empresas.

En el proceso de protesta el promotor deberá manifestar bajo fe de juramento los hechos relacionados con los actos que se alegan como irregulares y acompañar la documentación que sustente su petición. La falta de la manifestación indicada será causal de rechazo de la protesta. La expresión de hechos falsos por el promotor de la protesta se sancionará de acuerdo con las disposiciones de esta Ley y las demás que resulten aplicables.

En la implementación del OCDS para Paraguay, uno de los campos presentes en la entrega (release), es el de “complaints”, este campo lista las protestas que se han hecho sobre ese proceso de contratación pública, los datos disponibles sobre las protestas son los siguientes:

- **id:** Identificador relacionado a la protesta
- **date:** Fecha en que se registró la protesta
- **type:** Tipo de protesta
- **events:** Listado de eventos relacionados a la protesta, con id, tipo, descripción, estado y fechas

3.2 Fundamentos Teóricos de Machine Learning

La Inteligencia Artificial (IA) representa una revolución tecnológica con un impacto significativo en múltiples sectores, incluido el público. Definida como la capacidad de las máquinas para realizar tareas que normalmente requieren inteligencia humana, la IA ha evolucionado desde conceptos teóricos a aplicaciones prácticas que transforman cómo las organizaciones operan y toman decisiones. Su historia, marcada por avances en algoritmos y capacidad de cómputo, ilustra un creciente potencial para abordar problemas complejos.

El aprendizaje automático, una rama fundamental de la Inteligencia Artificial, implica el desarrollo de algoritmos que permiten a las máquinas aprender y optimizar su rendimiento a partir de datos y de la experiencia. En el contexto de las contrataciones públicas, el aprendizaje automático ofrece herramientas poderosas para analizar grandes volúmenes de datos, detectar patrones y predecir tendencias o anomalías.

Usualmente, para aplicar técnicas de aprendizaje automático se sigue un ciclo llamado Cross Industry Standard Process for Data Mining (CRISP DM) (Chapman et al., 1999, 10), que consta de seis fases interrelacionadas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Este marco proporciona una estructura metodológica sólida para guiar el desarrollo de modelos de aprendizaje automático, asegurando que cada paso sea cuidadosamente planificado y ejecutado para obtener resultados confiables y útiles.

El manejo de datos desbalanceados y jerárquicos presenta desafíos significativos en el análisis y modelado predictivo. Los datos desbalanceados, donde ciertas clases o

categorías están sobrerrepresentadas, pueden llevar a modelos sesgados que no generalizan bien en escenarios reales, afectando la precisión de los resultados. Por otro lado, los datos jerárquicos o anidados, con múltiples niveles de dependencia entre variables, aumentan la complejidad del análisis, dificultando la extracción de información relevante y la implementación de algoritmos eficientes. Abordar estos problemas es esencial para mejorar la calidad de los modelos y asegurar que los análisis reflejan adecuadamente la realidad, lo que se explora en detalle en las siguientes secciones.

3.2.1 Técnicas de Flattening de Datos

A la hora de consumir datos, un modelo de machine learning los necesita en formato plano y tabular, sin embargo, gran parte de los datos usados en este trabajo son complejos y requieren una transformación para llegar a ese formato. El "Flattening" de datos generalmente se refiere a la acción de transformar datos semi-estructurados, como los datos en formato JSON, en columnas separadas (*Data Flattening and Data Unflattening*, n.d.), donde el nombre se convierte en el nombre de la columna que contiene los valores en las filas.

Para avanzar con las técnicas de Flattening es necesario entender la cardinalidad de los datos, este término se refiere al número de elementos únicos que pueden existir dentro de un conjunto de datos o en una columna específica de una base de datos. En términos más simples, describe la cantidad de valores diferentes que una variable puede tomar.

Estrategias para transformar las variables estructuradas de acuerdo a la cardinalidad:

Cardinalidad baja:

Para las variables con baja cardinalidad, existen tres enfoques específicos:

- *One Hot Encoding*: En este caso, se comienza por enumerar todos los valores distintos que puede tomar la variable. Luego, se asigna a cada uno de estos valores una posición en un array, ordenándolos de acuerdo a la frecuencia de sus apariciones. A continuación, se divide el array en columnas, asignando una columna a cada elemento. Se puede observar un ejemplo de la entrada y salida de esta técnica en la figura 3.3

Id de proceso de contratación		Categoria de contratacion	
ocds-12312-1222		Works	
ocds-12312-1321		Services	
ocds-12312-1121		Goods	

↓

ID	Works	Services	Goods
ocds-12312-1222	1	0	0
ocds-12312-1321	0	1	0
ocds-12312-1121	0	0	1

Figura 3.3: Ejemplo del one hot encoding

- *Suma de montos según la moneda:* En situaciones que involucren variables no estructuradas, específicamente montos en diversas monedas, se utiliza un enfoque particular. En este caso, se divide la información en dos columnas: una para los montos expresados en guaraníes y otra para los montos expresados en dólares. Luego, se procede a sumar todas las sub - variables presentes en los arrays y objetos, lo que permite obtener dos nuevas variables estructuradas. Estas nuevas variables contienen los montos totales para ambas monedas, lo que facilita su análisis y comparación. Se puede observar un ejemplo en la figura 3.4.

Id de proceso de contratación	Planificacion
ocds-12312-1222	[{amount: 2000}, {amount: 5000}]
ocds-12312-1222	[{amount: 1000}, {amount: 3000}]



Id de proceso de contratación	Planificacion_amount
ocds-12312-1222	7000
ocds-12312-1222	4000

Figura 3.4: Ejemplo de técnica de flattening: suma de montos

- *Contar la cantidad de elementos:* Para cierto tipo de variables, en lugar de los valores que toman, lo importante es saber la cantidad de elementos que tiene, esto aporta información extra que se perdería al estructurar la variable. A estas columnas les agregamos la palabra "count" al final en el archivo en el cual guardamos todas las columnas estructuradas. Se puede observar un ejemplo en la figura 3.5

Id de proceso de contratación	Planificacion
ocds-12312-1222	[{amount: 2000}, {amount: 5000}]
ocds-12312-1222	[{amount: 1000},]



Id de proceso de contratación	Planificacion_count
ocds-12312-1222	2
ocds-12312-1222	1

Figura 3.5: Ejemplo técnica de flattening: de cuenta de cantidades

- **Valor Booleano:** Para ciertas variables es irrelevante conocer el valor o cantidad de elementos que tenga. Solamente importa si tiene o no elementos. En estos casos tendremos una columna de 0 y 1 en donde el valor será 0 si no tiene ningún elemento, la variable está vacía, y será 1 en caso de que tenga uno o más elementos. Se puede observar un ejemplo en la figura 3.6

Id de proceso de contratación	Consultas
ocds-12312-1222	[{consulta_id: 1}, {consulta_id: 2}]
ocds-12312-1222	[]



Id de proceso de contratación	has_consultas
ocds-12312-1222	1
ocds-12312-1222	0

Figura 3.6: Ejemplo de técnica de flattening con valor booleano

Cardinalidad alta: En el contexto de variables con una alta cardinalidad, se emplean dos estrategias distintas.

- La primera de ellas se aplica a los casos con la cardinalidad más alta, donde los datos están fuertemente distribuidos. Esta técnica se nombrará de aquí en adelante como la *Técnica de división en cuartiles*. Para llevar a cabo esta técnica, se siguen dos pasos esenciales. En el primer paso, se realiza una clasificación y ordenación de los valores que puede tomar la variable, desde el valor más frecuente hasta el menos frecuente. En el segundo paso, se procede a dividir estos valores en cuatro cuartiles. Cada cuartil representa un rango de valores que corresponde al 25%, 50%, 75%, y 100% de las apariciones respectivamente. En lugar de mantener una lista extensa de valores, se asigna a cada valor su cuartil correspondiente, lo que resulta en la representación de la variable con tan solo cuatro columnas.
- La segunda técnica, que se denominará *One Hot Encoding - 70-30%*, se utiliza cuando la variable presenta una cardinalidad medianamente alta o alta pero los valores que representan el 70% de los datos toman la forma de pocos elementos (Se eligió 20 como un umbral de referencia). Es decir, hay muchos valores posibles pero el 70% de las observaciones está distribuido o representado en un set pequeño de valores, se eligió el 70% de forma arbitraria, entendiendo que este número implica una amplia mayoría de las observaciones.

En este enfoque, se clasifican nuevamente los valores, pero en lugar de reducirlos a cuatro columnas, se selecciona el 70% de los valores más frecuentes, cada uno de los cuales se convierte en una columna independiente. El 30% restante se agrupa en una sola columna.

Los datos desbalanceados son un problema bastante común en los trabajos que usan inteligencia artificial, en específico, problemas de clasificación en machine learning. Aparece

cuando en una muestra dividida o categorizada en grupos, una de las clases o grupos es dominante, es decir, cuando una de las clases tiene un número de individuos de la muestra mucho más alto que la otra.

Para enfrentar este tipo de problemas, una solución habitual es la aplicación de técnicas de balanceo de datos o resampling (por su terminología inglesa) que modifican la distribución original de la muestra ya sea eliminando casos o instancias de la clase mayoritaria (undersampling) o replicando o creando nuevas instancias de la clase minoritaria (oversampling). (Comparativa de técnicas de balanceo de datos, 2021)

3.2.2 Técnicas de undersampling

- **Undersampling aleatorio:** Es una técnica sencilla de implementar y entender, consiste en eliminar instancias de la clase mayoritaria aleatoriamente, la desventaja es que se puede perder información valiosa al no tener en cuenta la distribución de los datos que puede representar una relación entre ellos.
- **Condensed Nearest Neighbours:** Se basa en el método de los "k-vecinos" más próximos. Éste es un método basado en instancias o casos, las clasificaciones se realizan en base a la similitud a los casos más cercanos. Es un método, por tanto, no paramétrico. Lo que este algoritmo de clasificación hace es fijarse en los "k" casos o instancias más cercanas al caso de interés (a clasificar) para realizar la clasificación.

3.2.3 Técnicas de oversampling

- **Oversampling aleatorio:** Es una técnica similar al undersampling aleatorio, solo que esta vez se buscan observaciones de datos aleatorias para clonaras, esta técnica, la mayoría de las veces, se aplica a la clase minoritaria.
- **Synthetic Minority Oversampling Technique (SMOTE):** Este método genera instancias sintéticas a partir de las muestras o instancias de la clase minoritaria (Fernandez et al., 2018).

En esta técnica de oversampling vuelve a tener como apoyo el método de los k-vecinos. La propuesta de SMOTE (*Chawla et al., 2002*) se basa en la réplica de instancias de la clase minoritaria tomando cada caso e introduciendo nuevos ejemplos sobre las líneas de unión de sus "k-vecinos" más cercanos. Si tenemos una instancia objetivo x_i y seleccionamos sus 5 vecinos más próximos $\{x_1, x_2, x_3, x_4, x_5\}$, en una primera iteración de un proceso de oversampling vía SMOTE, es posible la creación de 5 nuevas instancias $\{s_1, s_2, s_3, s_4, s_5\}$ sobre las líneas de unión entre la instancia x_i y sus vecinos más próximos.

Las herramientas de análisis se agrupan en tres tipos de aprendizajes, donde la naturaleza de los datos recolectados determina cuál de ellas es la adecuada para su uso en la búsqueda de la respuesta deseada:

- **Aprendizaje Supervisado:** El aprendizaje supervisado es una técnica de aprendizaje automático donde los algoritmos aprenden a partir de ejemplos etiquetados, los datos etiquetados son datos que están clasificados o segmentados de alguna forma, por ejemplo los datos u observaciones con protestas, y los datos sin protestas para realizar tareas específicas. Los algoritmos de clasificación más utilizados en el aprendizaje supervisado son los clasificadores lineales, las máquinas de vectores de soporte (SVM), los árboles de decisión, vecinos más cercanos, bosques aleatorios, regresión logística, naive Bayes y redes neuronales. Estos algoritmos se utilizan para problemas de clasificación y regresión, donde se busca predecir una categoría o un valor numérico, respectivamente.
- **Aprendizaje No Supervisado:** El aprendizaje no supervisado que busca descubrir patrones ocultos en los datos sin necesidad de contar con datos previamente etiquetados. Los algoritmos más utilizados en el aprendizaje no supervisado son los algoritmos de clustering, el análisis de componentes principales, la descomposición en valores singulares (SVD), la reducción de dimensionalidad y la detección de anomalías. Estos algoritmos se utilizan para problemas de agrupamiento, reducción de dimensionalidad y detección de patrones en los datos
- **Aprendizaje Reforzado:** El aprendizaje por refuerzo es una técnica en la que un agente aprende a tomar decisiones óptimas en un entorno dinámico a través de recompensas y castigos basado en la experiencia de las decisiones previas tomadas. Los algoritmos más utilizados en el aprendizaje por refuerzo incluyen Q-Learning, Deep Q Network (DQN), algoritmos de políticas, algoritmos actor-crítico y algoritmos genéticos. Estos algoritmos permiten que el agente aprenda a tomar decisiones secuenciales para maximizar la recompensa a largo plazo en diversos campos como la robótica, los videojuegos, el control de procesos y las finanzas

3.2.4 Algoritmos de aprendizaje Supervisado

Estos son los algoritmos de aprendizaje supervisado que serán utilizados para la solución propuesta, fueron seleccionados teniendo en cuenta los trabajos relacionados y sus hallazgos. Se presenta una breve descripción de cada uno de los algoritmos:

- **Distributed Random Forest (DRF):** Este es un método de aprendizaje supervisado que se utiliza para clasificación y regresión. Funciona construyendo múltiples árboles de decisión durante el entrenamiento y produciendo la media de las predicciones de los árboles individuales para la regresión, o el modo (la predicción más común) para la clasificación. La distribución de este algoritmo permite manejar grandes conjuntos de datos de manera eficiente.
- **Generalized Linear Model (GLM) with Regularization:** Los GLM son una extensión de los modelos lineales tradicionales que permiten la respuesta de variables dependientes que tienen distribuciones de error distintas a la normal. La regularización (como Lasso, Ridge o Elastic Net) se añade para prevenir el sobreajuste y mejorar la capacidad del modelo de generalización. Esto se logra penalizando los coeficientes del modelo para mantenerlos pequeños o incluso reducir algunos a cero.

- **XGBoost GBM (Gradient Boosting Machine):** XGBoost es una implementación optimizada de gradient boosting que es eficiente, flexible y portátil. Utiliza algoritmos avanzados, como el árbol de aumento de gradiente, para optimizar tanto la velocidad de cálculo como la eficiencia de memoria. Es especialmente conocido por su rendimiento en problemas de clasificación.
- **GBM:** Los Gradient Boosting Machines (GBM) son algoritmos de ensamblaje que construyen modelos predictivos de forma secuencial, añadiendo árboles de decisión en cada paso para corregir los errores del conjunto anterior. En cada iteración, se utiliza una función de pérdida derivable para identificar y minimizar los errores residuales, guiando así la adición del próximo árbol en la dirección que más reduce la pérdida total. Esta técnica enfoca su aprendizaje en las predicciones más difíciles, mejorando iterativamente la precisión del modelo global.
- **Fully-connected Multi-layer Artificial Neural Network:** Esta es una red neuronal artificial en la que cada neurona de una capa está conectada a todas las neuronas de la capa siguiente, formando una arquitectura de "capa completa". Estas redes son versátiles y pueden ser utilizadas para una amplia gama de tareas de aprendizaje supervisado y no supervisado. Son especialmente útiles en el aprendizaje de características no lineales y complejas dentro de los datos.

3.2.5 Algoritmos de aprendizaje no Supervisado

Los algoritmos de aprendizaje no supervisado son un conjunto de técnicas de aprendizaje automático que se utilizan para analizar y extraer patrones ocultos en datos sin necesidad de etiquetas o variables objetivo previamente definidas. Estos algoritmos son particularmente útiles en tareas como la segmentación de clientes, la detección de anomalías y la reducción de dimensionalidad. En esta sección, se exploran las principales técnicas no supervisadas de la literatura, sólo se incluye una breve explicación ya que estos algoritmos no serán utilizados en el trabajo.

- **K-Means Clustering:** Este es probablemente el algoritmo de agrupamiento más conocido. Funciona asignando puntos de datos a k grupos (o clústeres) basándose en sus características. Los puntos de datos se agrupan de manera que la suma de las distancias cuadradas entre los puntos de datos y el centroide de su clúster (la media de todos los puntos del clúster) sea mínima. No obstante, el número de clústeres k necesita ser especificado previamente.
- **Análisis de Componentes Principales (PCA):** PCA es una técnica de reducción de dimensionalidad que transforma los datos a un nuevo sistema de coordenadas, reduciendo el número de variables y conservando la mayor variabilidad posible. Los primeros componentes principales retienen la mayor parte de la variabilidad o información de los datos originales.
- **Agrupamiento Jerárquico:** Este método construye una jerarquía de clústeres de forma iterativa. Existen dos enfoques: divisivo (dividir todo en varios clústeres) y aglomerativo (comenzar con muchos pequeños clústeres y fusionarlos). El resultado

es a menudo visualizado en un dendrograma que muestra la formación de clústeres a diferentes niveles de similitud.

- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise):** DBSCAN es un algoritmo basado en la densidad que forma clústeres a partir de áreas densas de puntos de datos. Es notable por su capacidad para encontrar clústeres de formas arbitrarias y su habilidad para manejar puntos de ruido. No requiere que se especifique el número de clústeres de antemano.
- **Autoencoders:** Aunque generalmente se encuentran en el contexto del aprendizaje profundo, los autoencoders son redes neuronales utilizadas para la reducción de dimensionalidad y la extracción de características. Aprenden a comprimir los datos de entrada en una representación codificada y luego reconstruir la entrada lo más fielmente posible. Esto los hace útiles para aprender representaciones eficientes y para tareas como la eliminación de ruido.

Estos algoritmos tienen una amplia gama de aplicaciones, desde la segmentación del mercado y la detección de anomalías hasta la compresión de datos y la visualización. Cada uno tiene sus propias fortalezas y escenarios ideales de aplicación, y la elección de uno sobre otro dependerá de la naturaleza específica de los datos y del problema a resolver.

3.2.6 Algoritmos de aprendizaje reforzado

Esta es una técnica que imita el proceso de aprendizaje por ensayo y error que los humanos utilizan para lograr sus objetivos en base a experiencias de decisiones previas tomadas. Las acciones de software que trabajan para alcanzar su objetivo se refuerzan, mientras que las que se apartan del objetivo se penalizan. Estos algoritmos utilizan un paradigma de recompensa y castigo al procesar los datos y ejecutar sus acciones. Aprenden de los retornos de cada acción y descubren las mejores rutas de procesamiento para lograr los resultados finales.

Algunos ejemplos destacados que utilizan esta técnica son:

- **Q-Learning:** Es un algoritmo de aprendizaje por diferencias temporales (TD Learning). Aprende la función de valor de la acción, que da el valor esperado de las recompensas futuras por tomar una acción en un estado particular. Uno de sus mayores beneficios es que puede comparar la utilidad esperada de las acciones disponibles sin requerir un modelo del entorno.
- **Deep Q-Networks (DQN):** Esta técnica combina Q-Learning con redes neuronales profundas para proporcionar algoritmos que pueden escalar a problemas más complejos. La innovación clave en DQN fue la introducción de un buffer de repetición y una red objetivo para estabilizar el aprendizaje en entornos más complicados.
- **Policy Gradient Methods:** A diferencia de los métodos que aprenden valores de acción, los métodos de gradiente de política aprenden directamente la política de

acción sin necesidad de aprender la función de valor. Uno de los ejemplos más conocidos es el algoritmo REINFORCE.

- **Actor-Critic Methods:** Estos métodos combinan ideas de los métodos de gradiente de política y los métodos de valor. Tienen dos componentes principales: un "actor" que aprende la política de acción y un "crítico" que estima la función de valor. Esto permite que el algoritmo aproveche las fortalezas tanto de los enfoques basados en políticas como en valores.
- **Proximal Policy Optimization (PPO):** PPO se ha vuelto popular por su simplicidad y eficacia. Es un tipo de algoritmo de gradiente de política que busca realizar actualizaciones de políticas grandes pero seguras. PPO ha sido utilizado en muchos entornos de RL complejos y ha demostrado ser muy efectivo.
- **Trust Region Policy Optimization (TRPO):** TRPO es otro algoritmo de optimización de políticas que hace actualizaciones de política grandes pero seguras. Está diseñado para garantizar que las actualizaciones de la política no sean demasiado grandes, reduciendo el riesgo de rendimiento inestable después de las actualizaciones.
- **Asynchronous Advantage Actor-Critic (A3C):** Este algoritmo introduce el concepto de ejecución asíncrona de múltiples agentes en diferentes instancias del entorno. Cada agente actualiza de forma independiente una red neuronal global, y la red global se comparte entre todos los agentes. Esto acelera significativamente el entrenamiento y ayuda a la exploración del espacio de acción.
- **Soft Actor-Critic (SAC):** Es un algoritmo basado en el actor-crítico que optimiza una política estocástica en un marco de máxima entropía, lo que lo lleva a favorecer estrategias de exploración más diversas y robustas.
- **Algoritmos bioinspirados:** Son algoritmos inspirados en el funcionamiento de la naturaleza, que replican la forma con la que ésta afronta problemas de optimización, tratan de imitar la evolución natural de las especies y la respuesta de los sistemas sociales ante los desafíos que se les presentan. Dentro de estos, se encuentran los algoritmos genéticos, colonia de hormigas, optimización por enjambre de partículas y los meméticos, entre otros.

3.2.7 Métricas para medir desempeño de modelos de aprendizaje automático de clasificación

En el contexto de los modelos de machine learning, las métricas son medidas utilizadas para evaluar la calidad y el rendimiento de los modelos predictivos y de clasificación. Estas métricas son fundamentales para tomar decisiones informadas, comparar modelos y realizar ajustes. Algunas de las métricas más utilizadas, en modelos de clasificación, incluyen la precisión, la sensibilidad (recall) y el F1-Score, otra herramienta muy utilizada y simple para visualizar el desempeño de un modelo es la matriz de confusión, de la cual se derivan los cálculos de las métricas previamente mencionadas. La elección de las métricas depende del tipo de problema y de las características específicas del modelo y de los datos. Las métricas

son esenciales para evaluar el rendimiento de los modelos y tomar decisiones fundamentadas en el ámbito del machine learning.

La importancia radica en su capacidad para proporcionar información cuantitativa sobre la efectividad y la calidad de los modelos. Estas métricas son fundamentales para tomar decisiones informadas, comparar modelos y realizar ajustes. Aquí citaremos y explicaremos algunas de las métricas más usadas y más relevantes como la Matriz de confusión, la precisión, la sensibilidad, el F1 Score y la curva de precisión - recall.

3.2.7.1 Matriz de confusión

La matriz de confusión es una herramienta que permite visualizar el desempeño de un algoritmo de aprendizaje supervisado. Cada columna de la matriz representa el número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real. En términos prácticos, permite ver qué tipos de aciertos y errores está teniendo un modelo a la hora de pasar por el proceso de aprendizaje con los datos. Una representación gráfica de la matriz de confusión se puede observar en la Figura 3.3.




Figura 3.3: Matriz de confusión

3.2.7.2 Precisión

Es simplemente la capacidad del estimador de acertar cuando predice un determinado valor de clase en proporción a todas las predicciones de ese valor de clase que realizó. Se representa por la proporción de verdaderos positivos ("VP" o "TP" según sus iniciales en inglés "True Positives") dividido entre todos los resultados positivos (tanto verdaderos positivos, como falsos positivos representados por las iniciales "FP").

En forma práctica es el porcentaje de casos positivos detectados.

$$precisión = \frac{TP}{TP + FP}$$

Ecuación 3.1: Fórmula de precisión

3.2.7.3 Sensibilidad o Recall

Es un valor que indica la capacidad del estimador de encontrar los verdaderos casos del valor de clase analizado en proporción al total de casos de ese valor de clase presentes en el dataset. La sensibilidad se representa como la fracción de los verdaderos positivos.

También se conoce como Tasa de Verdaderos Positivos (True Positive Rate) ó TP. Es la proporción de casos positivos que fueron correctamente identificadas por el algoritmo.

Se calcula así:

$$recall = \frac{TP}{TP + FN}$$

Ecuación 3.2 - Fórmula de recall

3.2.7.4 F1-Score

Esta es la media armónica entre la precisión y el recall. Por ello es de gran utilidad cuando la distribución de las clases es desigual, por ejemplo en el caso de estudio, cuando la cantidad de procesos sin protestas es muy superior a la cantidad de procesos con protestas.

$$f1\ score = \frac{2 * precisión * sensibilidad}{precisión + sensibilidad}$$

Ecuación 3.3: Fórmula de puntaje F1

3.2.7.5 Curva precision recall o PR Curve

La curva PR es el resultado de dibujar la gráfica entre la precisión y el recall. Esta gráfica nos permite ver a partir de qué recall tenemos una degradación de la precisión y viceversa. Lo ideal sería una curva que se acerque lo máximo posible a la esquina superior derecha (alta precisión y alto recall). Se puede observar una representación gráfica de la curva en la Figura 3.4




Figura 3.4: Curva precision recall

En este gráfico podemos ver que el Average Precision (AP) es igual a 0.62. Este valor es el resultado de una manera de calcular el área bajo la curva PR o PR AUC, o lo que es lo mismo, el resultado de integrar la curva. El Average Precision sirve para evaluar y comparar el rendimiento de modelos. Cuanto más se acerque su valor a 1, mejor será el modelo.

El AUCPR se utiliza para evaluar qué tan bien un modelo de clasificación binaria puede distinguir entre pares o puntos de precisión-recall. La diferencia entre el AUC (área bajo la curva) y el AUCPR radica en que el AUC calcula el área bajo la curva ROC, mientras que el AUCPR calcula el área bajo la curva de Precisión-Recall. La curva de Precisión-Recall no tiene en cuenta los Verdaderos Negativos. En datos desequilibrados, una gran cantidad de Verdaderos Negativos suele opacar los efectos de cambios en otras métricas como los Falsos Positivos. El AUCPR será mucho más sensible a Verdaderos Positivos, Falsos Positivos y Falsos Negativos que el AUC. Por lo tanto, se recomienda el uso de AUCPR sobre AUC para datos altamente desequilibrados, que es el caso de esta investigación.

Un AUCPR de 1.0 indica un modelo perfecto que logra una precisión del 100% para todas las instancias positivas sin comprometer la exhaustividad, en cambio un AUCPR de 0.5 indica un rendimiento similar al azar, donde la precisión y la exhaustividad están equilibradas pero no son distintivas. A medida que el AUCPR se acerca a 1.0, el modelo demuestra un mejor equilibrio entre precisión y exhaustividad. Un valor más alto indica que el modelo puede clasificar positivamente las instancias positivas con mayor precisión y recuperar más instancias positivas en general.

El AUCPR es particularmente útil en problemas de clasificación desequilibrada, donde la clase negativa es dominante y la clase positiva es la de interés. Un AUCPR alto indica un modelo que puede clasificar correctamente las instancias positivas con alta precisión y, al mismo tiempo, recuperar la mayoría de las instancias positivas.

Capítulo 4 - Solución Propuesta

En este capítulo se presenta la solución elaborada, cada sección representa un paso en el proceso para el cumplimiento de los objetivos propuestos. Se eligió un enfoque numérico para cuantificar la probabilidad de que se realice protesta en un proceso de contratación pública, siguiendo el trabajo de Fazekas (Fazekas et al., 2016) al resultado del trabajo, lo llamaremos “score”. Puede ser de gran utilidad para evaluar fácilmente el riesgo de que un procedimiento sea objeto de una protesta. La figura 4.1 es un esquema del proceso a seguir para la generación de la solución.




Figura 4.1: Esquema de la solución propuesta

A continuación se expondrá cómo se obtuvieron los datos y cómo se generó el dataset, luego se utilizará un modelo de machine learning para generar este score, ya que se puede obtener una salida numérica utilizando como parámetros de entrada los atributos de un proceso de contratación pública. Dado que los datos están claramente divididos en dos clases: protestados o no protestados, la solución seleccionada será un clasificador, un algoritmo que a partir de ciertos datos es capaz de indicar la categoría o clase a la que pertenece cierta entrada. Este clasificador puede proporcionar un porcentaje que representa la probabilidad de que un proceso de contratación pública fuera objeto de una protesta. Todo este proyecto y los scripts generados para su ejecución son Open Source así que el código utilizado estará enlazado a cada parte a lo largo de este capítulo.

Para llegar a la solución final y obtener el modelo definitivo, se siguieron los siguientes pasos:

1. **Obtención inicial de los datos de los datos:** Se recolectaron los datos del API de la DNCP en formato JSON, que constituirían la materia prima para el análisis.
2. **Conversión de los datos en formato JSON a un archivo CSV:** Se llevó a cabo una transformación de los datos, convirtiéndolos en un formato más manejable y que se pueda usar para el entrenamiento.
3. **Filtrado de los atributos y las filas relevantes:** Se seleccionaron los atributos y las filas específicas que eran fundamentales, siendo las que mayor información valiosa aportan para el análisis y la construcción del modelo.
4. **Estructuración y transformación de los datos:** Se realizaron varios procesos para estructurar los datos, asegurando que se pueda aprovechar y obtener la mayor información posible de ellos.
5. **Extracción de los datos de las banderas rojas (red flags):** Basándonos en el aporte del trabajo de Elías Mora y Matías Rivas (Mora & Rivas, 2022), su trabajo proporciona alertas que podrían indicar si un proceso es más propenso a recibir protestas.
6. **Balanceo del conjunto de datos:** Se realizó un balanceo de datos para garantizar que el modelo fuera entrenado de manera imparcial y efectiva.
7. **Entrenamiento y selección de los modelos:** Se llevaron a cabo experimentos para entrenar diversos modelos de aprendizaje automático y se seleccionaron aquellos cuyo rendimiento era el esperado.
8. **Prueba de los modelos seleccionados con datos más recientes:** Los modelos se pusieron a prueba utilizando datos de compras públicas actuales, para evaluar su capacidad de predicción en condiciones de la vida real.

Estos pasos comprenden el flujo de trabajo por el cual pasan los datos y que representa a nuestra solución propuesta. Como se puede apreciar en la Figura 4.1 al inicio de este capítulo.

Cada uno de estos pasos involucró un proceso de experimentación y refinamiento continuo, con el objetivo de obtener un modelo preciso y efectivo para evaluar el riesgo de protestas en los procedimientos de contrataciones públicas.

4.1 Obtención de los datos. Generación del dataset

Para obtener los datos, se utilizó el API de la DNCP, el cual puede encontrarse en su página web¹⁵, que retorna información sobre las contrataciones públicas del Paraguay, según las consultas que se le envíen y usando el formato OCDS. El API fue utilizado en conjunto a la herramienta Kingfisher Collect¹⁶ la cual descarga los datos y los almacena en disco.

Para llevar a cabo el trabajo propuesto y desarrollar una solución integral, fue esencial contar con la mayor cantidad de datos disponibles sobre procesos de contratación pública y protestas. Aunque la Dirección Nacional de Contrataciones Públicas (DNCP) dispone de datos de procesos desde 2012, la información completa sobre protestas asociadas a estos procesos comenzó a publicarse recién a partir de 2015. Por lo tanto, en este proyecto se

¹⁵ <https://www.contrataciones.gov.py/datos/api/v3/doc/>

¹⁶ <https://github.com/open-contracting/kingfisher-collect>

optó por utilizar datos desde 2016 hasta mediados de 2023. Se eligió el año 2016 como punto de partida, ya que fue el primer año en el que la DNCP incluyó en sus datos abiertos información detallada sobre procesos con protestas¹⁷. De igual forma toda la solución propuesta se puede utilizar para extraer datos más antiguos o más nuevos de los que se utilizaran en este trabajo.

Una vez obtenidos todos los datos en formato OCDS, se guardaron las variables o campos en el formato CSV utilizando la herramienta kingfisher Process¹⁸ la cual almacena y preprocesa dichos datos. Entre estos campos, existen variables estructuradas, a estas variables, es fácil convertirlas a columnas de una tabla. Pero también existen algunas variables dinámicas o no estructuradas las cuales varían en cantidad de elementos o forma en la que se presentan, por lo que el proceso de pasar estas variables a columnas de una tabla es más complejo. A continuación hablaremos sobre las variables utilizadas en el dataset.

4.1.1 Dataset: Variables estructuradas

Para la selección de estas variables, se tuvo en cuenta como referencia a aquellas las cuales la DNCP utiliza para sus reportes de datos anuales y dashboards. Entre las variables estructuradas que se seleccionaron para ser utilizadas en el conjunto de datos (dataset) final se encuentran la Tabla 4.1

Nombre de la variable	Explicación
ocid	Identificador único global para el proceso de Contrataciones Abiertas
id	Identificador del release (entrega) de información particular. Único en el ámbito del proceso de contrataciones relacionado
language	El idioma predeterminado de los datos, usando dos letras
date	La fecha en la cual la información contenida en la entrega fue registrada por primera vez, o publicada, por cualquier sistema
initiationType	El tipo de proceso de iniciación utilizado para este contrato.
tag	Las etiquetas se utilizan para filtrar entregas y para entender el tipo de información que estas contienen
tender	Licitación. Actividades llevadas a cabo para celebrar un contrato
tender.id	Identificador para el proceso de contratación pública. Esto puede ser igual al ocid, o un identificador interno para este proceso.

¹⁷ https://gitlab.com/dncp-opendata/extensions_info/-/blob/master/README.md

¹⁸ <https://github.com/open-contracting/kingfisher-process>

tender.title	El título del proceso de contratación pública.
tender.status	El estado actual del proceso.
tender.awardCriteria	Los criterios de adjudicación para esta compra
tender.awardCriteriaDetails	Detalles o informaciones adicionales sobre la adjudicación o criterios de selección
tender.bidOpening.date	La fecha y hora de la apertura de ofertas del proceso
tender.bidOpening.address	La dirección en donde tendrá lugar la apertura de ofertas de la licitación
tender.submissionMethodDetails	Cualquier detalle o más información sobre el método de entrega
tender.eligibilityCriteria	Una descripción de los criterios de elegibilidad para proveedores potenciales. Requisitos y condiciones que deben cumplir los interesados para participar en el procedimiento de contratación
tender.statusDetails	El nombre local del status (estado).
tender.enquiriesAddress.streetAddress	La dirección del lugar donde se llevan a cabo las aclaraciones del proceso. Específicamente la dirección de la calle.
tender.mainProcurementCategory	La categoría principal del Proceso de Contratación.
tender.mainProcurementCategoryDetails	El nombre local que se le da a la Categoría Principal del Proceso de Contratación.
tender.hasEnquiries	Campo booleano que indica si se recibieron consultas durante el proceso de contratación pública.
tender.value	Valor máximo estimado de la contratación.
tender.value.amount	Es el monto como una cifra.
tender.value.currency	La moneda en la cual está el monto
tender.datePublished	La fecha en la que el proceso fue publicado.
tender.tenderPeriod	El periodo cuando el proceso de contratación está abierto para la recepción de propuestas.
tender.tenderPeriod.startDate	Fecha de inicio del periodo
tender.tenderPeriod.endDate	Fecha de conclusión del periodo
tender.tenderPeriod.durationInDays	Tiempo máximo de duración de este periodo en días.

tender.awardPeriod.startDate	El periodo de para tomar decisiones relacionadas a la adjudicación del contrato. Start Date indica el comienzo del periodo para la decisión de adjudicación.
tender.enquiryPeriod	El periodo durante el cual los postulantes potenciales pueden hacer preguntas o solicitudes de aclaración a la entidad que gestiona el proceso de contratación.
tender.enquiryPeriod.startDate	Fecha de inicio del periodo.
tender.enquiryPeriod.endDate	Fecha de conclusión del periodo.
tender.enquiryPeriod.durationInDays	Tiempo máximo de duración de este periodo en días.
tender.contractPeriod	El periodo sobre el cual se estima el contrato o se requiere que esté activo.
tender.contractPeriod.startDate	Fecha de inicio del periodo.
tender.contractPeriod.endDate	Fecha de conclusión del periodo
tender.contractPeriod.maxExtensionDate	Expresa la fecha máxima disponible para la extensión o renovación de este periodo.
tender.contractPeriod.durationInDays	Tiempo máximo de duración de este periodo en días.
tender.procurementMethod	El método de adquisición o contratación. Podría ser: abierta, selectiva. limitada o directa.
tender.procurementMethodDetails	Detalles adicionales sobre el método de adquisiciones utilizado. Este campo puede usarse para dar el nombre local del método de adquisición particular que se utilizó.
tender.procuringEntity.id	El identificador único de la entidad que gestiona el proceso de contratación. Esta puede ser distinta del comprador que paga/usa los artículos adquiridos.
tender.procuringEntity.name	Nombre de la entidad contratante.
tender.numberOfTenderers	El número total de propuestas recibidas.
tender.techniques.hasElectronicAuction	Información sobre el uso de técnicas como las subastas electrónicas. Indica si estas son o no utilizadas en este caso.

tender.techniques.hasFrameworkAgreement	Información sobre si son o no utilizadas las técnicas de acuerdo de framework
tender.procurementMethodRationale	Justificación para el método de compra elegido. Esto es especialmente importante para dar una justificación en el caso de procesos de contratación limitados o adjudicaciones directas.
tender.procurementIntention	Es la intención que tiene una entidad o organización de llevar a cabo un proceso de adquisición o contratación en el futuro. Puede ser importante para las partes interesadas, como los proveedores, ya que les permite prepararse para futuras oportunidades de negocios. Campo fuera del estándar OCDS.
tender.procurementIntention.id	Es un identificador de la intención de adquisición.
tender.procurementIntention.uri	Es URL o enlace que proporciona acceso directo a información más detallada o documentos relacionados con la intención de adquisición.
tender.procurementIntention.rationale	Explicación o justificación de por qué la entidad está considerando llevar a cabo esta adquisición en particular.
tender.procurementIntention.category	Categoría o tipo de adquisición que se está considerando, lo que puede incluir bienes, servicios u obras específicas.
tender.procurementIntention.title	Es el título o nombre breve que describe la intención de adquisición de manera general.
tender.procurementIntention.description	Descripción más detallada de la intención de adquisición.
tender.procurementIntention.startDate	Fecha prevista en la que se planea iniciar el proceso de contratación pública.
tender.procurementIntention.publishedDate	Fecha en la que se publicó inicialmente la información sobre la intención de adquisición
tender.procurementIntention.procuringEntity.id	Identificador único de la entidad que está considerando llevar a cabo la adquisición.
tender.procurementIntention.procuringEntity.name	Es el nombre de la entidad que está considerando la adquisición.
tender.procurementIntention.status	Estado general de la intención de adquisición, por ejemplo, si está en proceso, planificada o cancelada
tender.procurementIntention.statusDetails	Detalles adicionales sobre el estado de la intención de adquisición.
tender.lots.count	Se contó la cantidad de lotes de este proceso.
tender.enquiries.count	Se contó la cantidad de consultas, preguntas de este proceso.

awards.count	Se contó la cantidad de adjudicaciones de ese proceso de contratación pública. Puede haber más de una adjudicación por proceso de contrataciones; por ejemplo, porque el contrato se divide entre varios proveedores, o porque es una oferta permanente.
contracts.count	Se contó la cantidad de contratos firmados entre el comprador y el o los proveedores de este proceso de contratación pública.
buyer	Un comprador es una entidad cuyo presupuesto se utilizará para pagar bienes, obras o servicios relacionados con un contrato. Este puede ser diferente de la entidad contratante que puede especificarse en los datos del proceso de contratación pública.
buyer.id	El id de una parte involucrada a la que se hace referencia.
buyer.name	El nombre de la parte involucrada al que se hace referencia.
planning	Información sobre la fase de planificación del proceso de contratación.
planning.identifier	Identificador para esta planificación.
planning.estimatedDate	La fecha estimada de inicio del proceso de contratación pública.
planning.budget	Detalles del presupuesto que financia este proceso de contratación.
planning.budget.description	Un texto descriptivo breve de la fuente del presupuesto.
planning.budget.amount.amount	Cifra que muestra el monto del presupuesto que financia este proceso de contratación.
planning.budget.amount.currency	La moneda en la que está dicho monto.
secondStage.id	El identificador de los datos sobre la segunda etapa de un proceso de adquisiciones de múltiples etapas, como acuerdos marco o precalificaciones.

Tabla 4.1: Variables estructuradas y su explicación correspondiente

4.1.2 Dataset: Variables complejas

Las siguientes variables no estructuradas requieren de ciertas transformaciones para poder ser utilizadas en el dataset. En la siguiente Tabla 4.2, se citarán las variables y las técnicas utilizadas y luego de esto se explicara como funciona cada una de estas técnicas.

Campo	Explicación	Método Utilizado
contracts.guarantees.obligations	Se tiene información de las garantías utilizadas para asegurar que se cumplan con los términos de los contratos. Esta variable es una lista de las obligaciones garantizadas	One hot encoding
contracts.investmentprojects.id	Lista de identificadores únicos de proyectos de inversión a los que este contrato pertenece	One hot encoding
contracts.amendments.amendsAmount	Si se realiza una enmienda para aumentar el monto del contrato, ese monto adicional debe registrarse en este campo	Suma de montos según moneda
contracts.amendments.count	cantidad de enmiendas del contrato	Contar la cantidad de elementos
contracts.implementation.purchaseOrders.count	cantidad de órdenes de compra realizadas para este contrato	Contar la cantidad de elementos
contracts.implementation.transactions.count	Cantidad de transacciones de pago realizadas para este contrato	Contar la cantidad de elementos
contracts.documents.DocumentTypeDetails	Lista de los nombres locales de todos los documentos y archivos adjuntos relacionados con el contrato	One hot encoding
contracts.value.amounts	el monto como una cifra del valor total del contrato	Suma de montos según moneda
contracts.status	El estado actual del contrato	One hot encoding
contracts.statusDetails	El nombre local del estado del contrato	One hot encoding

awards.documents.documentTypeDetails	Lista de los nombres locales de todos los documentos y archivos adjuntos relacionados con el contrato	One hot encoding
awards.supplier.id	Lista de ids de los proveedores adjudicados	Técnica de división en cuartiles
awards.value.amount	el monto como una cifra del valor total de la adjudicación	Suma de montos según moneda
awards.status	El estado actual de la adjudicación	One hot encoding
awards.statusDetails	El nombre local del estado de la adjudicación	One hot encoding
tender.criteria.id	La lista de identificadores únicos de los criterios sobre los cuales se evaluarán o valorarán tanto los licitantes como los artículos	Valor Booleano
tender.enquiries	Lista de consultas o preguntas sobre esta licitación enviadas a la entidad contratante	Contar la cantidad de elementos
tender.lots	La lista de lotes de la licitación	Contar la cantidad de elementos
tender.notifiedSuppliers.id	La lista de identificadores únicos de los proveedores que han sido invitados a participar en esta licitación	Técnica de división en cuartiles
tender.documents.documentTypeDetails	Lista de los nombres locales de todos los documentos y archivos adjuntos relacionados con la adjudicación	One hot encoding 70-30%
tender.tenderers.id	La lista de identificadores únicos de los licitantes. Todas las partes que hacen una oferta en la licitación	Técnica de división en cuartiles
tender.items.classification	La clasificación primaria que se da a cada uno de los	Este campo puede ser dividido en niveles: - N5: cuartiles.

	bienes, obras y servicios que se decidió comprar. Se dividió esto en cuatro niveles yendo de los más específico a lo más general	- N4: cuartiles. - N3: cuartiles. - N2: one hot encoding 70-30% - N1: dos variantes: ➤ one hot encoding 70-30% ➤ one hot encoding normal.
planning.items.classification	La clasificación primaria que se da a cada uno de los bienes y servicios que se tiene planificado comprar. Se dividió esto en cuatro niveles yendo de los más específico a lo más general	Este campo puede ser dividido en niveles: - N4: cuartiles. - N3: cuartiles. - N2: one hot encoding 70-30%. - N1: dos variantes: ➤ one hot encoding 70-30% ➤ one hot encoding normal.
parties	La información de las partes involucradas (organizaciones, operadores económicos y otros participantes) que están involucrados en el proceso de contrataciones y sus roles	Para los parties a parte de generar nuevas columnas de acuerdo a las técnicas, también se dividió cada una de esas nuevas columnas en 9 columnas, una para cada rol.
parties.details.entityType	Clasificación organizacional de acuerdo a si la entidad es sub-nacional, nacional, o una entidad descentralizada	One hot encoding
parties.details.legalEntityTypeDetail	Clasificación organizacional de acuerdo con la estructura superior del Estado en Paraguay	One hot encoding
parties.roles	El rol (o roles) de las partes involucradas en el proceso de contrataciones	Técnica de división en cuartiles

Tabla 4.2: Variables complejas y sus técnicas de estructuración correspondientes

4.2 Flattening aplicado al dataset

Como se mencionó anteriormente, para las variables complejas fue necesaria la utilización de las técnicas de flattening, para poder estructurar los datos y usarla como input en un modelo predictivo.

Un caso particular de flattening fue el de las variables que simbolizan los ítems requeridos y usados por la licitación: `planning.items.classification` y `tender.items.classification`. Los valores que toman estas variables son códigos que sirven para clasificar ítems. En este caso, los códigos simbolizan niveles, que van de lo más general a lo más específico. El nivel más alto muestra más detalle (por lo tanto la variable tomará más valores). Estos niveles se identifican seleccionando los dígitos del código de a dos, yendo de izquierda a derecha, siendo el número que contiene los dos últimos dígitos el nivel más alto.

Por ejemplo, teniendo un código de diez dígitos, para efectos prácticos se puede usar "1234567890", Los dos primeros dígitos representan el nivel más bajo, una categoría más general como por ejemplo: "12": Construcción y saneamiento de estructuras viales y edificios.

El siguiente nivel serían los cuatro primeros dígitos que puede representar una categoría un poco más específica que la anterior, como por ejemplo: "1234": Materiales e insumos de construcción. y así sucesivamente hasta llegar al nivel 5 que está compuesto por las categorías más específicas.

Estos tipos de variables se dividieron en varias columnas, una por cada nivel y a cada una de estas columnas fue aplicada una de las técnicas mencionadas anteriormente.

4.3 Análisis de cardinalidad de las variables

En las subsecciones anteriores se explicaron detalladamente las variables seleccionadas como columnas de datos que serán utilizadas para alimentar y entrenar el modelo. Además, se mencionaron las técnicas empleadas para estructurar estos datos de acuerdo a su cardinalidad. A continuación, se detalla el estudio aplicado a todas las variables retornadas por la DNCP.

Para cada una de estas variables o campos, obtenidos previamente de la base de datos abierta de contrataciones públicas del DNCP, se presentará la cantidad total de valores que toma la variable, la cardinalidad de la variable(cantidad de valores distintos que toma) y el porcentaje de valores distintos que se repiten más de una vez para la variable; junto con un gráfico que muestra las diez variables principales y su frecuencia de aparición.

Además los diversos campos serán divididos en subsecciones según cada uno de los campos padres.

4.3.1 Parties

Los subcampos dentro de 'Parties' tienen la particularidad de poder ser divididos según los roles que cada una de las partes puede desempeñar en la licitación. En esta subsección, se

llevará a cabo el análisis de cardinalidad y también se indicará el valor con más apariciones para cada rol.

- parties.id: La Tabla 4.3 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.2 presenta los 10 valores con más apariciones en el campo. Finalmente la Tabla 4.4 muestra el valor con más apariciones para cada rol que pueden asumir las partes.

Cantidad total de valores	1073171
Cantidad de valores distintos	42154
Valores distintos que aparecen más de una vez (%)	55.615%

Tabla 4.3: Análisis de la cardinalidad de la variable parties.id




Figura 4.2: Gráfico del Top 10 de valores con más apariciones en el campo parties.id

Rol	Valor Predominante
candidate	CARLOS GABRIEL SANCHEZ SARTORIO
enquirer	DATA LAB SA
payer	Ministerio de Salud Pública y Bienestar Social (MSPBS)
payee	DATA SYSTEMS SA EMISORA DE CAPITAL ABIERTO
supplier	DATA SYSTEMS SA EMISORA DE CAPITAL ABIERTO
procuring entity	Ministerio de Salud Pública y Bienestar Social (MSPBS)
buyer	Ministerio de Salud Pública y Bienestar Social (MSPBS)

tenderer	DATA SYSTEMS SA EMISORA DE CAPITAL ABIERTO
notified supplier	DATA SYSTEMS SA EMISORA DE CAPITAL ABIERTO

Tabla 4.4: Valor para cada rol con más apariciones en el campo parties.id

- Parties.details.legalEntityTypeDetail: La Tabla 4.5 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.3 presenta los 10 valores con más apariciones en el campo. Finalmente la Tabla 4.6 muestra el valor con más apariciones para cada rol que pueden asumir las partes

Cantidad total de valores	766373
Cantidad de valores distintos	25
Valores distintos que aparecen más de una vez (%)	92%

Tabla 4.5: Análisis de la cardinalidad de la variable parties.details.legalEntityTypeDetail




Figura 4.3: Gráfico del Top 10 de valores con más apariciones del campo parties.details.legalEntityTypeDetail

Rol	Valor Predominante
candidate	S.A.
enquirer	S.A.
payer	Nulo
payee	S.A.

supplier	Persona Física - Bienes y Servicios
procuring entity	Nulo
buyer	Nulo
tenderer	Persona Física - Bienes y Servicios
notified supplier	S.A.

Tabla 4.6: Valor para cada rol con más apariciones en el campo parties.details.legalEntityTypeDetail

- parties.details.entityType: La Tabla 4.7 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.4 presenta los 4 valores con más apariciones en el campo. Finalmente la Tabla 4.8 muestra el valor con más apariciones para cada rol que pueden asumir las partes.

Cantidad total de valores	198387
Cantidad de valores distintos	4
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.7: Análisis de la cardinalidad de la variable parties.details.entityType




Figura 4.4: Gráfico del Top 4 de valores con más apariciones del campo parties.details.entityType

Rol	Valor Predominante
candidate	Nulo
enquirer	Nulo
payer	Entidades Descentralizadas

payee	Nulo
supplier	Nulo
procuring entity	Municipalidades
buyer	Municipalidades
tenderer	Nulo
notified supplier	Nulo

Tabla 4.8: Valor para cada rol con más apariciones en el campo parties.id

- parties.memberOf: La Tabla 4.9 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.5 presenta los 10 valores con más apariciones en el campo. Finalmente la Tabla 4.10 muestra el valor con más apariciones para cada rol que pueden asumir las partes.

Cantidad total de valores	38083
Cantidad de valores distintos	24
Razón de descarte	95% de los campos tienen valor nulo

Tabla 4.9: Análisis de la cardinalidad de la variable parties.memberOf




Figura 4.5 Top 10 valores con más apariciones del campo parties.memberOf

Rol	Valor Predominante
candidate	Nulo
enquirer	Nulo
payer	Universidad Nacional de Asunción (UNA)

payee	Nulo
supplier	Nulo
procuring entity	Universidad Nacional de Asunción (UNA)
buyer	Presidencia de la República
tenderer	Nulo
notified supplier	Nulo

Tabla 4.10: Valor para cada rol con más apariciones en el campo parties.id

- parties.roles: Para este campo, contamos la cantidad total de veces que aparece cada rol en todas las licitaciones. Teniendo un total de 1073171 elementos, como se puede observar en la Figura 4.6, la distribución es la siguiente:




Figura 4.6: Top 10 valores con más apariciones del campo parties.roles

Además, siguiendo con el análisis de este campo, como se observa en la figura 4.7, en el siguiente gráfico se puede observar las cantidades de roles por licitación, siendo dos roles por licitación el valor más común, seguido por once roles y así

sucesivamente:




Figura 4.7: Top 10 cantidades de roles por licitación

4.3.2 Planning

- `planning.documents.DocumentTypeDetails`: Como está señalado en la Tabla 4.11 esta variable fue descartada porque todos sus valores son nulos.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.11: Análisis de cardinalidad de `planning.documents.DocumentTypeDetails`

- `planning.milestones.type`: Como está señalado en la tabla 4.12 esta variable fue descartada porque todos sus valores son nulos.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.12: Análisis de cardinalidad de `planning.milestones.type`

- `planning.investmentProjects.id`: La Tabla 4.13 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.8 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	7091
Cantidad de valores distintos	266
Razón de descarte	Solo el 2% de los campos tienen datos no nulos.

Tabla 4.13: Análisis de la cardinalidad de la variable `planning.investmentProjects.id`




Figura 4.8: Gráfico del Top 10 de valores con más apariciones del campo *planning.investmentProjects.id*

- *planning.items.classification.id*: La Tabla 4.14 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.9 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	1438870
Cantidad de valores distintos	7692
Valores distintos que aparecen más de una vez (%)	85.998%

Tabla 4.14: Análisis de la cardinalidad de la variable *planning.items.classification.id*




Figura 4.9: Gráfico del Top 10 de valores con más apariciones del campo `planning.items.classification.id`

La variable `planning.items.classification` tiene dos subcampos: `id` y `descripción`, ambos sirven para clasificar de forma única al ítem, para alimentar al dataset se eligió la primera opción, el identificador único, pero para hacer más comprensible este análisis a continuación se agrega la Tabla 4.15 donde se mapea el `id` y la descripción del top 10 de valores que toma esta variable.

identificador	Descripción
72131601	Construccion de edificios comerciales, empresariales o institucionales
72131701	Pavimentación, construccion, arreglo o hermoseamiento de carreteras o caminos
78180101	Servicios de reparacion, mantenimiento de transportes
44103103	Toner
44103105	Cartuchos de tinta
72102201	Instalacion, mantenimiento y reparacion de energia electrica y aparatos eléctricos
41116105	Reactivos o soluciones quimicos
82121507	Impresion de papeleria, formularios, tarjetas
90101603	Servicios de catering
72102602	72102602-Instalacion, reparacion y mantenimiento de mobiliarios y aberturas

Tabla 4.15: Top 10 valores de la variable `planning.items.classification` con sus respectivas descripciones

4.3.3 Tender

- `tender.items.classification.id`: La Tabla 4.16 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.10 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	3101026
Cantidad de valores distintos	23664
Valores distintos que aparecen más de una vez (%)	83.714%

Tabla 4.16: Análisis de la cardinalidad de la variable `tender.items.classification.id`




Figura 4.10: Gráfico del Top 10 de valores con más apariciones del campo `tender.items.classification.id`

Al igual que `planning.items.classification`, para `tender` también se tienen dos subcampos, a continuación la tabla 4.17 muestra el mapeo para hacer más fácil la comprensión de los datos en este estudio.

identificador	Descripción
80111613-9999	Mano de Obra - Mantenimiento y/o reparación
78180101-014	Servicio de mantenimiento y reparacion de Motor
72131601-001	Mantenimiento / Reparacion de aire acondicionado
72102305-001	Construccion e instalaciones electricas
78180101-009	Serv. de repar. y mant. de sistema electrico
78180101-002	Serv. de repar. y mant. de sistema de caja o transmision
72131601-012	Servicio de pintura
72131601-009	Colocacion de pisos - contrapisos
78180101-006	Serv. de mant. y repar. de sistema de freno
72131601-002	Preparacion de obra

Tabla 4.17: Top 10 valores de la variable `tender.items.classification` con sus respectivas descripciones

- `tender.additionalProcurementCategories`: La Tabla 4.18 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.11 presenta los 4 valores con más

apariciones en el campo.

Cantidad total de valores	46209
Cantidad de valores distintos	4
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.18: Análisis de la cardinalidad de la variable `tender.additionalProcurementCategories`




Figura 4.11: Gráfico del Top 4 de valores con más apariciones del campo `tender.additionalProcurementCategories`

- `tender.submissionMethod`: La Tabla 4.19 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.12 presenta los valores con más apariciones en el campo.

Cantidad total de valores	135613
Cantidad de valores distintos	2
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.19: Análisis de la cardinalidad de la variable `tender.submissionMethod`




Figura 4.12: Top valores con más apariciones del campo tender.submissionMethod

- tender.tenderers.id: La Tabla 4.20 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.13 presenta los valores con más apariciones en el campo.

Cantidad total de valores	275689
Cantidad de valores distintos	17487
Valores distintos que aparecen más de una vez (%)	59.193%

Tabla 4.20: Análisis de la cardinalidad de la variable tender.tenderers.id




Figura 4.13 Top 10 de valores con más apariciones del campo tender.tenderers.id

- tender.documents.DocumentTypeDetails: La Tabla 4.21 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.14 presenta los valores con más apariciones en el campo.

Cantidad total de valores	1145654
Cantidad de valores distintos	131
Valores distintos que aparecen más de una vez (%)	92.366%

Tabla 4.21: Análisis de la cardinalidad de la variable `tender.documents.DocumentTypeDetails`




Figura 4.14: Top 10 de valores con más apariciones del campo `tender.documents.DocumentTypeDetails`

- `tender.milestones.type`: Está variable fue descartada como se explica en la Tabla 4.22

Razón de descarte	No se podrán utilizar hitos en este caso, ya que los hitos son variables en el tiempo y en este caso no se tendrá en cuenta el historial completo de la licitación.
--------------------------	---

Tabla 4.22: Análisis de cardinalidad de variable `tender.milestones.type`

- `tender.amendments`: Esta variable fue descartada por tener todos sus valores nulos como lo explica la tabla 4.23

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.23: Análisis de cardinalidad de la variable `tender.amendments`

- `tender.lots`: Para utilizar esta variable, se cuenta la cantidad de lotes por licitación como input. La Tabla 4.24 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.15 presenta las cantidades de lotes por licitación con más apariciones.

Cantidad total de valores	135470
Cantidad de valores distintos	425

Valores distintos que aparecen más de una vez (%)	63.294%
--	---------

Tabla 4.24: Análisis de cardinalidad de variable tender.lots




Figura 4.15: Top 10 de cantidades de lotes por licitación con más apariciones

- **tender.enquiries:** Para utilizar esta variable, se cuenta la cantidad de consultas por licitación respondidas y sin responder para utilizar el dato como entrada para el modelo. La Tabla 4.25 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.16 presenta los valores con más apariciones en el campo.

Cantidad total de valores	13848
Cantidad de valores distintos	355
Valores distintos que aparecen más de una vez (%)	51.549%

Tabla 4.25: Análisis de cardinalidad de la variable tender.enquiries




Figura 4.16 Top 10 de valores con más apariciones del campo tender.enquiries

- tender.clarificationMeetings: Esta variable fue descartada según se explica en la Tabla 4.26

Razón de descarte	Más del 95% sus valores son nulos y su cardinalidad es de 1 o ninguno.
--------------------------	--

Tabla 4.26: Análisis de cardinalidad de la variable tender.clarificationMeetings

- tender.notifiedSuppliers.id: La Tabla 4.27 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.17 presenta los valores con más apariciones en el campo.

Cantidad total de valores	623785
Cantidad de valores distintos	81876
Valores distintos que aparecen más de una vez (%)	14.604%

Tabla 4.27: Análisis de cardinalidad de la variable tender.notifiedSuppliers.id




Figura 4.17 Top 10 de valores con más apariciones del campo tender.notifiedSuppliers.id

- tender.criterias.id: La Tabla 4.28 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.18 presenta los valores con más apariciones en el campo.

Cantidad total de valores	196198
Cantidad de valores distintos	2
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.28: Análisis de cardinalidad de la variable tender.criterias.id




Figura 4.18: Top 2 de valores con más apariciones del campo tender.criterias.id

- tender.coveredBy: La Tabla 4.29 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.19 presenta los valores con más apariciones en el campo.

Cantidad total de valores	26713
Cantidad de valores distintos	8
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.29: Análisis de cardinalidad de la variable tender.coveredBy




Figura 4.19: Top 8 de valores con más apariciones del campo tender.coveredBy

- tender.participationFees.type: Esta variable fue descargada según se explica en la Tabla 4.30.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.30: Análisis de cardinalidad de la variable tender.participationFees.type

- tender.participationFees.amount: Esta variable fue descartada según se explica en la Tabla 4.31.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.31: Análisis de cardinalidad de la variable tender.participationFees.amount

4.3.4 Awards

- awards: La Tabla 4.32 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.20 presenta las 10 cantidades de awards por licitación con más apariciones.

Cantidad total de valores	117751
Cantidad de valores distintos	83
Valores distintos que aparecen más de una vez (%)	57.831%

Tabla 4.32: Análisis de cardinalidad de la variable awards




Figura 4.20: Top 10 de cantidades de awards por licitación con más apariciones

- awards.status: La Tabla 4.33 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.21 presenta los 4 valores con más apariciones en el campo.

Cantidad total de valores	192111
Cantidad de valores distintos	4
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.33: Análisis de cardinalidad de la variable awards.status




Figura 4.21: Top 4 de valores con más apariciones del campo awards.status

- awards.statusDetails: La Tabla 4.34 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.22 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	192111
Cantidad de valores distintos	11
Valores distintos que aparecen más de una vez (%)	90.909%

Tabla 4.34: Análisis de cardinalidad de la variable awards.statusDetails




Figura 4.22: Top 10 de valores con más apariciones del campo awards.statusDetails

- awards.value.amount: La Tabla 4.35 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.23 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	117751
Cantidad de valores distintos	75591
Valores distintos que aparecen más de una vez (%)	8.686%

Tabla 4.35: Análisis de cardinalidad de la variable awards.value.amount




Figura 4.23: Top 10 de valores con más apariciones del campo awards.value.amount

- awards.value.currency: La Tabla 4.36 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.24 presenta los valores con más apariciones en el campo.

Cantidad total de valores	194770
Cantidad de valores distintos	2
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.36: Análisis de cardinalidad de la variable awards.value.currency




Figura 4.24: Top de valores con más apariciones del campo `awards.value.currency`

- `awards.items.classification.id`: La Tabla 4.37 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.25 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	2670588
Cantidad de valores distintos	21401
Valores distintos que aparecen más de una vez (%)	83.650%

Tabla 4.37: Análisis de cardinalidad de la variable `awards.items.classification.id`




Figura 4.25: Top 10 de valores con más apariciones del campo awards.items.classification.id

Al igual que en items.classification de planning y tender también tenemos dos subcampos para awards, a continuación, en la Tabla 4.38, el mapeo para hacer más fácil la comprensión de los datos en este estudio.

identificador	Descripción
78180101-014	Servicio de mantenimiento y reparacion de Motor
72131601-001	Construccion e instalaciones electricas
80111613-9999	Mano de Obra - Mantenimiento y/o reparación
72131601-012	Mantenimiento / Reparacion de aire acondicionado
72102305-001	Servicio de pintura
78180101-009	Serv. de repar. y mant. de sistema electrico
78180101-002	Serv. de repar. y mant. de sistema de caja o transmision
72131601-002	Preparacion de obra
72131601-009	Colocacion de pisos - contrapisos
72131701-002	Construcción de empedrado

Tabla 4.38: Top 10 valores de la variable awards.items.classification con sus respectivas descripciones

- awards.suppliers.id: La Tabla 4.39 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.26 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	195214
Cantidad de valores distintos	15200
Valores distintos que aparecen más de una vez (%)	57.546%

Figura 4.39: Top 10 de valores con más apariciones del campo awards.suppliers.id




Figura 4.26: Top 10 de valores con más apariciones del campo awards.suppliers.id

- awards.documents.DocumentTypeDetails: La Tabla 4.40 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.27 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	1228849
Cantidad de valores distintos	19
Valores distintos que aparecen más de una vez (%)	94.737%

*Tabla 4.40: Análisis de cardinalidad de la variable
awards.documents.DocumentTypeDetails*




Figura 4.27: Top 10 de valores con más apariciones del campo awards.documents.DocumentTypeDetails

- awards.amendments: Esta variable fue descartada según se explica en la Tabla 4.41.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.41: Análisis de cardinalidad de la variable awards.amendments

- awards.relatedLots: Esta variable fue descartada según se explica en la Tabla 4.42.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.42: Análisis de cardinalidad de la variable awards.relatedLots

- awards.requirementResponses: Esta variable fue descartada según se explica en la Tabla 4.43.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.43: Análisis de cardinalidad de la variable awards.requirementResponses

- awards.relatedBids: Esta variable fue descartada según se explica en la Tabla 4.44.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.44: Análisis de cardinalidad de la variable awards.relatedBids

4.3.5 Contracts

- contracts: La Tabla 4.45 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.28 presenta el top 10 de cantidades de contratos por licitación con más

apariciones.

Cantidad total de valores	113053
Cantidad de valores distintos	85
Valores distintos que aparecen más de una vez (%)	58.824%

Tabla 4.45: Análisis de cardinalidad de la variable contracts




Figura 4.28 Top 10 cantidades de contracts por licitación con más apariciones

- **contracts.status:** La Tabla 4.46 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.29 presenta los valores con más apariciones en el campo.

Cantidad total de valores	187165
Cantidad de valores distintos	3
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.46: Análisis de cardinalidad de la variable contracts.status




Figura 4.29: Top de valores con más apariciones del campo `contracts.status`

- `contract.statusDetails`: La Tabla 4.47 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.30 presenta los valores con más apariciones en el campo.

Cantidad total de valores	187165
Cantidad de valores distintos	8
Valores distintos que aparecen más de una vez (%)	87.500%

Tabla 4.47: Análisis de cardinalidad de la variable `contract.statusDetails`




Figura 4.30 Top valores con más apariciones del campo `contracts.statusDetails`

- `contracts.value.amount`: La Tabla 4.48 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.31 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	113053
Cantidad de valores distintos	72622
Valores distintos que aparecen más de una vez (%)	8.674%

Tabla 4.48: Análisis de cardinalidad de la variable `contracts.value.amount`




Figura 4.31: Top 10 valores con más apariciones del campo `contracts.value.amount`

- `contracts.value.currency`: La Tabla 4.49 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.32 presenta los valores con más apariciones en el campo.

Cantidad total de valores	187166
Cantidad de valores distintos	2
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.49: Análisis de cardinalidad de la variable `contracts.value.currency`




Figura 4.32: Top de valores con más apariciones del campo `contracts.value.currency`

- `contracts.items.classification.id`: Esta variable fue descartada según se explica en la Tabla 4.50

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.50: Análisis de cardinalidad de la variable `contracts.items.classification.id`

- `contracts.documents.DocumentTypeDetails`: La Tabla 4.51 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.33 presenta los valores con más apariciones en el campo.

Cantidad total de valores	280766
Cantidad de valores distintos	11
Valores distintos que aparecen más de una vez (%)	81.818%

Tabla 4.51: Análisis de cardinalidad de la variable `contracts.documents.DocumentTypeDetails`




Figura 4.33: Top 10 de valores con más apariciones del campo *contracts.documents.DocumentTypeDetails*

- *contracts.Implementation.transactions*: La Tabla 4.52 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.34 presenta los valores con más apariciones en el campo.

Cantidad total de valores	118219
Cantidad de valores distintos	546
Valores distintos que aparecen más de una vez (%)	60.989%

Tabla 4.52: Análisis de cardinalidad de la variable *contracts.Implementation.transactions*



*Figura 4.34: Top 10 de valores con más apariciones del campo
contracts.Implementation.transactions*

- contracts.Implementation.milestones: Esta variable fue descartada según se explica en la Tabla 4.53

Razón de descarte	No se podrá utilizar hitos en este caso, ya que no hay suficiente información en las observaciones
--------------------------	--

*Tabla 4.53: Análisis de cardinalidad de la variable
contracts.Implementation.milestones*

- contracts.implementation.documents.DocumentTypeDetails: Esta variable fue descartada según se explica en la Tabla 4.54.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

*Tabla 4.54: Análisis de cardinalidad de la variable
contracts.implementation.documents.DocumentTypeDetails*

- contracts.implementation.purchaseOrders.documents.documentType: Esta variable fue descartada por la razón que se explica en la Tabla 4.55.

Razón de descarte	Este campo siempre toma solamente un valor: "contractSchedule"
--------------------------	--

*Tabla 4.55: Análisis de cardinalidad de la variable
contracts.implementation.purchaseOrders.documents.documentType*

- contracts.implementation.purchaseOrders: La Tabla 4.56 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.35 presenta los valores con más apariciones en el campo.

Cantidad total de valores	19781
Cantidad de valores distintos	210
Valores distintos que aparecen más de una vez (%)	64.286%

*Tabla 4.56: Análisis de cardinalidad de la variable
contracts.implementation.purchaseOrders*




Figura 4.35 Top 10 de cantidades de órdenes de compra por licitación con más apariciones

- `contracts.relatedProcess`: Esta variable fue descartada según se explica en la Tabla 4.57.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.57: Análisis de cardinalidad de la variable `contracts.relatedProcess`

- `contracts.milestones`: Esta variable fue descartada según se explica en la Tabla 4.58

Razón de descarte	No se podrán utilizar hitos en este caso, ya que la entrada se basará en procesos de contratación pública y un snapshot de su estado actual, no se tendrán en cuenta los historiales de cada licitación.
--------------------------	--

Tabla 4.58: Análisis de cardinalidad de la variable `contracts.milestones`

- `contracts.amendments`: La Tabla 4.59 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.36 presenta el top 10 de cantidades de enmiendas por licitación con más apariciones.

Cantidad total de valores	28472
Cantidad de valores distintos	21
Valores distintos que aparecen más de una vez (%)	66.667%

Tabla 4.59: Análisis de cardinalidad de la variable `contracts.amendments`




Figura 4.36: Top 10 de cantidades de enmiendas por licitación con más apariciones

- `contracts.amendments.amendsAmount.amount`: La Tabla 4.60 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.37 presenta los valores con más apariciones en el campo.

Cantidad total de valores	23277
Cantidad de valores distintos	16063
Valores distintos que aparecen más de una vez (%)	7.483%

Tabla 4.60: Análisis de cardinalidad de la variable `contracts.amendments.amendsAmount.amount`




Figura 4.37: Top 10 de valores con más apariciones del campo `contracts.amendments.amendsAmount.amount`

- `contracts.amendments.amendsAmount.currency`: La Tabla 4.61 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.38 presenta los valores con más apariciones en el campo.

Cantidad total de valores	23277
Cantidad de valores distintos	2
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.61: Análisis de cardinalidad de la variable `contracts.amendments.amendsAmount.currency`




Figura 4.38: Top de valores con más apariciones del campo `contracts.amendments.amendsAmount.currency`

- `contracts.investmentProjects.id`: La Tabla 4.62 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.39 presenta los valores con más apariciones en el campo.

Cantidad total de valores	7395
Cantidad de valores distintos	260
Valores distintos que aparecen más de una vez (%)	83.462%

Tabla 4.62: Análisis de cardinalidad de la variable `contracts.investmentProjects.id`




Figura 4.39: Gráfico del Top10 de valores con más apariciones del campo `contracts.investmentProjects.id`

- `contracts.suppliers.id`: Esta variable fue descartada según se explica en la Tabla 4.63.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.63: Análisis de cardinalidad de la variable `contracts.suppliers.id`

- `contracts.guarantees.id`: La Tabla 4.64 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.40 presenta las 10 cantidades de garantías más comunes por licitación.

Cantidad total de valores	35234
Cantidad de valores distintos	29
Valores distintos que aparecen más de una vez (%)	86.207%

Tabla 4.64: Análisis de cardinalidad de la variable `contracts.guarantees.id`




Figura 4.40: Gráfica del Top 10 de cantidades de garantías por licitación con más apariciones

- `contracts.guarantees.type`: La variable fue descartada por la razón explicada en la Tabla 4.65.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.65: Análisis de cardinalidad de la variable `contracts.guarantees.type`

- `contracts.guarantees.obligations`: La Tabla 4.66 muestra un análisis de cardinalidad de la variable. Luego, la Figura 4.41 presenta los 10 valores con más apariciones en el campo.

Cantidad total de valores	49031
Cantidad de valores distintos	18
Valores distintos que aparecen más de una vez (%)	100%

Tabla 4.66: Análisis de cardinalidad de la variable `contracts.guarantees.obligations`




Figura 4.41: Top 10 de valores con más apariciones del campo contracts.guarantees.obligations

- contracts.requirementResponses: La variable fue descartada por la razón explicada en la Tabla 4.67.

Razón de descarte	Todos sus valores son nulos
--------------------------	-----------------------------

Tabla 4.67: Análisis de cardinalidad de la variable contracts.requirementResponses

4.3.6 Otros

- relatedProcesses.id: La variable fue descartada por la razón explicada en la tabla 4.68.

Razón de descarte	Más del 96% de las licitaciones toman valor nulo
--------------------------	--

Tabla 4.68: Análisis de cardinalidad de la variable relatedProcesses.id

- relatedProcesses.relationship: La variable fue descartada por la razón explicada en la tabla 4.69.

Razón de descarte	Más del 96% de las licitaciones toman valor nulo
--------------------------	--

Tabla 4.69: Análisis de cardinalidad de la variable relatedProcesses.relationship

- sources.id: La variable fue descartada por la razón explicada en la tabla 4.70.

Razón de descarte	Siempre toma el mismo valor, el id correspondiente al Sistema de Información de las Contrataciones Públicas - DNCP.
--------------------------	---

Tabla 4.70: Análisis de cardinalidad de la variable sources.id

- bids: Fue descartado con todos sus subcampos, según la razón explicada en la Tabla 4.71:
 - bids.status
 - bids.value.amount
 - bids.requirementResponses
 - bids.items.classification.id
 - bids.tenderers
 - bids.documents.DocumentTypeDetails
 - bids.relatedLots

Razón de descarte	Menos del 5% de las licitaciones tienen valor no nulo para este campo
--------------------------	---

Tabla 4.71: Análisis de cardinalidad de bids y sus subcampos

- auctions: Fue descartado con todos sus subcampos, según la razón explicada en la Tabla 4.72:
 - auctions.status
 - auctions.relatedLots
 - auctions.stages
 - auctions.winningBids.value.amount

Razón de descarte	Menos del 5% de las licitaciones tienen valor no nulo para este campo
--------------------------	---

Tabla 4.72: Análisis de cardinalidad de auctions y sus subcampos

- secondStage: Fue descartado con todos sus subcampos, según la razón explicada en la tabla 4.73:
 - secondStage.id
 - secondStage.candidates
 - secondStage.invitations
 - secondStage.documents.DocumentTypeDetails

Razón de descarte	Solamente 68 de las licitaciones tienen valor no nulo para este campo (esto es menos del 0,04%)
--------------------------	---

Tabla 4.73: Análisis de cardinalidad de secondStage y sus subcampos

Como resultado de la fase de selección de variables a utilizar y la estructuración de los datos, este estudio arroja su primer resultado: un conjunto de datos presentado de manera organizada y estructurada que abarca los procesos de contratación pública desde el año 2016 hasta el 2023. Este dataset emerge como una fuente de información muy valiosa no solo para el presente estudio, sino también como un recurso que podría ser aprovechado en una variedad de investigaciones adicionales y en el entrenamiento de modelos en el mismo ámbito.

La uniformidad y estructura de estos datos proporcionan una base sólida para futuros análisis y proyectos. Además, al ofrecer información histórica y actualizada sobre los

procesos de licitación, este dataset se convierte en una fuente eficaz para futuros estudios que busquen comprender tendencias, identificar patrones y desarrollar modelos predictivos en base a la información que contiene.

En resumen, este conjunto de datos no solo es útil para el presente estudio, sino que también promete ser un recurso de gran relevancia para la comunidad académica, investigadores y profesionales que desean profundizar en el análisis y la predicción de eventos relacionados con licitaciones en el ámbito de contrataciones públicas.

4.4 Anexo de red flags al dataset

En la investigación para elaborar el estado del arte, se observó que un trabajo ya usaba los datos OCDS de Paraguay para obtener información de los mismos, el trabajo implementado por Mora y Rivas (Mora & Rivas, 2022). Los datos generados por este trabajo fueron las red flags detectadas para cada licitación en el proceso de contratación pública mediante el uso del motor de reglas de negocio para dicha detección.

Aquí se generó la idea de anexar el output de este trabajo a los datos de entrenamiento ya obtenidos. Ya que los datasets eran compatibles y el trabajo para generar las red flags ya estaba hecho, estos datos de red flags resultantes fueron agregados en forma de columnas al conjunto de datos estructurados en este trabajo. Esta información proporciona un valor significativo al modelo, ya que representa alarmas activadas, alarmas que en diversos casos indican anomalías e irregularidades en una licitación.

Para la integración de las red flags, fue necesario usar Elasticsearch, que es un servidor de búsqueda basado en Lucene. Provee un motor de búsqueda de texto completo, distribuido y con capacidad de multitenencia con una interfaz web RESTful y con documentos JSON. Es una herramienta versátil que se utiliza en una amplia variedad de aplicaciones más allá de la búsqueda de texto. En este caso se utilizó por los Ingenieros Rivas y Mora (Mora & Rivas, 2022) para almacenar ciertos datos de cada licitación y las red flags que se dispararon para dicha licitación.

Con los datos ya listos en la base de datos PostgreSQL, el trabajo de Mora y Rivas (Mora & Rivas, 2022) provee un script que se encarga de trasladar los datos desde la base Postgresql al elasticsearch uno por uno, y usando la estructura necesaria para su posterior procesamiento. Este proceso culmina con el elasticsearch cargado con todos los datos necesarios para la generación de las red-flags.

Una vez que se cargó el elasticsearch con datos de las licitaciones, se utilizaron los scripts disponibles nuevamente (Esta vez usando el lenguaje de programación Java) para calcular las red flags. Este cálculo se realizó sobre todos los datos disponibles. El script está encargado de evaluar cada campo de la licitación disponible y asignar las red flags que se disparan según las reglas de negocio propuestas en el trabajo ya mencionado.

El resultado de todo este proceso es una instancia de elasticsearch cargada con licitaciones desde el 2015 al 2023 y las red flags que se disparan para cada una de estas licitaciones.

Finalmente se procedió a codificar un script python que fue el encargado de extraer tanto las red flags generadas como el identificador único OCDS del proceso de licitación. Esto genero como salida un dataset o conjunto de datos con los siguientes campos:

- **id:** Identificador único del proceso licitatorio en formato OCDS.
- **Protestas:** Valor booleano que indica si el proceso ha generado protestas (true) o no (false).
- **Preguntas Sin Respuesta:** Valor booleano que indica si el proceso tiene preguntas sin responder (true) o no (false).
- **Enmiendas del contrato:** Valor booleano que indica si el proceso cuenta con enmiendas de contrato (true) o no (false).
- **Proveedores Notificados CO:** La bandera se activa (true) si menos de 5 proveedores han sido notificados; de lo contrario, se establece como false.
- **Monto faltante:** Valor booleano que indica si el proceso de licitación tiene el campo de monto vacío (true) o no (false).
- **Criterio de evaluación faltante:** Valor booleano que indica si no hay criterios de evaluación (true) o si existen criterios definidos (false).
- **Tiempo de convocatoria LPN:** Valor booleano que indica si el tiempo de convocatoria es muy reducido (true), activándose si el plazo es inferior a 20 días; de lo contrario, se establece como false.
- **Oferente Único:** Valor booleano que indica si sólo existe un oferente (true) en el proceso o si hay múltiples oferentes (false).
- **Tiempo de Convocatoria CO:** El valor booleano de esta bandera será true si el tiempo de convocatoria para el concurso de ofertas es menor a 10 días; de lo contrario, se establece como false.

El conjunto de datos seleccionado para este estudio, abarca datos de procesos de contratación pública entre 2016 y 2023, esos mismos procesos se usaron para generar un conjunto de datos que incluye información sobre todas las banderas de alerta, tanto activas como inactivas, asociadas a cada uno de los procesos, así como el identificador único para cada proceso. Esta nueva información, se emplea en las siguientes etapas como un input adicional en el proceso de entrenamiento del modelo junto con los datos obtenidos y estructurados a partir de la base de datos de la DNCP.

En el estado del proceso al que se llegó, los datos de entrada se presentaban en diversos formatos, como cadenas de texto, valores numéricos, listas, booleanos, entre otros. Para abordar esta diversidad, se aplicaron técnicas de transformación y codificación con el fin de convertir todos los datos al formato numérico necesario y pasar a la siguiente etapa.

Además de la transformación de datos, se implementaron técnicas de "flattening", similares a las que se aplicaron en las variables no estructuradas, para lidiar con las variables estructuradas que presentaban una alta cardinalidad. Este proceso de aplanamiento permitió simplificar el uso de dichas variables.

A continuación, se detallarán las estrategias específicas utilizadas para cada tipo de variable, tanto las de Conversión categórica a binaria como las de aplanamiento de datos.

El aplanamiento de datos o flattening de variables estructuradas se realizó utilizando la técnica de división en cuartiles, la cual fue explicada anteriormente. Las siguientes variables fueron transformadas:

- buyer.id
- buyer.name
- secondStage.Id
- tender.eligibilityCriteria
- tender.mainProcurementCategoryDetails
- tender.procurementIntention.category
- tender.procurementIntention.procuringEntity.id
- tender.procurementIntention.procuringEntity.name
- tender.procurementMethodDetails
- tender.procuringEntity.id
- tender.procuringEntity.name
- tender.submissionMethodDetails

Después de transformar estas columnas en cuatro nuevas columnas cada una, representando la cantidad de elementos en cada cuartil para cada proceso, se procedió a eliminar las columnas originales del conjunto de datos de estudio.

La conversión de datos categóricos a binario, se llevó a cabo utilizando el lenguaje de programación Python en conjunto con las bibliotecas Pandas y NumPy. En esta fase de transformación del conjunto de datos, se realizó una limpieza de los datos como paso inicial.

Para comenzar, se empleó la función *notna* de la biblioteca Pandas para descartar las filas que no tenían un valor definido en los campos: 'tender.tenderPeriod.durationInDays', 'tender.enquiryPeriod.durationInDays' o 'tender.value.amount'.

Continuando con la conversión, se procedió a eliminar las columnas del conjunto de datos que contenían identificadores únicos, ya que estos valores no se repiten y no aportan información relevante al modelo. Las columnas descartadas incluyeron: 'ocid', 'id_x', 'id_y', 'tender.id' y 'tender.procurementIntention.id'. Asimismo, se eliminó la columna 'tender.procurementIntention.uri', ya que se trataba de una URL única para cada caso. También se excluyeron las columnas que contenían información sobre direcciones, como 'tender.bidOpening.address.streetAddress' y 'tender.enquiriesAddress.streetAddress', dado que no proporcionaban información útil para el modelo y presentaban una cardinalidad muy alta.

Se eliminaron las subcolumnas de 'tender.procurementIntention': 'description' y 'category', ya que contenían información redundante que ya se encontraba en otras subcolumnas. La subcolumna 'title' también se descartó, dado que prácticamente todos los títulos eran únicos. Otra variable con datos redundantes fue 'tender.contractPeriod.durationInDays', ya que se podía calcular a partir de las demás subcolumnas de 'contractPeriod'. Para planning se eliminó la columna: 'planning.budget.description', que al igual que las anteriores contiene información redundante ya presente en otras columnas.

Además, se eliminaron otros campos debido a que su cardinalidad era constante en todos los casos, lo que los hacía poco informativos para el modelo. Estos campos incluyen:

'initiationType' (siempre con el valor 'tender'), 'tag' (siempre con el valor 'compiled') y 'language' (siempre con el valor 'es'). También se excluyó la columna 'tender.techniques.hasFrameworkAgreement' al tener un solo valor distinto de nulo y solo aparecer en 72 filas del conjunto de datos. Finalmente, se eliminaron todas las subcolumnas de la variable 'Complaints', ya que esta era la variable objetivo de nuestro estudio.

Se llevaron a cabo transformaciones específicas en las variables de tipo datetime (que incluyen fecha y hora) con el objetivo de optimizar el aprovechamiento de la información disponible. En particular, en la variable 'date', que registra la fecha de registro de los procesos de contratación pública, se aplicaron transformaciones que resultaron en la creación de tres nuevas columnas: una para el mes, otra para el año, y una tercera que combina mes y año, denominadas 'date.month', 'date.year' y 'date.yearmonth' respectivamente. Estas tres nuevas variables desempeñarán un papel fundamental en la identificación de patrones dentro de los datos, al permitir un análisis más detallado con diferentes unidades de tiempo. Estos patrones, posiblemente, no habrían sido identificados utilizando únicamente la variable original. Además, se aplicó una transformación adicional a la variable 'date.year'. En este caso, se procedió a filtrar las filas del conjunto de datos, descartando aquellas en las que la fecha de registro se encuentre en un año anterior a 2016. Este criterio se basa en el hecho de que este estudio se enfoca en datos a partir de dicho año.

Para las demás variables en formato datetime, se siguió la misma lógica que se aplicó a la variable 'date'. Se realizaron transformaciones con el propósito de obtener tres nuevas variables, tal como se explicó previamente. Las variables que fueron objeto de estas transformaciones incluyen: 'tender.bidOpening.date', 'tender.datePublished' y 'planning.estimatedDate'. También las variables: 'tender.tenderPeriod', 'tender.awardPeriod' y 'tender.enquiryPeriod' con sus subcampos: startDate y endDate.

A continuación, se procedió a eliminar las variables datetime originales que ya habían sido transformadas previamente. Esto se debió a que la información a procesar se encontraba contenida en las nuevas variables, y el formato datetime original de estas no era adecuado para los siguientes pasos del proceso. Asimismo, se eliminaron otras variables con formato datetime sin transformar, dado que presentaban muy pocos datos no nulos en sus filas, lo que hacía que no fuera justificable realizar transformaciones en ellas. Estas variables incluyen: 'tender.contractPeriod.startDate', 'tender.contractPeriod.maxExtentDate', 'tender.procurementIntention.publishedDate', 'tender.procurementIntention.startDate' y 'tender.contractPeriod.endDate'.

Para el siguiente grupo de variables, las cuales son variables que representan una baja cardinalidad, se empleó la función `get_dummies` de la biblioteca Pandas. Esta función transforma las variables categóricas en columnas de datos binarios, donde cada columna representa uno de los posibles valores categóricos, y los valores 1 o 0 indican si la variable tomó o no ese valor. Las variables que fueron transformadas con este método son: 'tender.procurementMethod', 'tender.statusDetails', 'tender.value.currency', 'tender.status', 'tender.awardCriteria', 'tender.mainProcurementCategory', 'tender.awardCriteriaDetails', 'tender.procurementMethodRationale', 'tender.procurementIntention.statusDetails', 'tender.procurementIntention.rationale', 'tender.procurementIntention.status' y 'planning.budget.amount.currency'.

Para concluir con las transformaciones, todas las columnas booleanas (que toman un valor o verdadero o falso), como por ejemplo: 'tender.techniques.hasElectronicAuction', fueron transformadas a columnas numéricas de valor 1 si es verdadero o 0 si es falso. Las columnas con vectores creadas a partir de las técnicas de estructuración de datos como cuartiles y one hot encoding se desglosaron en múltiples columnas, donde cada elemento del vector se convirtió en una columna independiente. Finalmente, todos los campos sin ningún valor fueron llenados con el valor 0, con la excepción de la columna 'tender.numberOfTenderers' la cual fue llenada con el valor 1, al siempre tener por lo menos un licitante cada proceso de contratación pública.

Es importante destacar que los datos obtenidos del dataset de las red flags, de los cuales se explicó anteriormente, también se incorporaron a este conjunto de datos. Antes de su incorporación, estos datos pasaron por un proceso de transformación en el que, al igual que los datos booleanos del dataset estructurado de la DNCP, todos los valores verdaderos se asignaron como 1 y los falsos como 0.

Como resultado de esta etapa del proceso, se obtiene un conjunto de datos estructurados y normalizados que contiene la información tanto de la base de datos del DNCP como de las 'red flags' o banderas rojas que fueron activadas por cada uno de estos procesos de contratación pública. Todos los resultados se presentan en formato numérico, lo que lo convierte en un conjunto de datos listo para ser balanceado y, posteriormente, utilizado como entrada para el entrenamiento de modelos de predicción de la probabilidad de protestas en las licitaciones. Este dataset quedará publicado y accesible en Google Drive¹⁹.

4.5 Balanceo del dataset y generación de modelos

Una vez que se obtiene el conjunto de datos final, que se utilizará como entrada para los modelos del estudio, se verifica que este presentaba un desequilibrio o desbalance significativo, ya que este dataset solo contiene protestas en un 8,882% de las licitaciones. Este desequilibrio es un problema común en modelos de clasificación, ya que puede llevar a un rendimiento deficiente en los modelos. Por lo tanto, fue necesario aplicar técnicas de balanceo de datos para utilizar el modelo sin sesgos.

Tomando como referencia varios trabajos y estudios al respecto como por ejemplo el de Comparativa de técnicas de balanceo de datos (García Abad, 2021), para determinar la técnica adecuada, se llevaron a cabo pruebas empíricas comparando los resultados obtenidos. Las opciones evaluadas fueron entrenar el modelo con el dataset sin ninguna modificación; aplicar técnicas de oversampling sobre la clase minoritaria, en este caso los procesos con protesta, aplicar técnicas de undersampling sobre la clase mayoritaria, en este caso los procesos sin protesta; o la combinación del oversampling y el undersampling.

Para la técnica de oversampling, se seleccionó SMOTE como el algoritmo a ser utilizado. Esta técnica requiere de un hiper parámetro el cual es el ratio de balance (o balance ratio). Fueron probados empíricamente valores entre 0,1 y 0,35 subiendo de a 0,015. Con estas

¹⁹ https://drive.google.com/file/d/1-tNBUCWFU0_b9QW6ie4Vvfs7eb4WblPY/view?usp=drive_link

pruebas se encontraron resultados buenos entre 0,14 y 0,155; entonces se volvieron a realizar pruebas empíricas en el rango entre estos dos valores sumando 0,005 al valor en cada iteración. Finalmente se encontraron los resultados deseados con el hiper parámetro con el valor: 0,145.

Es importante aclarar que para las pruebas realizadas, el mismo dataset, modelo y métricas fueron utilizados, y las conclusiones obtenidas fueron las siguientes:

- El conjunto de datos en su estado original no tenía suficientes muestras de casos con protestas para que el modelo pudiera clasificar correctamente las protestas.
- Como se mencionó anteriormente, la técnica de sobre-muestreo o oversampling seleccionada fue SMOTE. Esta técnica resultó ser más efectiva que utilizar el conjunto de datos en su forma original y condujo a resultados más óptimos en este experimento aislado.
- La técnica de sub-muestreo o undersampling utilizada fue el submuestreo aleatorio y se aplicó un enfoque 50/50, ya que elimina la posibilidad de que el modelo se incline hacia la clase más predominante. Los resultados fueron ligeramente más óptimos que usar el modelo en su forma original, y la conclusión fue que las observaciones totales no eran suficientes para que el modelo aprendiera.
- La combinación de muestreos fue la técnica que mostró el rendimiento más óptimo entre todas las demás técnicas para este experimento aislado, utilizando las dos técnicas descritas anteriormente. Por lo tanto, esta combinación se seleccionó como la técnica final de balanceo.

El resultado obtenido en esta etapa, después de aplicar la combinación de oversampling con SMOTE y undersampling, es el conjunto de datos balanceado con ambas clases (con y sin protestas) distribuidas equitativamente en un ratio del 50-50.

Finalmente luego de estas pruebas, la fase de preparación y balanceo del dataset terminó, luego se inició la fase de entrenamiento del modelo utilizando como herramienta principal a H2O AutoML (en su versión: 3.42.0.1) (*H2O AutoML: Automatic Machine Learning — H2O 3.42.0.1 Documentation*, n.d.) (LeDell & Poirier, 2020). Esta herramienta fue seleccionada porque, en base a un grupo de hiper parámetros y configuraciones, permite probar con una gran cantidad de modelos distintos de machine learning, sobre los cuales se prueban distintas configuraciones en base a los parámetros que recibe cada uno; y además se prueban también combinaciones de estos modelos. Hasta llegar al conjunto de modelos con los resultados más óptimos de acuerdo a la métrica que se quiera optimizar. Brindando listas de resultados obtenidos por cada uno de los modelos con sus parámetros configurados. Esto permite trabajar con una gran cantidad de modelos diversos para poder encontrar el que más se adecue a los requerimientos del modelo.

Para esta fase se dividió el dataset en dos partes. La primera parte comprende todos los registros desde el año 2016 hasta el año 2022 y fue utilizada como input para el entrenamiento del modelo. La segunda parte incluye los datos del año 2023, específicamente hasta agosto y estos registros fueron utilizados como datos de validación para el modelo.

Se tuvieron en cuenta las siguientes métricas para evaluar el desempeño de los modelos: precisión, sensibilidad o recall, y F1-score. Además la métrica del Área bajo la curva de precisión-recall (Area Under the Precision-Recall Curve, AUCPR) fue utilizada como la principal métrica de desempeño. Todas estas métricas, junto con sus fórmulas, fueron explicadas en la sección del marco teórico.

Después de una serie de experimentos empíricos para el entrenamiento del modelo, se identificó un conjunto óptimo de hiper parámetros que generan los mejores resultados. En la Tabla 4.74, se describen de manera concisa los hiper parámetros y sus respectivos valores que condujeron a los resultados experimentales:

Parámetro H2O	Explicación y valor utilizado
x	Las columnas del conjunto de datos de entrada, excluyendo la columna o variable objetivo.
y	La columna o variable objetivo, en este caso, la columna Protestas.
training_frame y validation_frame	Estos son los conjuntos de datos de entrenamiento y validación, cuyos valores se explicaron previamente.
max_models	Un valor entero que indica la cantidad máxima de modelos que el proceso de AutoML ejecutará, excluyendo los modelos Stacked Ensemble. Después de diversas pruebas y un equilibrio entre la duración del proceso y la cantidad de modelos a evaluar simultáneamente, se optó por utilizar 42 modelos para este hiper parámetro.
seed	Un valor entero para garantizar la reproducibilidad en el entrenamiento de los modelos. Se eligió aleatoriamente el valor 23 como semilla para los entrenamientos.
sort_metric	La métrica según la cual se ordenará el leaderboard o la clasificación de los modelos al finalizar la ejecución. Se utilizó "AUCPR" como la métrica principal de desempeño seleccionada.
stopping_metric	Este parámetro detiene el entrenamiento de manera temprana si, después de 3 entrenamientos, la métrica elegida (valor del hiper parámetro) no ha cambiado significativamente. También se seleccionó "AUCPR" como valor aquí.

Tabla 4.74: Explicación de parámetros H2O

Todos los demás hiper parámetros, que pueden configurarse, mantuvieron sus valores por defecto o no fueron utilizados, ya que no influyen en el entrenamiento y validación del modelo.

En adición a las métricas previamente mencionadas, se llevaron a cabo pruebas empíricas para seleccionar los hiper parámetros. Se compararon los valores de precisión tanto para los resultados verdaderos como para los falsos en cada modelo de los diferentes leaderboards (tablas con los modelos más performantes).

Los resultados obtenidos de estas comparaciones empíricas condujeron, como se mencionó anteriormente, a la identificación de los parámetros óptimos para lograr los resultados más óptimos.

Usando los hiper parámetros finales obtenidos, se llevó a cabo la ejecución de la herramienta AutoML, generando los siguientes modelos junto con sus respectivas métricas. Estos resultados se presentan en la Tabla 4.75 a continuación, que exhibe diversas métricas, ordenadas de forma descendente según el valor de AUCPR de cada modelo.

model_id	aucpr	auc	logloss	mean_per_class_error	rmse	mse
StackedEnsemble_All Models_1	0.905502	0.955333	0.184771	0.128951	0.227546	0.0517773
StackedEnsemble_Best OfFamily_1	0.902951	0.954166	0.186937	0.128939	0.228654	0.0522827
GBM_grid_1_model_7	0.897297	0.951278	0.194325	0.131874	0.232677	0.0541387
GBM_grid_1_model_8	0.895144	0.949964	0.195882	0.133774	0.233467	0.0545067
XGBoost_grid_1_model_5	0.894219	0.949703	0.207487	0.132953	0.234613	0.0550432
GBM_grid_1_model_5	0.888166	0.948613	0.201197	0.134969	0.238613	0.0569363
GBM_grid_1_model_4	0.887625	0.946709	0.203242	0.133458	0.237822	0.0565591
XGBoost_grid_1_model_7	0.88756	0.945772	0.216199	0.134831	0.238973	0.0571079
XGBoost_grid_1_model_8	0.88617	0.947506	0.2038	0.132513	0.238837	0.0570433
XGBoost_grid_1_model_1	0.882323	0.943308	0.2223	0.139194	0.242147	0.058635
XGBoost_grid_1_model_3	0.882265	0.945753	0.207929	0.136023	0.24155	0.0583463
GBM_grid_1_model_1	0.88196	0.9464	0.206442	0.139252	0.241556	0.0583491
XGBoost_grid_1_model_10	0.879845	0.945219	0.209233	0.138014	0.242785	0.0589443
XGBoost_grid_1_model_6	0.877623	0.943621	0.21191	0.13963	0.243809	0.059443
GBM_4	0.875635	0.943238	0.213479	0.141807	0.246314	0.0606704
GBM_1	0.87518	0.946088	0.213375	0.135841	0.247389	0.0612016
XGBoost_grid_1_model_2	0.875127	0.943644	0.214101	0.133178	0.245347	0.060195
XGBoost_2	0.871166	0.940528	0.219802	0.140858	0.248004	0.061506
XGBoost_1	0.87079	0.941021	0.220062	0.141722	0.248101	0.0615541
GBM_grid_1_model_6	0.868008	0.943484	0.218971	0.143365	0.251241	0.0631219

GBM_3	0.867172	0.940287	0.221853	0.149817	0.252102	0.0635555
XGBoost_grid_1_model_12	0.858284	0.937277	0.227275	0.14597	0.256119	0.0655969
XGBoost_grid_1_model_4	0.858074	0.937805	0.227092	0.152902	0.25634	0.0657101
GBM_grid_1_model_3	0.856874	0.936983	0.230592	0.148914	0.258135	0.0666339
XGBoost_3	0.856325	0.937486	0.2286	0.155055	0.257731	0.0664251
DRF_1	0.856017	0.93556	0.242065	0.156307	0.26284	0.0690848
GBM_2	0.855503	0.935901	0.23217	0.157043	0.258517	0.0668312
GBM_grid_1_model_2	0.851359	0.934181	0.234899	0.147986	0.26004	0.067621
GBM_5	0.842253	0.93035	0.243163	0.159183	0.265265	0.0703654
XGBoost_grid_1_model_11	0.83344	0.927556	0.247331	0.163486	0.269774	0.072778
XGBoost_grid_1_model_9	0.827759	0.92521	0.251188	0.174357	0.27193	0.0739457
XRT_1	0.822739	0.917343	0.322452	0.173803	0.301396	0.0908398
GLM_1	0.794697	0.902484	0.281068	0.187406	0.285317	0.0814057
DeepLearning_grid_3_model_2	0.752915	0.855842	0.518309	0.208481	0.306814	0.0941345
DeepLearning_grid_2_model_2	0.728503	0.86176	0.394761	0.219483	0.310795	0.0965934
DeepLearning_grid_2_model_3	0.725037	0.866006	0.332234	0.221316	0.311114	0.0967916
DeepLearning_grid_3_model_1	0.719446	0.852502	0.40177	0.220296	0.316781	0.10035
DeepLearning_grid_1_model_4	0.700731	0.859965	0.61218	0.216809	0.349836	0.122385
DeepLearning_grid_1_model_3	0.685756	0.844931	0.428886	0.241923	0.334748	0.112056
DeepLearning_grid_1_model_1	0.665798	0.832993	0.559175	0.24794	0.33649	0.113225
DeepLearning_grid_2_model_1	0.664115	0.825464	0.507494	0.251927	0.333214	0.111032
DeepLearning_grid_1_model_2	0.616663	0.833671	0.829108	0.23812	0.425779	0.181288
DeepLearning_grid_3_model_3	0.60467	0.760544	0.52551	0.281759	0.35706	0.127492
DeepLearning_1	0.46511	0.707427	1.46884	0.363742	0.585812	0.343176

Tabla 4.75: Comparación de modelos y resultados obtenidos en sus métricas

Asimismo, se empleó la tabla de valores de precisión verdaderos y falsos como criterio para la selección de los modelos cuyo performance fue superior según las métricas escogidas, la cual se presenta a continuación en la Tabla 4.76

Model	Precisión true	Precisión false
StackedEnsemble_AllModels_1	0.7303	0.9145
StackedEnsemble_BestOfFamily_1	0.75	0.8946

GBM_grid_1_model_7	0.7802	0.8686
GBM_grid_1_model_8	0.7331	0.9014
XGBoost_grid_1_model_5	0.7451	0.887
GBM_grid_1_model_5	0.7233	0.9044
GBM_grid_1_model_4	0.7377	0.8934
XGBoost_grid_1_model_7	0.6879	0.9243
XGBoost_grid_1_model_8	0.7216	0.9174
XGBoost_grid_1_model_1	0.6805	0.9216
XGBoost_grid_1_model_3	0.7205	0.9115
GBM_grid_1_model_1	0.7335	0.8986
XGBoost_grid_1_model_10	0.7117	0.9112
XGBoost_grid_1_model_6	0.6959	0.9225
GBM_4	0.7103	0.929
GBM_1	0.7261	0.923
XGBoost_grid_1_model_2	0.7591	0.8885
XGBoost_2	0.7247	0.9015
XGBoost_1	0.6875	0.9166
GBM_grid_1_model_6	0.7282	0.9181
GBM_3	0.6959	0.932
XGBoost_grid_1_model_12	0.7096	0.9125
XGBoost_grid_1_model_4	0.717	0.9188
GBM_grid_1_model_3	0.7103	0.9268
XGBoost_3	0.7714	0.8845
DRF_1	0.7426	0.8812
GBM_2	0.7275	0.9169
GBM_grid_1_model_2	0.7591	0.8912
GBM_5	0.731	0.9135
XGBoost_grid_1_model_11	0.7718	0.8914
XGBoost_grid_1_model_9	0.7507	0.8985
XRT_1	0.6973	0.9071
GLM_1	0.7286	0.8951
DeepLearning_grid_3_model_2	0.7328	0.8839
DeepLearning_grid_2_model_2	0.6805	0.9101
DeepLearning_grid_2_model_3	0.6798	0.8571
DeepLearning_grid_3_model_1	0.6966	0.9014
DeepLearning_grid_1_model_4	1.0	0.0
DeepLearning_grid_1_model_3	1.0	0.0
DeepLearning_grid_1_model_1	0.9371	0.1193
DeepLearning_grid_2_model_1	0.7714	0.8197
DeepLearning_grid_1_model_2	0.6429	0.9119

DeepLearning_grid_3_model_3	0.6808	0.9145
DeepLearning_1	0.7317	0.856

Tabla 4.76: Comparación de precisión verdadera (positiva) y falsa (negativa) entre los modelos

El modelo seleccionado demostró el rendimiento mas optimo después de las pruebas, al alcanzar la posición destacada en el leaderboard de modelos y también ser el modelo que generaba los valores más óptimos tanto de predicciones verdaderas como falsas (esta información fue obtenida con el algoritmo mostrado al comienzo de la sección). Este modelo en particular es el Stacked Ensemble: StackedEnsemble_AllModels (*Stacked Ensembles — H2O 3.46.0.1 Documentation*, n.d.), funciona combinando diversos modelos, los cuales son empleados como entrada para el metamodelo el cual obtiene resultados más óptimos.

El algoritmo de aprendizaje (meta learner), utiliza las predicciones de todos los modelos base como entrada, es del tipo GLM (Generalized Linear Model) (*Generalized Linear Model (GLM) — H2O 3.46.0.1 Documentation*, n.d.) sin pesos negativos y con estandarización apagada. Además, el mismo fue definido con los parámetros nfolds = 5 como todos los modelos base. Luego de las optimizaciones finales y la selección de modelos hecha por H2O, el resultado fueron estos modelos base:

- 1 modelo Deeplearning
- 3 modelos Deeplearning grid 1
- 3 modelos Deeplearning grid 2
- 3 modelos Deeplearning grid 3
- 1 modelo DRF
- 5 modelos GBM
- 8 modelos GBM grid 1
- 1 modelo GLM
- 3 modelos XGBoost
- 12 modelos XGBoost grid 1
- 1 modelo XRT

En la siguiente imagen, la Figura 4.42, se puede observar los niveles de influencia de cada uno de los modelos que sirvieron de base para el meta learner o meta modelo final. Se puede observar que principalmente los algoritmos de tipo XGBoost y GBM fueron los que más aportaron a la eficiencia del modelo obtenido.




Figura 4.42: Nivel de influencia de sub-modelos para el modelo final

Los modelos grid han sido entrenados con diferentes configuraciones de hiper parámetros, cada uno proveniente de una búsqueda en cuadrícula diferente (técnica grid) (*Grid (Hyperparameter) Search* — *H2O 3.42.0.1 Documentation*, n.d.). La diversidad en las configuraciones de hiper parámetros permite explorar y adaptarse mejor a la complejidad de los datos y mejorar las posibilidades de encontrar un modelo que generalice bien sobre nuevos datos.

Es importante mencionar algunos de los hiper parámetros los cuales fueron utilizados en todos los modelos para asegurar que los datos de entrada sean iguales, los cuales son:

- *nfolds*: Para todos los modelos este valor debe ser igual para realizar la validación cruzada (Schaffer, 1993) y para que los modelos puedan ser una misma entrada. El valor elegido es 5 por defecto.
- *fold_assignment* = "Modulo" junto a *nfolds* garantiza que todas las divisiones (folds) realizadas sean iguales entre sí entre los modelos.
- *training_frame*: Todos los modelos deben tener el mismo conjunto de datos de entrada.

4.6 Resumen del capítulo

Se concluye este capítulo con la solución ya construida, la serie de pasos que se han seguido empezaron con la extracción de los datos desde el API de la DNCP, para lo cual se usó la herramienta del kingfisher collect, luego se generaron las tablas de acuerdo al esquema del kingfisher usando la herramienta del kingfisher process. Posteriormente, con los datos ya en un PostgreSQL, se generó un script de python que sirvió para aplicar todas las transformaciones necesarias²⁰, el resultado fue un dataset con los datos planos y en formato tabular²¹ Este dataset fue unido con los datos obtenidos por el trabajo de Red Flags en contrataciones públicas realizado por Rivas y Mora (Mora & Rivas, 2022). Con ambos datasets combinados, se realiza el preprocesamiento final, para arreglar el problema del desbalanceo se utiliza la técnica SMOTE para generar más observaciones de la clase minoritaria (es decir, los procesos con protesta) y el undersampling aleatorio para remover algunas otras observaciones de la clase mayoritaria (es decir, los procesos sin protestas) luego, con el fin de evitar que el modelo genere sesgos hacia cualquiera de las clases, se escoge un set con distribución de 50% y 50% para ambas clases, esto, fue lo utilizado para entrenar y comparar los modelos usando las utilidades de la librería H2O, este entrenamiento se realizó con datos de los procesos de contratación pública del Paraguay desde el 2016 hasta el 2022, finalmente, se usaron los procesos de contratación del 2023 para validar los resultados del modelo, con esta validación se comparó nuevamente los modelos y se concluyó que el *StackedEnsemble_AllModels_1* fue el modelo que mejor performo, para llegar a este modelo se compararon 42 modelos distintos, se usó como método principal de comparación el AUCPR de cada modelo. En el siguiente capítulo, se explorarán los resultados que se obtuvieron usando el modelo elegido.

²⁰ <https://github.com/davinun99/ocds-flattener/blob/main/src/main.py>

²¹ https://drive.google.com/file/d/1-tNBUCWFU0_b9QW6ie4Vvfs7eb4WbIPY/view?usp=drive_link

Capítulo 5 - Resultados Experimentales

En esta sección se presentan los resultados obtenidos por este trabajo, la solución propuesta fue la generación de un score para medir la probabilidad de que una contratación pública sea objeto de una protesta. Para la generación de dicho score, se compararon algoritmos de clasificación entrenados con la información obtenida de los procesos de contratación pública en el Paraguay desde el 2015 hasta mediados de 2023. Además también se agregaron banderas rojas (o Red flags) las cuales son alertas de anomalías detectadas sobre cada licitación como fuente de información adicional para el entrenamiento del algoritmo.

El experimento en cuestión, estuvo compuesto de varias fases, investigación, implementación, pruebas y ajustes, finalmente se pueden rescatar 5 ítems principales que serán de ayuda para la DNCP o para otros trabajos que busquen profundizar en el análisis de contrataciones públicas, particularmente en el Paraguay, o inclusive en otros países, ya que gracias al uso del estándar OCDS, las herramientas de este trabajo y los análisis realizados, son fácilmente replicables a otros países que también se adhieren al estándar.

Conjunto de Datos Integrado: Se generó una base de datos integrada y limpia con la información de los procesos de contrataciones públicas del Paraguay, publicada por la DNCP. Esta base de datos incluye las red flags disparadas por estos procesos de contratación, basadas en trabajos previos relacionados.

Modelo Predictivo: Se desarrolló un modelo basado en técnicas de machine learning que permite predecir la probabilidad de protesta de un proceso de contratación específico. El modelo utiliza como entrada los atributos seleccionados y las red flags identificadas durante el análisis.

Score de Riesgo: El sistema asigna un score de riesgo a cada proceso de contratación, indicando la probabilidad de que sea protestado. Este score proporciona una medida cuantitativa del nivel de riesgo asociado a cada proceso, permitiendo a los responsables de la toma de decisiones priorizar y gestionar adecuadamente los casos más susceptibles de protestas de manera preventiva y temprana.

API con Score de Riesgo: Se generó una API desarrollada en Python, lista para ser puesta en producción y para ser utilizada en la detección de la probabilidad de protestas de nuevos procesos de contratación pública.

5.1 Conjunto de datos

Una de las principales tareas desarrolladas en este trabajo fue la creación de un conjunto de datos estructurado y limpio²² que pudiera ser utilizado de manera eficiente en el proceso de entrenamiento del modelo y para futuros análisis relacionados con los procesos de contrataciones públicas. La integración de datos provenientes de diversas fuentes y su transformación en un formato utilizable fue un paso clave en la construcción de un modelo robusto. Para la obtención del dataset, como se mencionó previamente, se extrajeron datos en formato JSON directamente de la API de la Dirección Nacional de Contrataciones Públicas (DNCP), los cuales fueron depurados y transformados para facilitar su uso en el análisis y modelado. Esto fue realizado con las herramientas open source proveídas por el equipo del OCDS, el kingfisher collect y el kingfisher process.

Durante el procesamiento, se aplicaron técnicas especializadas para lidiar con variables dinámicas o no estructuradas, tales como el ajuste de campos de longitud variable, el agrupamiento de valores en cuartiles y la codificación de variables categóricas en formatos dicotómicos. Adicionalmente, las "red flags" detectadas en los procesos de contratación fueron transformadas en columnas booleanas, indicando de manera clara la activación o no de cada alerta en los diferentes contratos. Esta estructuración no solo permitió un análisis más preciso y eficaz, sino que también proporcionó un framework adaptable para futuros estudios y modelos.

El conjunto de datos generado es una valiosa contribución al campo, ya que no solo facilita el análisis del comportamiento de las protestas en los procesos de contratación, sino que también ofrece un punto de partida para entrenar modelos adicionales que busquen predecir otros factores o tendencias en las licitaciones públicas. Asimismo, su flexibilidad permite que sea utilizado en otros proyectos de investigación que exploren diversas dimensiones de la contratación pública.

Cabe destacar que los datos empleados abarcan el periodo desde 2016 hasta 2022, debido a que el módulo de protestas de la DNCP comenzó a operar en ese intervalo por lo que los datos de protestas están disponibles recién desde ese año. Los datos correspondientes al año 2023 fueron reservados para la evaluación final del modelo, garantizando una prueba independiente y adecuada del desempeño del sistema predictivo en escenarios más recientes.

5.2 Modelo de clasificación

Con el modelo final, Stacked Ensemble, se procedió a la validación utilizando los datos del año 2023, los cuales comprenden un 10,27% del total de licitaciones en el dataset. Estos datos, no formaron parte del entrenamiento. Esta etapa representa una evaluación del rendimiento del modelo frente a datos de la vida real que aún no ha visto. Para verificar la efectividad y eficiencia del modelo, se calcularon las métricas de desempeño, cuyos resultados se presentan a continuación.

²² https://drive.google.com/file/d/1sfkbbq0RSPJw2ty6jEwCZ2EpdN3W4flm/view?usp=drive_link

5.2.1 Resultados de las métricas de desempeño

Usando el dataset de validación, que contiene todas las licitaciones del año 2023 se obtuvieron los siguientes valores presentados en la Tabla 5.1:

True Positives	2.175
False Positives	824
True Negatives	7.097
False Negatives	673

Tabla 5.1: Valores verdaderos y falsos tanto positivos como negativos del modelo final

Estos son los valores de las métricas de desempeño para el modelo elegido, usando el conjunto de datos de validación, como se puede apreciar en la Tabla 5.2:

	Accuracy		0,8610
	F Measure (Protested class)		0,7440
	AUCPR		0,83067
	Protested	Precisión	0,7252
		Recall	0,7637
	Non protested	Precisión	0,9134
		Recall	0,8960

Tabla 5.2: Valores de las métricas de desempeño del modelo final

Las métricas revelan que el modelo elegido cuenta con una exactitud (accuracy) del 86,1%, y además, un F-Measure de 0,744. Este último indicador arroja resultados más óptimos cuanto más se acerca a 1 y se aleja de 0, señalando así una menor incidencia de falsos positivos y negativos, cuando se acerca más al 1.

También es relevante destacar la capacidad del modelo para detectar con precisión el 72,52% de las licitaciones que tendrán protestas, mientras que demuestra una precisión del 91,34% al identificar aquellas licitaciones que no resultarán en protestas. Se destaca además que el valor de AUCPR obtenido con el conjunto de validación es de 0,83067. Este valor resultante indica una buena precisión.

Por lo tanto, las métricas obtenidas constituyen un sólido indicador de la eficacia del modelo, demostrando que es mas que bueno clasificando procesos de contratación pública que pueden llegar a tener protestas y procesos que no tendrán protestas.

5.3 Score de riesgo

El score de riesgo propuesto utiliza el modelo generado para determinar si una licitación tiene o no protestas, proporcionando dos salidas para cada licitación.

Resultado 1: El porcentaje de probabilidad de que la licitación sea protestada. Este valor proviene directamente del output del modelo y consiste en un porcentaje entre 1 y 100. Puede ser útil para evaluar la probabilidad de que la licitación analizada tenga protestas.

Resultado 2: El nivel de riesgo de que la licitación sea protestada. Este valor se calcula utilizando el Resultado 1 y puede clasificarse como Bajo, Medio o Alto, tal como se muestra en la Tabla 5.3. Aquí se propone utilizar una estrategia similar a una distribución basada en cuartiles para demostrar el riesgo que tiene un proceso de licitación de ser protestado, tomando menor al Q1 como bajo, entre Q1 y Q2 como medio, entre Q2 y Q3 como alto y mayor a Q3 como muy alto.

Nivel	% de probabilidad de protesta
Bajo	< 25 %
Medio	>= 25 % & < 50%
Alto	>= 50 % & < 75%
Muy Alto	>= 75%

Tabla 5.3: Clasificación de los niveles de riesgo según la predicción del modelo

5.4 API con Score de riesgo

Se ha desarrollado un API en Python con el objetivo de exponer el modelo usando el API de la DNCP. Esta API recibe como parámetro un ID de licitación de la DNCP, y usando el API consulta los detalles de la licitación, para posteriormente ejecutar el modelo y retornar los resultados obtenidos, esta API puede ser de gran utilidad para la detección de protestas o integración para mostrar los resultados en otros portales.

Para el desarrollo de dicha API, se ha utilizado el framework Flask del lenguaje de programación Python, y el código está disponible para ser utilizado o mejorado²³.

Se puede observar un ejemplo de respuesta del API en la Figura 5.1

```
{
  - parameters: {
    High: ">= 75%",
    Medium: ">= 50%"
  },
  riskLevel: "Medium",
  riskScore: 71.80748612296824
}
```

Figura 5.1: Respuesta del API en formato JSON

También, como se puede ver en la Figura 5.2, se ha documentado el API usando Swagger, que es un framework de código abierto especialmente diseñado para documentar APIs²⁴.

²³ <https://github.com/davinun99/complaint-scorer-api>

²⁴ <https://app.swaggerhub.com/apis/NUNDAVID99/complaint-scorer-api/1.0.1>

default

GET

/api/v1/predict

Gets complaint prediction for DNCP ID



By passing the DNCP ID, you'll get insights on the possibility of that procurement call to be protested, try 415916 or 367291

Parameters

Try it out

Name	Description
id	DNCP procurement call ID
integer(\$int64) (query)	id

Responses

Code	Description	Links
200	Prediction	No links

Figura 5.2: Swagger del API para detectar protestas

Capítulo 6 - Conclusión y trabajos futuros

Este trabajo representa un paso significativo hacia una comprensión más sofisticada de las probabilidades de protesta en el contexto de la contratación pública. Los prometedores resultados experimentales obtenidos muestran que es posible entrenar un modelo preciso mediante aprendizaje automático para determinar la probabilidad de protesta en un proceso de contratación pública.

La adquisición, entendimiento y procesamiento de los datos que publica la DNCP requirió un complejo proceso de transformación y refinamiento de datos, detallado en este trabajo. Se realizó una evaluación exhaustiva de los diversos atributos, su relevancia y su potencial como indicadores de posibles irregularidades. Esta parte del trabajo

La utilización de una familia de clasificadores de aprendizaje automático, como el Stacked Ensemble de todos los modelos, elevó las capacidades predictivas del modelo. Este paso, combinado con la incorporación de las red flags, permite obtener una precisión del 86.1%, considerando ambas clases de etiquetas en la clasificación. Esto consolida la herramienta como un instrumento poderoso para prever y, por ende, mitigar de manera proactiva los riesgos de protestas en las contrataciones públicas.

Además, otro gran aporte de este trabajo es el conjunto de datos estructurado y unificado, un repositorio preparado para análisis futuros. El esfuerzo invertido en aplanar las columnas y estructurar el conjunto de datos mejora su usabilidad para investigaciones posteriores. Este conjunto de datos rico en recursos permite a futuros investigadores explorar el contexto de la contratación pública y el análisis de riesgos abriendo la posibilidad a interesantes trabajos futuros.

El primer objetivo específico fue desarrollado y completado, los detalles de cómo se generó el dataset y las propiedades del mismo se encuentran en el capítulo 4, usando el API de la DNCP, se generó el conjunto de datos que luego de varias transformaciones y adaptaciones llegó a un punto donde puede ser utilizado en trabajos similares a este o ser fuente de análisis más complejos y profundos de las contrataciones públicas del país.

El segundo objetivo específico de entrenar y trabajar con los modelos predictivos está explicado en la parte final del capítulo 4, usando el dataset generado en combinación con herramientas de Machine Learning, se generaron varios modelos capaces de predecir las protestas con un nivel bastante alto de precisión.

El tercer y último objetivo específico fue el de generar el score de riesgo usando el modelo más óptimo en combinación con las red flags, también se cumplió y se detallo en el final del capítulo 4 con el modelo mejor performante que para este trabajo fue un Stacked Ensemble de varios modelos. Esto también se plasmó en el API desarrollado, esta API genera el score usando el modelo, y los datos de la DNCP.

6.1 Posibles trabajos futuros

El presente trabajo de investigación ha explorado diversos aspectos de las contrataciones públicas, el estándar OCDS, el uso de técnicas de aprendizaje automático, y las protestas en contrataciones públicas en Paraguay, como toda investigación, esto abre nuevas líneas de estudio y desarrollo que podrían ampliar y mejorar las aplicaciones prácticas de los resultados obtenidos. En esta sección, se presentan varias de estas líneas para futuros trabajos, yendo desde cambios en el enfoque del problema, y de los modelos propuestos y probados, hasta el refinamiento o reentrenamiento de los modelos aquí mencionados.

Uno de los caminos posibles es la exploración y prueba de otros algoritmos o metodologías para generar el score de predicción de protestas. Este enfoque podría incluir la aplicación de otras técnicas de aprendizaje automático, para mejorar la capacidad de identificar patrones complejos en los datos y predecir con mayor precisión posibles protestas o anomalías en los procesos de contratación. Si bien este trabajo ya ha utilizado y estudiado varios algoritmos como los árboles de decisión, regresión logística, máquinas de soporte vectorial (SVM), Random Forest o Gradient Boosting, existen técnicas de aprendizaje distintas que podrían ser investigadas y puestas a prueba. Estas técnicas podrían ofrecer una capacidad distinta para capturar relaciones complejas entre las variables de los procesos de contratación y las protestas, quizás llegando a conclusiones distintas y a otro tipo de modelo predictivo o score.

Se puede plantear totalmente otro enfoque para ver el problema de detección de protestas, de una forma que use técnicas de aprendizaje semi-supervisado, o no supervisado, recordar que en este trabajo se decidió considerar el problema como uno de clasificación donde se plantearon dos grupos bien definidos: los procesos de contratación pública con protestas y los que no fueron protestados. Además de explorar nuevos algoritmos, también sería beneficioso investigar la integración de características adicionales. Por ejemplo, incorporar datos temporales secuenciales correspondientes a las instituciones que convocan al proceso, o a los proveedores que ofrecen el bien o servicio, o inclusive a los precios y tipos de los ítems solicitados. Capturar la evolución de los patrones de protestas y las características de los procesos de contratación pública a lo largo del tiempo podría proporcionar una visión más dinámica y precisa del riesgo.

Otro camino para continuar el trabajo, es la aplicación de técnicas de preprocesamiento de datos más sofisticadas, como técnicas de embedding o el manejo de los datos desbalanceados mediante métodos de remuestreo más avanzados. En este trabajo solo se han abordado algunas de las técnicas para el remuestreo de los datos como lo son el sampling aleatorio y el SMOTE, otras técnicas podrían mejorar la cantidad y calidad de datos de entrenamiento para el modelo. También podría abordarse la experimentación con diferentes configuraciones de hiper parámetros en el modelo seleccionado o en los otros modelos que también fueron entrenados y probados pero no seleccionados. Otro punto clave son las técnicas usadas para “aplanar los datos”, en el trabajo se usaron técnicas como el one hot encoding, y la transformación en cuantiles de variables, pero aquí podrían explorarse otro tipo de técnicas para que el modelo reciba mayor información en el entrenamiento.

Además de ajustar los parámetros del modelo, se podría evaluar su rendimiento en diferentes subconjuntos de datos y validar su robustez frente a cambios en las condiciones del mercado o políticas gubernamentales. Esto podría implicar la creación de escenarios simulados o la aplicación de pruebas de sensibilidad para determinar cómo factores externos afectan la capacidad predictiva del modelo a lo largo del tiempo, también podrían ser sujetos de estudio, subconjuntos de datos que representen un periodo de tiempo corto, como por ejemplo, temporadas de elecciones, fin o inicio de mandato, quizás hacer un análisis más detallado de los tiempos de pandemia u otros periodos de tiempo relevantes.

El refinamiento del modelo presentado, también es un punto interesante que puede disparar otro estudio, esto podría darse usando un reentrenamiento periodico, cada vez que hayan datos nuevos, para mejorar el rendimiento del modelo y exponerlo a nuevos patrones que puedan surgir en la posterioridad, también con las modificaciones adecuadas se podría incluir datos como el feedback humano de alguna persona encargada de examinar los procesos de contratación pública.

Otro frente de investigación sugerido es el desarrollo de herramientas de monitoreo en tiempo real que utilicen datos de contrataciones públicas para detectar anomalías y riesgos de protestas de manera anticipada. Este avance podría transformar la gestión de riesgos en contrataciones públicas al permitir intervenciones proactivas y una respuesta más ágil a posibles irregularidades, asegurando así la transparencia y eficiencia en el uso de recursos públicos. Esta herramienta podría integrarse con sistemas existentes de gestión y monitoreo gubernamentales, facilitando una supervisión continua y mejorando la capacidad de planificación estratégica de las entidades involucradas.

Una de las principales ventajas de esta herramienta sería su capacidad para alertar de manera proactiva a los responsables de la toma de decisiones sobre áreas de alto riesgo, permitiendo intervenciones preventivas y mitigación de riesgos antes de que las protestas afecten negativamente los cronogramas de entrega o los presupuestos asignados. Esto podría incluir la implementación de alertas automáticas, paneles de visualización interactivos y reportes analíticos que faciliten una supervisión efectiva y en tiempo real de los procesos de contratación pública.

Los datos usados en el modelo y análisis también se pueden integrar con otros datos de diversos tipos, en este mismo trabajo se propuso la integración de los datos de procesos de contrataciones públicas y protestas con red-flags, este mismo proceso puede ser aplicado usando otros datasets que aporten información relevante para análisis o para entrenamiento de nuevos y mejores modelos de Machine Learning.

Además de la detección de protestas, estas herramientas podrían ser diseñadas para analizar tendencias históricas y proyectar escenarios futuros, ayudando así a las entidades gubernamentales a planificar de manera más efectiva sus recursos y estrategias de contratación. Por ejemplo, la integración con sistemas de gestión de recursos humanos y financieros podría permitir una gestión integrada de riesgos y recursos en tiempo real, mejorando la eficiencia operativa y la transparencia en el uso de fondos públicos.

6.2 Publicación Científica

El contenido desarrollado en este libro, fue propuesto y aceptado en formato de Full Research Paper en el Congreso Internacional Multiconferencia sobre Complejidad, Informática y Cibernética Nro 15 - International Multi-Conference on Complexity, Informatics and Cybernetics (IMCIC 2024). Celebrado en Marzo del 2024.

El Paper relacionado está titulado “Quantifying the Risk of Complaints In Public Procurement tenders in Paraguay using Machine Learning”.

El libro en el que se encuentra publicado el paper puede accederse desde la url correspondiente²⁵.

²⁵ <https://www.iiis.org/CDs2024/CD2024Spring/bookZ1.htm>

Bibliografía

Chapman, P., J, C., & R, K. (1999). The CRISP-DM user guide. *4th CRISP-DM SIG*

Workshop in Brussels in March, 1999(4), sn. scholar.

Comparativa de técnicas de balanceo de datos, C. d. t. d. b. d. d. (2021, Mayo).

Comparativa de técnicas de balanceo de datos. *Universidad de Oviedo*, 1(1), 1.

Congreso de la Nación de Paraguay. (2008, 01 10). *Ley N° 3439 / MODIFICA LA LEY N°*

2.051/03 “DE CONTRATACIONES PÚBLICAS” Y ESTABLECE LA CARTA

ORGÁNICA DE LA DIRECCIÓN NACIONAL DE CONTRATACIONES PÚBLICAS”.

[Ley N° 3439 / MODIFICA LA LEY N° 2.051/03 “DE CONTRATACIONES PÚBLICAS”

Y ESTABLECE LA CARTA ORGÁNICA DE LA DIRECCIÓN NACIONAL DE

CONTRATACIONES PÚBLICAS”]. *Ley N° 3439 / MODIFICA LA LEY N° 2.051/03*

“DE CONTRATACIONES PÚBLICAS” Y ESTABLECE LA CARTA ORGÁNICA DE LA

DIRECCIÓN NACIONAL DE CONTRATACIONES PÚBLICAS”. Retrieved Mayo 08,

2024, from

<https://www.bacn.gov.py/leyes-paraguayas/9271/ley-n-3439-modifica-la-ley-n-205103>

[-de-contrataciones-publicas-y-establece-la-carta-organica-de-la-direccion-nacional-d](https://www.bacn.gov.py/leyes-paraguayas/9271/ley-n-3439-modifica-la-ley-n-205103)

[e-contrataciones-publicas](https://www.bacn.gov.py/leyes-paraguayas/9271/ley-n-3439-modifica-la-ley-n-205103)

Congreso de la Nación de Paraguay. (2012, August 24). *Ley N° 2051 / DE*

CONTRATACIONES PÚBLICAS. Biblioteca y Archivo del Congreso Nacional.

Retrieved May 8, 2024, from

[https://www.bacn.gov.py/leyes-paraguayas/159/ley-n-2051-de-contrataciones-publica](https://www.bacn.gov.py/leyes-paraguayas/159/ley-n-2051-de-contrataciones-publicas)

[s](https://www.bacn.gov.py/leyes-paraguayas/159/ley-n-2051-de-contrataciones-publicas)

Data Flattening and Data Unflattening. (n.d.). Firebolt. Retrieved May 12, 2024, from

<https://www.firebolt.io/glossary-items/data-flattening-and-data-unflattening>

DNCP. (2023, Agosto 14). *DNCP destaca la evolución de su sistema con un informe de*

gestión de los últimos años. DNCP. Retrieved May 9, 2024, from

<https://www.contrataciones.gov.py/noticias/478.html>

- Encina Perez, A. (2023, 12 21). Revista de compras. *Revista de compras públicas*, 2(2023), 10. <https://revista.dncp.edu.py/rcp>
- Fazekas, M., Cingolani, L., & Tóth, B. (2016, 08 01). A Comprehensive Review of Objective Corruption Proxies in Public Procurement: Risky Actors, Transactions, and Vehicles of Rent Extraction. *SSRN (Social Science Research Network)*.
<http://dx.doi.org/10.2139/ssrn.2891017>
- Fazekas, M., János, T., & King, L. (2016, 09). n Objective Corruption Risk Index Using Public Procurement Data. European Journal on Criminal Policy and Research. *European Journal on Criminal Policy and Research*, 22. 10.1007/s10610-016-9308-z
- Fazekas, M., & Kocsis, G. (2017, 08 11). Uncovering high-level corruption: Cross-national objective corruption risk indicators using public procurement data. *British Journal of Political Science*. 10.17863/CAM.12545
- Fernandez, A., Garcia, S., Herrera, F., & Chawla, N. V. (2018, 04 1). SMOTE for learning from imbalanced data: progress and challenges, marking the 15-year anniversary. *Journal of Artificial Intelligence Research*, 61(1), 863–905.
<https://dl.acm.org/doi/10.5555/3241691.3241712>
- García Abad, J. (2021, 05 27). *Comparativa de técnicas de balanceo de datos. Aplicación a un caso real para la predicción de fuga de clientes*. Repositorio Institucional de la Universidad de Oviedo. Retrieved 05 12, 2024, from
<https://digibuo.uniovi.es/dspace/handle/10651/60629>
- Generalized Linear Model (GLM) — H2O 3.46.0.1 documentation*. (n.d.). H2O.ai Documentation. Retrieved May 12, 2024, from
<https://docs.h2o.ai/h2o/latest-stable/h2o-docs/data-science/glm.html>
- Gobierno del Paraguay. (2022, Marzo 21). *Ley 7021/2022*. Ley 7021/2022. Retrieved Mayo 8, 2024, from
<https://www.contrataciones.gov.py/dncp/ley-7021/ley-7021-de-suministro-y-contrataciones-publicas/>

- Goldstein, M., & Uchida, S. (2016, 04 19). A Comparative Evaluation of Unsupervised Anomaly Detection Algorithms for Multivariate Data. *PLoS ONE*, 11(4).
<https://doi.org/10.1371/journal.pone.0152173>
- Grid (Hyperparameter) Search — H2O 3.42.0.1 documentation.* (n.d.). H2O.ai Documentation. Retrieved May 12, 2024, from
<https://docs.h2o.ai/h2o/latest-stable/h2o-docs/grid-search.html>
- H2O AutoML: Automatic Machine Learning — H2O 3.42.0.1 documentation.* (n.d.). H2O.ai Documentation. Retrieved May 12, 2024, from
<https://docs.h2o.ai/h2o/latest-stable/h2o-docs/automl.html>
- Kehler Niessen, M. E. (2020, 04 01). Anomaly Detection in Public Procurements using the Open Contracting Data Standard. *2020 Seventh International Conference on eDemocracy & eGovernment (ICEDEG)*, 127-134.
 10.1109/ICEDEG48599.2020.9096674
- LeDell, E., & Poirier, S. (2020, Julio). H2O AutoML: Scalable Automatic Machine Learning. *7th ICML Workshop on Automated Machine Learning*.
https://www.automl.org/wp-content/uploads/2020/07/AutoML_2020_paper_61.pdf
- López-Iturriaga, F. J., & Pastor-Sanz, I. (2018, 12 01). Predicting Public Corruption with Neural Networks: An Analysis of Spanish Provinces. *Social Indicators Research*, 140(3), 975-998. 10.1007/s11205-017-1802-2
- Mora, E., & Rivas, M. (2022). *Red Flags Detection in Public Procurements using a Business Rules Management System*.
- Ovsyannikova, A., & Domashova, J. (2020). Identification of public procurement contracts with a high risk of non-performance based on neural networks. *Procedia Computer Science*, 169, 795-799. <https://doi.org/10.1016/j.procs.2020.02.161>.
- Rabuzin, K., & Modrušan, N. (2019, 09 18). Prediction of Public Procurement Corruption Indices using Machine Learning Methods. *Proceedings of the 11th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge*

Management, 3(IC3K 2019), 333-340.

<https://pdfs.semanticscholar.org/66f7/89dc355dbc1728b33a90f3ea0d8d28d0fae1.pdf>

Release Schema — Open Contracting Data Standard 1.1.5 documentation. (n.d.). Open

Contracting Data Standard. Retrieved May 12, 2024, from

<https://standard.open-contracting.org/latest/en/schema/release/>

Schaffer, C. (1993, Octobre 1). Selecting a classification method by cross-validation.

Machine Learning, 13(1), 135-143. <https://doi.org/10.1007/BF00993106>

Stacked Ensembles — H2O 3.42.0.1 documentation. (n.d.). H2O.ai Documentation.

Retrieved May 12, 2024, from

<https://docs.h2o.ai/h2o/latest-stable/h2o-docs/data-science/stacked-ensembles.html>