

**UNIVERSIDAD NACIONAL DE ASUNCION
FACULTAD POLITECNICA
INGENIERÍA EN INFORMATICA**



**DESARROLLO DE UNA ESTRATEGIA DE
FUSION DE DATOS FTIR Y RAMAN PARA EL
ANALISIS MULTIVARIADO DE MUESTRAS**

Trabajo Final de Grado

Autor:

Alumno Nombre

Orientadores

Dr. Julio César Mello Román

Dr. Edher Zacarias Herrera

San Lorenzo - Paraguay

Mes - 2026

UNIVERSIDAD NACIONAL DE ASUNCION
FACULTAD POLITECNICA
INGENIERÍA EN INFORMATICA



**DESARROLLO DE UNA ESTRATEGIA DE
FUSION DE DATOS FTIR Y RAMAN PARA EL
ANALISIS MULTIVARIADO DE MUESTRAS**

Alumno Nombre

Orientadores: Dr. Julio César Mello Román
Dr. Edher Zacarias Herrera

Proyecto de Trabajo de Grado presentado en conformidad a los requisitos
para obtener el grado de Ingeniería en Informática

San Lorenzo - Paraguay
Mes - 2026

Dedicatoria

Agradecimientos

Resumen

Este trabajo presenta el desarrollo de una herramienta computacional denominada EspectroApp, diseñada para el procesamiento, análisis y fusión de datos espectroscópicos provenientes de técnicas FTIR y Raman, aplicadas a muestras farmacéuticas. Se implementaron algoritmos de preprocesamiento, tales como normalización, suavizado y cálculo de derivadas, así como métodos de reducción de dimensionalidad como el Análisis de Componentes Principales (PCA) y t-Distributed Stochastic Neighbor Embedding (t-SNE), además de técnicas de agrupamiento mediante Análisis de Clúster Jerárquico (HCA), integrando todas estas etapas en una interfaz gráfica interactiva.

El enfoque principal del trabajo consistió en la aplicación de la fusión de datos a nivel bajo, combinando las intensidades espectrales de FTIR y Raman para evaluar su impacto en la discriminación entre muestras. Los resultados experimentales demostraron que la fusión de datos, acompañada de un preprocesamiento adecuado, mejora significativamente la capacidad de clasificación, alcanzando un alto porcentaje de asertividad en los modelos multivariados.

Se concluye que la integración de ambas técnicas espectroscópicas permite aprovechar su complementariedad vibracional, optimizando la identificación de compuestos y la detección de posibles adulteraciones. En este contexto, EspectroApp se presenta como una herramienta accesible, robusta y eficaz para el análisis multivariado de datos espectroscópicos.

Abstract

This work presents the development of a computational tool called EspectroApp, designed for the processing, analysis, and fusion of spectroscopic data obtained from FTIR and Raman techniques applied to pharmaceutical samples. Data preprocessing algorithms such as normalization, smoothing, and derivative calculation were implemented, along with dimensionality reduction methods including Principal Component Analysis (PCA) and t-Distributed Stochastic Neighbor Embedding (t-SNE), as well as clustering techniques based on Hierarchical Cluster Analysis (HCA). All stages were integrated into an interactive graphical user interface.

The main focus of this study was the application of low-level data fusion, combining FTIR and Raman spectral intensities to evaluate its impact on sample discrimination. Experimental results demonstrated that data fusion, when combined with appropriate preprocessing, significantly enhances classification performance, achieving a high accuracy rate in multivariate models.

It is concluded that the integration of both spectroscopic techniques allows the exploitation of their vibrational complementarity, improving compound identification and the detection of potential adulterations. In this context, EspectroApp is presented as an accessible, robust, and effective tool for the multivariate analysis of spectroscopic data.

Indice general

Indice de cuadros o Apendice[ver si necesito]

Indice de figuras [ver si necesito]

Lista de tablas [ver si necesito]

Lista de simbolos [ver si necesito]

Acrónimos

FACEN Facultad de Ciencias Exactas y Naturales

DF Data Fusion

FTIR Fourier Transform Infrared Spectroscopy

HCA Hierarchical Cluster Analysis

LLF Low-Level Fusion

PCA Analisis de Componentes principales

PLS Partial Least Squares Regression(Regresión por Mínimos Cuadrados Parciales)

PLS-DA Partial Least Squares Discriminant Analysis(Análisis Discriminante por Mínimos Cuadrados Parciales)

FTIR Infrarrojo por Transformada de Fourier

SG Savitzky–Golay

t-SNE t-Distributed Stochastic Neighbor Embedding

Capítulo 1

1. Introducción

1.1. Objetivos del trabajo

1.1.1. Objetivo general

Desarrollar una herramienta software capaz de realizar el procesamiento, análisis y fusión de datos espectroscópicos provenientes de técnicas FTIR y Raman, empleando métodos multivariantes para mejorar la discriminación y caracterización de muestras en un entorno computacional accesible y eficiente.

1.1.2. Objetivos específicos

VER CUALES DEJAR

- Diseñar e implementar una aplicación interactiva (*EspectroApp*) que permita cargar, visualizar y procesar datos espectrales de FTIR y Raman.
- Integrar en la aplicación técnicas de preprocesamiento tales como: normalización, corrección de línea base, suavizado Savitzky–Golay y derivadas de primer y segundo orden.
- Aplicar métodos de análisis multivariante, incluyendo PCA, t-SNE y HCA, para explorar la estructura interna de los datos y evaluar la separación entre clases.
- Desarrollar e implementar estrategias de fusión de datos (Data Fusion), específicamente Low-Level Fusion, para combinar matrices FTIR y Raman en un único espacio de información.
- Evaluar el desempeño de los modelos analíticos generados a partir de FTIR, Raman y su fusión, comparando la precisión y la capacidad discriminante antes y después del preprocesamiento.
- Proveer una interfaz gráfica intuitiva que facilite el uso de técnicas computacionales avanzadas a usuarios sin experiencia programática.
- Validar la utilidad de la herramienta mediante pruebas con datos reales, demostrando su aplicabilidad en análisis espectroscópico y clasificación de muestras.

2. Justificación

En la actualidad, el análisis de datos provenientes de equipos científicos genera grandes volúmenes de información que requieren herramientas informáticas capaces de procesarlos, integrarlos y visualizarlos de manera eficiente. En este contexto, las técnicas de espectroscopía FTIR y Raman son ampliamente utilizadas en laboratorios industriales, farmacéuticos y de investigación debido a su capacidad para proporcionar información vibracional de alta resolución. Sin embargo, cada una de estas técnicas genera datos con características propias, diferentes niveles de ruido, escalas distintas y patrones espectrales específicos, lo que exige un tratamiento computacional especializado.

A pesar del uso extendido de estas técnicas, existe una carencia de herramientas informáticas accesibles, integradas y orientadas al usuario que permitan realizar un análisis completo de los datos espectrales, incluyendo etapas de preprocesamiento, reducción de dimensionalidad, clasificación, visualización y fusión de datos. Los softwares disponibles suelen ser costosos, poco intuitivos o carecen de módulos específicos para el análisis multivariante y la fusión de datos, lo que limita la adopción de metodologías avanzadas tanto en entornos académicos como productivos.

En este sentido, el presente trabajo se justifica en la necesidad de desarrollar una herramienta computacional que permita procesar, analizar y combinar datos espectrales de manera eficiente desde un enfoque informático. La implementación de EspectroApp constituye un aporte concreto al integrar, en una única plataforma, funciones de preprocesamiento como corrección de línea base, suavizado, normalización y cálculo de derivadas, junto con algoritmos multivariantes como PCA, t-SNE y HCA, además de estrategias de fusión de datos FTIR y Raman. De este modo, se propone una solución tecnológica funcional, accesible y de utilidad para profesionales e investigadores que trabajan con análisis espectroscópico.

Capítulo 2

Marco Teorico

3. Fusión de datos

La fusión de datos consiste en integrar información proveniente de diferentes fuentes con el fin de mejorar la exactitud y confiabilidad de los modelos predictivos. Cada método espectral aporta una capacidad de medición particular y, al combinarse, se obtiene una visión composicional más amplia que la que se alcanzaría aplicando cada técnica de manera independiente. Estas estrategias han encontrado también aplicaciones destacadas en áreas como la teledetección y la bioinformática.[1]

Las estrategias de fusión de datos abarcan un espectro amplio de enfoques, tanto en complejidad como en la manera de integrar la información. El reto central es elegir un método capaz de armonizar datos heterogéneos procedentes de sistemas complejos. Un caso frecuente es la integración de señales de distintos instrumentos en particular en espectroscopía, que puede incrementar el ruido en las etapas de posprocesado. La técnica adecuada suele ser dependiente del problema y del tipo de datos, por lo que no existe una receta única. En la práctica, es común comparar de forma experimental varias alternativas de fusión y contrastarlas con los resultados obtenidos por cada fuente por separado, a fin de identificar el enfoque más conveniente para la construcción del modelo.

Las técnicas de fusión de datos se agrupan en tres niveles: bajo, medio y alto. Una representación esquemática de estas tres modalidades se muestra en la Figura 1.[2]




Figura 1: Resumen gráfico de los tres tipos de fusión de datos.

Fuente: <https://doi.org/10.3389/fnut.2022.1074688>, adaptado por los autores, 2026.

3.1. Fusión de nivel bajo

Consiste en unir, por simple concatenación, los datos crudos de cada fuente para formar una única matriz sobre la que se entrena el modelo. Es el enfoque más directo, pues no exige extracción de rasgos ni reducción dimensional previa. No obstante, requiere escalar los bloques para igualar sus varianzas. Además, el tamaño resultante puede ser muy grande y arrastrar información redundante o altamente correlacionada, lo que limita la eficacia de la fusión de nivel bajo.[3]

Debido a sus características de gran tamaño muestral, ineficiencia computacional e incapacidad para realizar fusión directa de datos con diferentes magnitudes, la fusión de nivel bajo está sujeta a preprocesamiento y cribado de variables, lo que generalmente requiere preprocesar los datos como normalización, reducción de ruido y eliminación de variables redundantes antes de la fusión.

La fusión de nivel bajo es más fácil de operar que la de nivel medio y alto y puede obtener información integral. Es simple de operar, tiene alta exactitud de detección y es adecuada para muestras con poca cantidad de información de datos; por ejemplo, la fusión de nivel bajo puede reconocer mejor diferentes tipos de jugos de frutas, identificar la autenticidad del aceite de oliva, así como la trazabilidad del origen[4].

3.2. Fusion de nivel medio

En este enfoque, primero se comprime cada bloque de datos para extraer rasgos representativos y, recién entonces, se integran para el modelado final. Habitualmente, las proyecciones reducidas se obtienen como componentes principales (PCA). La extracción de características se utiliza principalmente en la fusión de nivel medio. Esto implica tomar características de diferentes conjuntos de datos y tratarlas de manera equivalente. Las características extraídas se concatenan en un único vector que alimenta después un clasificador o un regresor. Frente a la fusión de nivel bajo, ofrece ventajas claras: filtra información irrelevante mediante reducción dimensional y, con técnicas de selección de variables, conserva solo lo más informativo de cada conjunto, disminuyendo ruido y redundancias. Como efecto adicional, el menor número de variables reduce de forma notable el costo computacional del análisis.

Debe considerarse la información de características de la fusión de nivel medio cuando se trabaja con información de alta complejidad para reducir variables y acortar el tiempo de cálculo. La técnica de fusión de nivel medio también se utiliza comúnmente en la evaluación de calidad y trazabilidad de origen de productos alimentarios, donde se fusionan datos de espectroscopia y espectrometría de masas para el análisis[4].

3.3. Fusion de nivel alto

La fusión a nivel de decisión entrena un modelo por cada fuente y, posteriormente, integra sus salidas para obtener una única predicción de consenso. En muchos casos supera a los esquemas de nivel bajo y medio, al atenuar información irrelevante sin descartar señales útiles. En general, tanto la fusión de nivel medio como la de nivel alto tienden a ofrecer mejores resultados de clasificación que los modelos derivados de cada conjunto de datos por separado.[5]

La construcción de la fusión de nivel alto es más complicada, pero su beneficio radica en el tratamiento separado de bloques de datos, lo que reduce la interferencia mutua entre diferentes modelos. Las estrategias de fusión de nivel alto pueden resolver el problema de baja exactitud de la fusión de nivel bajo y medio y son adecuadas para escenarios de análisis que requieren mayor exactitud. Se utilizan comúnmente para resolver problemas de clasificación, como la clasificación de imágenes hiperespectrales, la clasificación de hongos silvestres y cultivados, y la clasificación de variedades de vino.

La fusión de datos permite integrar información procedente de distintas fuentes, con el objetivo de generar resultados más robustos y completos. Diversos estudios en diferentes áreas han mostrado que los modelos basados en estrategias de fusión alcanzan niveles superiores de exactitud y aplicabilidad en comparación con aquellos desarrollados a partir de una sola fuente de información[6].

En este trabajo también se consideran algunas de las principales ventajas y desventajas de cada enfoque de fusión de datos. A continuación, en la Tabla 1, se resumen comparativamente estos aspectos para los niveles bajo, medio y alto.

Tabla 1: Comparativo de fusión de datos por niveles, ventajas y desventajas.

Nivel	Ventajas	Desventajas
Bajo	Implementación sencilla; puede aplicarse PCA/PLS/PLS-DA u otros métodos estándar; mantiene toda la señal disponible de cada plataforma.	Alta dimensionalidad (muchas variables y pocas muestras), lo que aumenta el riesgo de sobreajuste; Una técnica puede dominar a la otra por diferencias de escala o varianza.
Medio	Reduce la cantidad de variables, generando modelos más estables; Minimiza problemas de escalado entre FTIR y Raman; Facilita la interpretación porque usa solo características relevantes de cada técnica.	Riesgo de perder información útil al reducir/seleccionar; puede necesitar estrategias de “reciclaje” para recuperar componentes residuales correlacionadas entre bloques.
Alto	Útil para predicción; no sufre problemas de escalado; permite modelos independientes por técnica.	Menor interpretabilidad; la mejora puede ser limitada en comparación con fusiones low/mid-level.

Fuente: Elaborado por los autores, 2026.

4. Preprocesamiento

El preprocesamiento de datos brutos elimina ruido o señales no deseadas, mejora la precisión de los análisis espectrales, facilita la interpretación de los datos y aumenta la información significativa[7]. Un preprocesamiento mal aplicado puede afectar los resultados de clasificación, por eso cada conjunto de datos tendrá una manera específica de realizar el preprocesamiento para obtener los mejores resultados posibles, algunas formas de preprocesamiento son:

4.1. Normalización

La normalización es esencial porque reduce estas variaciones físicas y hace que los espectros sean comparables en escala e intensidad, permitiendo que los algoritmos multivariantes como PCA trabajen sobre diferencias químicas reales[8], algunas de las formas de normalización puede ser:

4.1.1. Normalización Media

- Cada espectro se centra y escala individualmente, restando su media y dividiendo por su desviación estándar:

$$x' = \frac{x - \bar{x}}{s_x} \quad (1)$$

- Corrige tanto desplazamientos de línea base como diferencias de escala.
- Muy útil cuando los espectros presentan dispersión o diferencias de espesor.

4.1.2. Normalización Area

La normalización por área consiste en ajustar la escala de un espectro de modo que su área total (suma de intensidades) sea igual a 1 o a un valor constante.

En forma matemática general:

$$x'_i = \frac{x_i}{\sum_{i=1}^n x_i} \quad (2)$$

donde:

- $x_i \rightarrow$ intensidad original en el punto i del espectro.
- $\sum x_i \rightarrow$ área total bajo la curva (suma de todas las intensidades).
- $x'_i \rightarrow$ valor normalizado de la intensidad.

Dentro del conjunto de técnicas conocidas como scatter correction, la normalización tiene como objetivo reducir la variabilidad física asociada a factores como la dispersión de la luz, el grosor de la muestra, la concentración o la potencia de la fuente. Estos factores afectan la magnitud absoluta de las señales y pueden introducir variaciones que no tienen origen químico[8].

En palabras simples:

- Si dos espectros tienen la misma forma pero diferente intensidad global, la normalización por área los ajusta para que ambos tengan igual contribución total (área = 1), eliminando diferencias que no son químicas.
- Esto preserva las relaciones relativas entre bandas (la forma del espectro), que sí reflejan la composición molecular.

4.2. Suavizado

4.2.1. Savitzky–Golay

El método de Savitzky–Golay es uno de los procedimientos de suavizado más utilizados en el procesamiento de datos espectroscópicos, especialmente en espectros FTIR y Raman, debido a su capacidad para reducir el ruido aleatorio sin distorsionar significativamente la forma de las bandas espectrales. A diferencia de los métodos de suavizado más simples como la media móvil que reemplazan cada punto por el promedio de sus vecinos, el filtro de Savitzky–Golay se basa en un ajuste polinómico local dentro de una ventana móvil de

tamaño definido por el usuario. En cada ventana se ajusta un polinomio de bajo orden (p. ej., 2 o 3) a los valores experimentales mediante el método de mínimos cuadrados, y el valor suavizado se obtiene evaluando el polinomio en el punto central de la ventana. Este procedimiento se repite a lo largo de todo el espectro, desplazando la ventana punto por punto.

La función de suavizado puede representarse de manera general como:

$$y'_i = \sum_{j=-m}^m c_j y_{i+j} \quad (3)$$

donde y_i representa los valores originales del espectro, y'_i los valores suavizados, m la mitad del tamaño de la ventana y c_j los coeficientes calculados mediante el ajuste por mínimos cuadrados[9].

4.2.2. Media móvil

El objetivo del suavizado por media móvil es reducir el ruido aleatorio de los espectros sin alterar de forma significativa la forma general de las bandas o picos. Es una técnica muy usada en espectros FTIR y Raman, especialmente cuando se requiere un filtrado rápido y sin parámetros complejos[10]. En su forma más simple, el suavizado consiste en aplicar una media móvil no ponderada, donde el valor de absorbancia en un punto del espectro se reemplaza por el promedio de las absorbancias vecinas dentro de una ventana de tamaño $N + 1$.

$$y'_i = \frac{1}{N + 1} \sum_{j=-\frac{N}{2}}^{\frac{N}{2}} y_{i+j}, \quad (4)$$

donde y_i representa los valores originales del espectro, y'_i los valores suavizados y N corresponde al número de puntos vecinos considerados a cada lado del punto central[11].

Esto significa que:

- Cada punto suavizado es la media entre el valor central y sus $N/2$ vecinos anteriores y $N/2$ vecinos posteriores.
- Se suele usar un número impar de puntos ($N + 1$) para que exista un punto central simétrico.
- En los extremos del espectro, donde no existen suficientes vecinos, se reflejan los valores de los bordes para evitar discontinuidades en el resultado.

4.2.3. Filtro gaussiano

El filtro gaussiano es una técnica de suavizado que utiliza la distribución normal de Gauss como función de ponderación para reducir el ruido en señales espectroscópicas. A diferencia del media móvil que asigna el mismo peso a todos los puntos dentro de la ventana o del filtro Savitzky–Golay que ajusta un polinomio por mínimos cuadrados, el filtro gaussiano asigna pesos decrecientes conforme aumenta la distancia al punto central, lo que produce un suavizado más natural y menos propenso a distorsionar picos[11].

El principio del filtro se basa en la convolución del espectro $x(i)$ con una función gaussiana $G(j)$:

$$x'(i) = \sum_{j=-m}^m x(i-j) G(j) \quad (5)$$

donde la función de ponderación gaussiana se define como:

$$G(j) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{j^2}{2\sigma^2}} \quad (6)$$

- $x(i)$: intensidad espectral en el punto i .
- $x'(i)$: intensidad suavizada.
- σ : desviación estándar que controla el grado de suavizado.
- m : número de puntos considerados alrededor del punto central.

Cuanto mayor sea σ , más amplia será la ventana efectiva del filtro y más pronunciado será el efecto de suavizado.

4.3. Derivadas


Las derivadas espectrales (primera y segunda derivada) son ampliamente empleadas en el preprocesamiento de espectros Raman y FTIR debido a su capacidad para eliminar líneas base, compensar efectos de dispersión y resaltar diferencias químicas sutiles entre bandas superpuestas. Las derivadas forman parte del conjunto fundamental de técnicas de preprocesamiento, ya que transforman la intensidad absoluta del espectro en información relacionada con los cambios en su pendiente (primera derivada) o en su curvatura (segunda derivada)[9].

Para obtener derivadas robustas y suavizadas es común emplear el método de Savitzky–Golay, el cual ajusta polinomios locales dentro de una ventana móvil, permitiendo calcular derivadas sin distorsionar significativamente la forma espectral. En espectros FTIR y Raman, estas transformaciones han demostrado ser especialmente útiles para mejorar la resolución de señales, distinguir bandas solapadas y reducir artefactos instrumentales[12].

Como referencia, la aproximación numérica discreta más utilizada para estimar la primera derivada sin suavizado corresponde al esquema de diferencias centradas, expresado como:

$$X'_k = \frac{X_{k+1} - X_{k-1}}{2 \Delta x}, \quad (7)$$

donde k representa el índice asociado a la longitud de onda o número de onda, Δx es el espaciamiento entre puntos espectrales y X_k es la intensidad en el punto k . Este método proporciona una estimación más estable y precisa que la diferencia hacia adelante, aunque en aplicaciones espectroscópicas suele preferirse Savitzky–Golay debido a su capacidad de suavizar y derivar simultáneamente.



(A) Espectro original (B) Espectro de segunda derivada

Fuente: Kong, J., & Yu, S. (2007). Fourier transform infrared spectroscopic analysis of protein secondary structures. *Acta Biochimica et Biophysica Sinica*, 39(8), 549–559.

La segunda derivada proporciona beneficios adicionales con respecto a la primera, especialmente cuando existe un fuerte solapamiento de bandas o una línea base compleja.

Mientras que la primera derivada resalta los cambios en la pendiente, la segunda derivada permite:

- Identificar con mayor claridad la posición de bandas ocultas.
- Separar componentes espectrales superpuestos, mejorando la resolución.
- Reducir la influencia de variaciones lentas de la línea base.
- Facilitar el ajuste de picos en regiones altamente congestionadas.

Estas ventajas hacen que la segunda derivada sea una herramienta esencial en el análisis cualitativo y cuantitativo de espectros vibracionales complejos.

1. **Corrección más eficaz de la línea base.** Mientras que la primera derivada elimina únicamente tendencias lineales del fondo, la segunda derivada corrige también componentes curvilíneas, como efectos parabólicos o variaciones debidas a dispersión no lineal. Esto resulta particularmente útil en espectros Raman afectados por fluorescencia.
2. **Mayor resolución de bandas solapadas.** La segunda derivada introduce máximos y mínimos bien definidos alrededor de las bandas, lo que permite separar picos superpuestos y resaltar señales ocultas bajo bandas de mayor intensidad. En consecuencia, mejora la selectividad química del espectro.
3. **Menor sensibilidad a cambios de intensidad global.** La segunda derivada reduce de forma más efectiva las diferencias puramente escalares entre muestras, preservando la forma relativa de las bandas y favoreciendo comparaciones más robustas entre espectros.
4. **Mayor sensibilidad a cambios locales en la curvatura.** Debido a que la segunda derivada evalúa la variación de la pendiente, es especialmente eficaz para resaltar inflexiones y bordes espectrales, lo cual permite identificar contribuciones sutiles que la primera derivada no distingue claramente.
5. **Mejor desempeño en análisis multivariante y fusión de datos.** Al reducir tanto la línea base como la escala absoluta de los espectros, la segunda derivada produce matrices con varianzas más equilibradas entre bloques espectrales, lo que evita fenómenos de dominancia y mejora el desempeño de modelos como es el caso del PCA o estrategias de fusión a nivel bajo.

En conjunto, estos factores hacen que la segunda derivada sea el preprocesamiento más adecuado cuando se requiere una corrección robusta de la línea base, una mejor separación de bandas solapadas y una mayor estabilidad en los modelos quimiométricos construidos a partir de los espectros.

4.4. Corrección

4.4.1. Corrección Lineal

La corrección lineal de línea base es uno de los métodos más simples y ampliamente utilizados para eliminar el fondo en datos espectroscópicos, especialmente en FTIR y en algunos casos de Raman [8]. Este procedimiento consiste en identificar dos puntos del espectro que se consideran representativos del nivel de fondo es decir, regiones donde no hay presencia de picos o bandas reales del análisis y trazar entre ellos una línea recta. Esta línea se resta posteriormente del espectro original, produciendo un espectro corregido en el que las señales de interés se encuentran más definidas.

Este tipo de corrección resulta adecuado cuando el fondo presenta una variación suave y aproximadamente lineal, como ocurre en espectros donde la señal instrumental es estable y no existen contribuciones significativas de fenómenos como fluorescencia, deriva térmica o scattering no lineal. Sin embargo, su efectividad disminuye cuando se trabaja con espectros que presentan curvaturas complejas, fondos polinomiales o incrementos intensos de fluorescencia, características comunes en espectros Raman de materiales orgánicos y biológicos [13].

Diversos estudios han demostrado que, aunque es un método rápido y fácil de implementar, su simplicidad implica limitaciones cuando el ruido de fondo tiene un comportamiento no lineal. En tales casos, la corrección lineal puede dejar residuos que afectan la cuantificación o incluso distorsionar la forma de los picos [14].

4.4.2. Corrección de Shirley

La corrección de Shirley es un método iterativo que estima la línea base como una función proporcional al área integrada del espectro por encima de cada punto. El método fue desarrollado para espectros Raman y Ftir, donde demostró una gran capacidad para modelar fondos no lineales [15]. Gracias a esta propiedad, su uso se ha extendido posteriormente a otros tipos de espectros, especialmente en casos donde el fondo presenta variaciones complejas o contribuciones significativas de señales superpuestas.

En el algoritmo de Shirley, el nivel de fondo aumenta suavemente en regiones donde existe una acumulación de intensidad, reflejando la contribución integrada de los picos. Este comportamiento permite separar de manera más efectiva la señal real del fondo, evitando distorsiones que suelen generarse con métodos lineales o polinomiales cuando el fondo no es lineal [14].

5. Espectroscopia

La espectroscopía es una técnica analítica que estudia la interacción entre la radiación electromagnética y la materia. A través de esta interacción se obtiene un espectro, el cual representa cómo la energía absorbida, emitida o dispersada varía en función de la longitud de onda o del número de onda. Estos espectros contienen información fundamental sobre la estructura molecular, los enlaces químicos y las vibraciones atómicas de las sustancias analizadas, permitiendo su identificación, caracterización y cuantificación [16].

En el contexto del análisis multivariado y la fusión de datos, la espectroscopía cobra un papel esencial, ya que genera conjuntos de datos altamente dimensionales y complementarios. Técnicas vibracionales como Raman y FTIR (Infrarrojo por Transformada de Fourier) son particularmente valiosas debido a su carácter no destructivo, la rápida adquisición de señales y su elevada sensibilidad molecular, lo que permite el estudio detallado de materiales orgánicos, inorgánicos, biomoléculas y compuestos poliméricos [17].

5.1. Espectroscopía Raman

La espectroscopía Raman es una técnica analítica mediante el cual la luz dispersada por una muestra experimenta un cambio en su frecuencia debido a interacciones con las vibraciones moleculares [18]. Este fenómeno de dispersión inelástica proporciona información detallada sobre la estructura molecular y las características químicas de los materiales analizados. El efecto Raman ocurre cuando un fotón incidente interactúa con una molécula y es dispersado con una energía diferente a la original. Si el fotón pierde energía tras la interacción, se produce un desplazamiento Raman Stokes; si gana energía, el fenómeno se denomina desplazamiento anti-Stokes. Debido a que la mayoría de las moléculas se encuentran en estados vibracionales fundamentales, las líneas Stokes suelen ser más intensas y, por lo tanto, más utilizadas en el análisis espectroscópico [19].

5.1.1. Ventajas de la espectroscopia Raman

Una de las ventajas más destacadas de la espectroscopía Raman es que se trata de una técnica no destructiva que requiere poca o ninguna preparación de la muestra. Además, puede aplicarse a sólidos, líquidos y gases, e incluso realizarse a través de ventanas transparentes o envases, lo que facilita el análisis in situ y el estudio de sistemas en condiciones reales. La selectividad vibracional de la técnica permite obtener información detallada sobre grupos funcionales y estructuras moleculares, incluso en materiales complejos [10].

5.1.2. Aplicaciones de la espectroscopia Raman

La espectroscopía Raman posee una amplia gama de aplicaciones en diversos campos científicos y tecnológicos debido a su capacidad para analizar la composición química de

las muestras sin necesidad de preparaciones extensas. Se utiliza de manera rutinaria en el estudio de materiales orgánicos e inorgánicos, biomoléculas, polímeros, sistemas nanoestructurados y compuestos avanzados. También es una técnica fundamental en caracterización de materiales, control de calidad, monitoreo de procesos y análisis de contaminantes [20].

5.1.3. Interpretación del espectro Raman

La interpretación del espectro Raman se basa en el análisis de los desplazamientos de frecuencia expresados en número de onda (cm^{-1}), los cuales corresponden a modos vibracionales específicos de las moléculas presentes en la muestra. Cada banda Raman funciona como una huella vibracional característica, lo que permite identificar grupos funcionales, evaluar la estructura química y detectar cambios en la composición o en el estado del material. La posición, intensidad y anchura de las bandas proporcionan información relevante sobre enlaces químicos, orden estructural, interacciones intermoleculares y posibles transformaciones físicas o químicas [12].

5.2. Espectroscopía FTIR

La espectroscopía Infrarroja por Transformada de Fourier (FTIR) es una técnica vibracional que permite obtener información detallada sobre la estructura molecular y los grupos funcionales presentes en una muestra. Su principio se basa en la absorción de radiación infrarroja por las moléculas, lo cual induce transiciones vibracionales asociadas a cambios en el momento dipolar. El espectro resultante, obtenido mediante la transformada de Fourier del interferograma generado por un interferómetro de Michelson, refleja la distribución energética de dichas absorciones [16].

FTIR es ampliamente utilizada en química, ciencia de materiales, biología y análisis ambiental debido a su capacidad para identificar compuestos, monitorear reacciones y caracterizar estructuras moleculares complejas. La técnica es especialmente sensible a enlaces químicos específicos, lo que permite diferenciar grupos funcionales, estudiar interacciones intermoleculares y detectar cambios conformacionales [12].

En el contexto del análisis multivariado, FTIR genera datos altamente dimensionales y reproducibles, lo que la convierte en una herramienta valiosa para estudios de clasificación, cuantificación y modelado predictivo. Sus aplicaciones abarcan desde la caracterización de biomoléculas y polímeros hasta la autenticación de alimentos y el control de calidad industrial [10].

5.2.1. Ventajas de la espectroscopía FTIR

La espectroscopía FTIR ofrece alta resolución, excelente relación señal-ruido y una adquisición muy rápida gracias al uso de la transformada de Fourier. Es una técnica no

destruictiva, con preparación mínima de muestra, y destaca por su gran sensibilidad a grupos funcionales específicos y a cambios en la estructura química [12].

A diferencia de Raman, FTIR no se ve afectada por fluorescencia, lo que permite obtener espectros limpios incluso en materiales orgánicos o biológicos complejos. Su versatilidad para analizar sólidos, líquidos y gases la convierte en una herramienta valiosa en control de calidad, identificación de compuestos y monitoreo de procesos industriales y biotecnológicos [21].

5.2.2. Aplicaciones de la espectroscopía FTIR

En ciencia de materiales, FTIR se emplea para el análisis de polímeros, compuestos carbonosos, cerámicas, minerales y materiales híbridos. La técnica permite evaluar cambios químicos durante procesos de degradación, curado, envejecimiento térmico o oxidativo, así como identificar impurezas o fases funcionales específicas. En química orgánica y bioquímica, FTIR es fundamental para el estudio de grupos carbonilo, hidroxilo, aminas, fosfatos y otras funcionalidades, permitiendo la caracterización estructural de proteínas, lípidos y carbohidratos[22].

En geociencias y paleontología, FTIR se utiliza para estudiar composición mineralógica, detectar sustituciones químicas en apatitas, evaluar el estado de preservación de fósiles y analizar procesos de diagénesis. Asimismo, en ingeniería y tecnología industrial, la técnica es ampliamente utilizada en control de calidad, monitoreo de procesos, autenticidad de materiales y detección de contaminantes. Finalmente, FTIR se ha consolidado como una herramienta esencial en análisis forense, control ambiental, farmacéutica y ciencias de los alimentos, gracias a su capacidad para realizar identificación rápida, no destructiva y sensible de una amplia diversidad de muestras y matrices complejas[23].

5.2.3. Interpretación del espectro FTIR

La interpretación del espectro FTIR se basa en el análisis de las bandas de absorción que aparecen cuando las moléculas interactúan con la radiación infrarroja. Estas bandas corresponden a modos vibracionales activos en el infrarrojo, es decir, vibraciones que producen un cambio en el momento dipolar de la molécula. Cada grupo funcional presenta frecuencias características, lo que permite identificar enlaces químicos, determinar la composición molecular y estudiar interacciones intermoleculares. Otros parámetros relevantes para la interpretación son la intensidad relativa, la anchura y posibles desplazamientos, los cuales pueden indicar variaciones en la conformación molecular, formación de enlaces de hidrógeno, cambios de fase o interacciones químicas. De esta forma, FTIR se convierte en una herramienta clave para estudiar procesos de degradación, cinética de reacciones, formación de complejos y modificaciones estructurales en polímeros, biomoléculas y materiales avanzados.[24].

Aspecto	Raman	FTIR
Principio vibracional	Detecta cambios en la polarizabilidad.	Detecta cambios en el momento dipolar.
Modos vibracionales	Bandas activas en Raman suelen ser débiles en FTIR.	Bandas activas en FTIR suelen ser débiles en Raman.
Sensibilidad a la muestra	Menor sensibilidad al agua.	El agua puede saturar el espectro.
Interferencias típicas	Fluorescencia puede ocultar la señal.	Picos saturados por grupos altamente absorbentes.
Información estructural	Simetría, estructura y orden molecular.	Identificación funcional e interacciones químicas.
Profundidad analítica	Inserción mayor en materiales opacos.	Excelente para análisis superficial y de grupos funcionales.
Complementariedad Raman-FTIR. Raman y FTIR proporcionan información vibracional diferente pero complementaria: una técnica destaca donde la otra presenta limitaciones. La combinación de ambas permite obtener un panorama vibracional completo, mejorar la resolución de bandas solapadas, confirmar asignaciones vibracionales y fortalecer modelos multivariados.		

Tabla 2: Complementariedad entre espectroscopía Raman y FTIR.

5.3. Análisis Multivariado

El análisis multivariado comprende un conjunto de técnicas estadísticas utilizadas para el estudio de conjuntos de datos que contienen múltiples variables, siendo especialmente valiosas cuando dichas variables presentan altos grados de correlación. A diferencia de los métodos univariados, que evalúan una variable a la vez, las técnicas multivariadas consideran la interdependencia entre múltiples dimensiones de un mismo fenómeno, proporcionando una visión más completa de los procesos estudiados [25].

Este enfoque resulta esencial en el análisis de datos de alta dimensionalidad, como los generados por las espectroscopías FTIR y Raman, donde cada espectro puede contener cientos o miles de variables altamente correlacionadas correspondientes a números de onda o longitudes de onda. En este contexto, métodos multivariados como el Análisis de Componentes Principales (PCA) y técnicas de clasificación supervisada permiten reducir la dimensionalidad del conjunto de datos, mejorar la interpretación de los resultados y resaltar las fuentes de variación más significativas. Estas herramientas facilitan la visualización de la información en espacios de menor dimensión, la detección de patrones ocultos y el desarrollo de modelos predictivos relacionados con las propiedades físicas de las muestras. No obstante, el análisis multivariado requiere una preparación rigurosa de los datos, donde etapas de preprocesamiento como normalización, corrección de dispersión y suavizado espectral son fundamentales para garantizar la comparabilidad entre variables y reducir la influencia del ruido experimental [26].

En síntesis, el análisis multivariado constituye una herramienta indispensable para el tratamiento e interpretación de datos espectroscópicos complejos, ya que permite extraer información relevante a partir de grandes volúmenes de datos correlacionados y construir modelos predictivos robustos con una base estadística sólida [27].

5.3.1. Análisis de Componentes Principales (PCA)

El propósito principal de los métodos multivariados es la extracción de información relevante a partir de conjuntos de datos complejos y altamente correlacionados. Una de las técnicas más simples y ampliamente utilizadas para la reducción de dimensionalidad y exploración de datos es el Análisis de Componentes Principales (PCA). PCA es un método estadístico no supervisado que transforma las variables originales en un nuevo conjunto de variables ortogonales y no correlacionadas, denominadas componentes principales, ordenadas de acuerdo con la cantidad de varianza explicada [26].

En el contexto de datos espectroscópicos, como los generados por espectroscopía Raman y FTIR, PCA resulta especialmente útil debido a la alta dimensionalidad y fuerte correlación existente entre las variables espectrales. Su aplicación permite identificar patrones vibracionales comunes, detectar agrupamientos naturales entre muestras y resaltar las principales fuentes de variación asociadas a diferencias químicas o estructurales. En

particular, para espectros Raman, PCA facilita la diferenciación entre compuestos químicamente similares, apoyando la exploración de datos y etapas posteriores de clasificación o modelado supervisado [27].

5.3.2. Fundamentos matemáticos del PCA

Desde el punto de vista matemático, el PCA se basa en la descomposición espectral de la matriz de covarianza (o de correlación) del conjunto de datos. A partir de esta descomposición se obtienen autovalores y autovectores, donde los autovectores definen las direcciones principales del espacio de datos y los autovalores cuantifican la varianza asociada a cada dirección [25].

Las componentes principales se obtienen como combinaciones lineales de las variables originales y se ordenan de forma decreciente según la varianza explicada. Este procedimiento permite representar el conjunto de datos original en un espacio de menor dimensionalidad, conservando la mayor parte de la información estadística relevante [26].

a) Procedimiento

El procedimiento del Análisis de Componentes Principales (PCA) se basa en una serie de pasos matemáticos que permiten transformar el conjunto de datos original en un espacio de menor dimensionalidad, conservando la mayor parte de la variabilidad presente en los datos [25].

b) Estandarización de los datos

Dado que las variables originales pueden encontrarse en diferentes escalas, el primer paso consiste en estandarizar los datos. Este proceso asegura que cada variable tenga media cero y varianza unitaria, evitando que aquellas con mayor magnitud dominen el análisis [26].

La estandarización se realiza mediante una normalización, en la cual cada variable es centrada respecto a su media y escalada por su desviación estándar.

c) Cálculo de la matriz de covarianza

Una vez estandarizados los datos, se calcula la matriz de covarianza, la cual describe el grado de correlación lineal entre las variables del conjunto de datos. La covarianza entre dos variables X_i y X_j se define como:

$$\text{cov}(X_i, X_j) = \frac{1}{n-1} \sum_{k=1}^n (X_{ik} - \bar{X}_i)(X_{jk} - \bar{X}_j) \quad (8)$$

donde:

- n es el número total de observaciones (muestras).

- k es el índice que identifica cada muestra, con $k = 1, \dots, n$.
- X_{ik} representa el valor de la variable i correspondiente a la muestra k .
- $\overline{X_i}$ es la media de la variable i , calculada a partir de todas las muestras.
- $(n - 1)$ corresponde a la corrección de Bessel, utilizada para obtener un estimador insesgado de la covarianza muestral.

La matriz de covarianza resultante es una matriz simétrica que contiene la varianza de cada variable en la diagonal principal y las covarianzas entre variables en las posiciones fuera de la diagonal [25].

d) Descomposición en autovalores y autovectores

La matriz de covarianza se descompone en autovalores y autovectores mediante una descomposición espectral. Los autovalores representan la cantidad de varianza explicada por cada componente principal, mientras que los autovectores definen las direcciones principales del espacio de datos [26].

La descomposición de la matriz de covarianza C se expresa como:

$$C = PDP^T \quad (9)$$

donde D es una matriz diagonal que contiene los autovalores y P es la matriz cuyos vectores columna corresponden a los autovectores asociados.

e) Selección de componentes principales

Las componentes principales se seleccionan en función de la proporción de varianza explicada acumulada. En aplicaciones prácticas, suele seleccionarse el menor número de componentes que expliquen un porcentaje significativo de la varianza total, típicamente del orden del 90-95 %, garantizando así una representación reducida pero informativa del conjunto de datos [25].

f) Proyección de los datos

Finalmente, los datos originales se proyectan en el espacio definido por las componentes principales seleccionadas. La proyección se obtiene multiplicando la matriz de datos original X por la matriz de autovectores P , según:

$$Z = XP \quad (10)$$

donde Z representa la matriz de datos transformados en el espacio de las componentes principales.

5.3.3. Limitaciones del PCA

El Análisis de Componentes Principales (PCA) es ampliamente utilizado como técnica de visualización de datos mediante la proyección del conjunto original en un espacio de dos dimensiones. Esta aproximación resulta intuitiva y útil para la exploración de datos complejos; sin embargo, presenta limitaciones importantes que deben ser consideradas [26].





Figura 2: Esquema general del PCA aplicado a la reducción de dimensionalidad y visualización de datos.

Fuente: <https://www.dailydoseofds.com>, adaptado por los autores.

Tras aplicar PCA, cada componente principal captura una fracción decreciente de la varianza total del conjunto de datos. En consecuencia, la visualización bidimensional solo es adecuada cuando los dos primeros componentes principales explican de forma conjunta una proporción elevada de la varianza original.




PCA seguro de usar para visualización 2D

Figura 3: Caso en el que los dos primeros componentes principales explican la mayor parte de la varianza total, haciendo adecuada la visualización en dos dimensiones.

Fuente: <https://www.dailydoseofds.com>, adaptado por los autores.

Por el contrario, cuando la varianza explicada por los dos primeros componentes es baja, la proyección en dos dimensiones puede resultar engañosa, ya que una parte sustancial de la información queda distribuida en componentes de orden superior.



No se recomienda utilizar PCA para visualización 2D

Figura 4: Caso en el que los dos primeros componentes principales no capturan suficiente varianza, por lo que no se recomienda la visualización bidimensional mediante PCA.

Fuente: <https://www.dailydoseofds.com>, adaptado por los autores.

Por lo tanto, el uso de PCA como herramienta de visualización en dos dimensiones solo se recomienda cuando el análisis de la varianza explicada acumulada lo justifique. En caso contrario, es preferible recurrir a métodos alternativos de reducción de dimensionalidad, especialmente aquellos capaces de capturar relaciones no lineales presentes en los datos.

5.3.4. t-Distributed Stochastic Neighbor Embedding (t-SNE)

La incrustación de vecinos estocásticos distribuidos en t (t-Distributed Stochastic Neighbor Embedding, t-SNE) es una técnica de reducción de dimensionalidad no lineal utilizada principalmente para la visualización de conjuntos de datos de alta dimensión mediante su proyección en espacios de baja dimensionalidad, típicamente en dos o tres dimensiones.

A diferencia del PCA, que preserva la varianza global de los datos mediante transformaciones lineales, t-SNE se enfoca en preservar las relaciones locales entre las muestras. Para ello, el método convierte las distancias entre pares de puntos en el espacio de alta dimensión en probabilidades que reflejan la similitud entre muestras, y busca una representación en el espacio reducido que minimice la divergencia entre ambas distribuciones de probabilidad[28].

Esta característica hace que t-SNE sea especialmente eficaz para revelar estructuras complejas, agrupamientos naturales y patrones no lineales que pueden pasar desapercibidos con técnicas lineales. En el análisis de datos espectroscópicos, como FTIR y Raman, t-SNE ha demostrado ser una herramienta valiosa para la exploración visual de clases químicamente similares, la detección de subgrupos y la evaluación preliminar de la separabilidad entre muestras.

Sin embargo, t-SNE presenta algunas limitaciones importantes. El método no conserva las distancias globales ni la varianza explicada, por lo que los ejes del espacio reducido no tienen una interpretación física directa. Además, los resultados dependen de parámetros como la perplexity, la tasa de aprendizaje y la inicialización, lo que puede generar diferentes representaciones visuales para un mismo conjunto de datos.

Por estas razones, t-SNE se utiliza principalmente como una herramienta exploratoria y visual, complementaria a métodos lineales como PCA, y no como una técnica para modelado predictivo o interpretación cuantitativa directa[29].

5.3.5. Fundamentos matemáticos del t-SNE

Desde el punto de vista matemático, t-SNE modela explícitamente las relaciones de vecindad entre muestras mediante distribuciones de probabilidad, con el objetivo de preservar la estructura local de los datos durante la proyección a un espacio de menor dimensión. A diferencia de métodos lineales, su formulación se basa en la comparación probabilística de pares de puntos en los espacios original y reducido [28].

El método comienza modelando la similitud entre pares de puntos en el espacio original de alta dimensión. Dada una colección de vectores $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$, la similitud condicional entre dos puntos $\mathbf{x}_i$ y $\mathbf{x}_j$ se define como:

$$p_{j|i} = \frac{\exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_k\|^2}{2\sigma_i^2}\right)} \quad (11)$$

donde σ_i es un parámetro adaptativo que controla el ancho de la distribución gaussiana centrada en el punto $\mathbf{x}_i$. Estas probabilidades se simetrizan para obtener una medida conjunta de similitud:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n} \quad (12)$$

En el espacio de baja dimensión, los puntos proyectados $\{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n\}$ se comparan utilizando una distribución t de Student con un grado de libertad, lo que permite modelar de manera más adecuada las relaciones entre puntos lejanos y mitigar el denominado *crowding problem*. La similitud en el espacio reducido se define como:

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|\mathbf{y}_k - \mathbf{y}_l\|^2)^{-1}} \quad (13)$$

El objetivo del algoritmo consiste en encontrar una proyección que minimice la divergencia de Kullback–Leibler entre las distribuciones de similitud del espacio original y del espacio reducido, definida como:

$$\mathcal{C} = \sum_{i \neq j} p_{ij} \log\left(\frac{p_{ij}}{q_{ij}}\right) \quad (14)$$

Esta función de costo penaliza fuertemente los casos en los que puntos cercanos en el espacio original aparecen separados en la representación de baja dimensión, favoreciendo la preservación de la estructura local de los datos [28].

Desde un punto de vista práctico, t-SNE no conserva distancias globales ni varianza, por lo que sus resultados deben interpretarse de manera cualitativa. En aplicaciones espectroscópicas, como FTIR y Raman, t-SNE se utiliza principalmente como herramienta exploratoria para la visualización de agrupamientos, y suele aplicarse después de una reducción inicial de dimensionalidad mediante PCA, con el fin de eliminar ruido y redundancias antes del análisis no lineal [26].

5.3.6. Análisis de Clúster Jerárquico (HCA)


Es una técnica de aprendizaje no supervisado que permite agrupar observaciones en función de su similitud, construyendo una estructura jerárquica representada mediante un dendrograma [30].

El procedimiento de HCA se desarrolla de forma secuencial a través de los siguientes pasos:

a) Cálculo de la distancia

El primer paso consiste en cuantificar la disimilitud entre todas las observaciones. Una de las métricas más utilizadas es la distancia euclidiana, definida como [31]:

$$d_{\text{Euclidiana}}(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2} \quad (15)$$




Representación geométrica de la distancia euclidiana.

Figura 5: Distancia euclidiana entre dos puntos en un espacio p -dimensional.

donde $\mathbf{x}$ y $\mathbf{y}$ son vectores de observaciones y p es el número de variables.

Alternativamente, puede emplearse la distancia Manhattan, que mide la suma de las diferencias absolutas entre las coordenadas: [30]

$$d_{\text{Manhattan}}(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^p |x_i - y_i| \quad (16)$$



Representación geométrica de la distancia Manhattan.

Figura 6: Distancia Manhattan entre dos puntos en un espacio p -dimensional.

b) Regla de enlace o fusión de clústeres

Una vez calculadas las distancias, se define un criterio para fusionar los clústeres. Entre los métodos de enlace más utilizados se encuentran:


- **Single linkage:** define la distancia entre dos clústeres como la distancia mínima entre cualquier par de observaciones pertenecientes a ambos clústeres [30]:

$$D(C_1, C_2) = \min_{x \in C_1, y \in C_2} d(x, y) \quad (17)$$




- **Complete linkage:** utiliza la distancia máxima entre las observaciones de los clústeres [31]:

$$D(C_1, C_2) = \max_{x \in C_1, y \in C_2} d(x, y) \quad (18)$$




- **Average linkage:** calcula la distancia promedio entre todos los pares de observaciones de los clústeres [32]:

$$D(C_1, C_2) = \frac{1}{|C_1||C_2|} \sum_{x \in C_1} \sum_{y \in C_2} d(x, y) \quad (19)$$



- **Método de Ward:** fusiona los clústeres que producen el menor incremento en la varianza intra-clúster, equivalente a minimizar el aumento de la suma de cuadrados dentro de los grupos [33]:

$$\Delta E = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_{C_k}\|^2 \quad (20)$$



c) **Construcción e interpretación del dendrograma.** El dendrograma representa el proceso jerárquico de fusión. La altura de cada unión indica la disimilitud a la que se combinaron los grupos, permitiendo visualizar qué observaciones son más similares y decidir un número de clústeres mediante un corte a una altura determinada [32].

6. Metodología

Para la realización del presente trabajo, se emplearon muestras de medicamentos analizadas mediante espectroscopia Raman y FTIR en el laboratorio de Análisis Moleculares de la Facultad de Ciencias Exactas y Naturales. Estas técnicas fueron seleccionadas por su capacidad de proporcionar información complementaria sobre la composición molecular, los modos vibracionales y la estructura química de los compuestos farmacéuticos.

Los espectros obtenidos fueron sometidos a un preprocesamiento digital con el fin de garantizar la calidad, consistencia y comparabilidad de los datos antes del análisis. Las etapas de preprocesamiento incluyeron suavizado para la reducción de ruido, corrección de línea base, normalización (por área o por media) y, en algunos casos, el cálculo de derivadas para resaltar variaciones espectrales sutiles. Una vez preprocesados, los datos fueron organizados en una matriz multivariante y analizados mediante técnicas estadísticas como el Análisis de Componentes Principales, t-Distributed Stochastic Neighbor Embedding y Análisis de Clúster Jerárquico.

Adicionalmente, se aplicó un enfoque de fusión de datos, combinando la información proveniente de las técnicas FTIR y Raman con el objetivo de mejorar la capacidad discriminante de los modelos y facilitar la interpretación de los resultados[34].

El programa desarrollado para este trabajo fue implementado en el lenguaje Python con el objetivo de crear una herramienta computacional específica para el procesamiento y análisis de datos espectroscópicos. La aplicación integra en una sola interfaz las etapas de preprocesamiento, análisis multivariado y fusión de datos. Su diseño se inspiró en la filosofía del software Orange Data Mining, reconocido por su entorno visual y su facilidad para el análisis exploratorio de datos, aunque no dispone de módulos específicos para la fusión de datos espectroscópicos provenientes de distintas técnicas analíticas.

Ante esta limitación, se desarrolló EspectroApp, una aplicación creada desde cero utilizando PySide6 para la interfaz gráfica y bibliotecas científicas como NumPy, Pandas y Scikit-learn para el modelado de datos, así como Plotly y Matplotlib para la visualización de resultados. La herramienta permite implementar de manera integrada las etapas metodológicas del presente trabajo, incluyendo la fusión de datos en diferentes niveles.

6.1. Arquitectura metodológica y computacional de la aplicación

Con el fin de implementar de manera integrada las etapas de preprocesamiento, análisis multivariado, fusión de datos y visualización de resultados, se desarrolló una arquitectura computacional modular.

La Figura X presenta el esquema general de la arquitectura metodológica y computacional de la aplicación, donde la interfaz gráfica actúa como eje central que integra de forma interactiva todas las etapas del flujo de trabajo.




Figura 7: Esquema general de la interfaz gráfica y del flujo metodológico completo de la aplicación.

Fuente: Elaborado por el autor.

6.1.1. Interfaz gráfica e interacción con el usuario

La interfaz gráfica de la aplicación fue desarrollada utilizando la biblioteca PySide6, la cual permite la creación de ventanas, botones, menús y tablas, así como la gestión de eventos asociados a la interacción del usuario, tales como clics, selección de archivos y ejecución de análisis.

Desde el punto de vista metodológico, la interfaz gráfica cumple un rol fundamental al permitir que todo el flujo de trabajo de preprocesamiento, análisis y visualización sea interactivo, tal como se ilustra en la Figura X(figura de arriba GUI).

6.1.2. Gestión y organización de los datos espectroscópicos

Los datos espectroscópicos obtenidos mediante FTIR y Raman fueron organizados y gestionados utilizando las bibliotecas Pandas y NumPy. Pandas se empleó para el almacenamiento estructurado de los espectros en forma de DataFrames, donde las filas representan el número de ondas y las columnas las distintas muestras analizadas.

Por su parte, NumPy proporcionó el soporte matemático necesario para la realización de operaciones matriciales, normalización, escalado y transformaciones vectoriales, constituyendo la base matemática de los métodos multivariados aplicados (Figura X).




Figura 8: Esquema de la gestión y organización de los datos espectroscópicos mediante las bibliotecas Pandas y NumPy.

Fuente: Elaborado por el autor.

6.1.3. Preprocesamiento espectral y análisis multivariado

El preprocesamiento espectral se llevó a cabo utilizando funciones de la biblioteca SciPy, orientadas al procesamiento de señales y análisis matemático. Entre las técnicas implementadas se incluyeron el suavizado Savitzky–Golay, el filtrado gaussiano, la corrección de línea base y el cálculo de distancias para análisis de agrupamiento.

Estas etapas permitieron mejorar la calidad de los espectros antes de su análisis multivariado, reduciendo el ruido y resaltando características espectrales relevantes.

Posteriormente, el análisis multivariado fue implementado utilizando la biblioteca Scikit-learn. Se aplicaron técnicas de reducción de dimensionalidad como el PCA y t-SNE para la exploración de la estructura de los datos, así como métodos de estandarización y evaluación de la separabilidad mediante el clasificador K-Nearest Neighbors.

Este conjunto de procedimientos constituye el núcleo del análisis multivariado y exploratorio del trabajo, integrando el preprocesamiento espectral con los métodos de reducción de la Figura X




Figura 9: Esquema del módulo de preprocesamiento espectral y análisis multivariado, mostrando la integración entre las bibliotecas SciPy y Scikit-learn.

Fuente: Elaborado por el autor.

6.1.4. Análisis de clúster jerárquico

El análisis de clúster jerárquico se realizó mediante el módulo `scipy.cluster.hierarchy`, permitiendo la construcción de dendrogramas y la identificación de agrupamientos naturales entre las muestras. Se utilizaron distintos criterios de enlace y la función `fccluster` para la definición de clústeres, facilitando la interpretación de similitudes entre espectros Figura X.




Figura 10: Esquema del análisis de clúster jerárquico implementado mediante el módulo `scipy.cluster.hierarchy`.

Fuente: Elaborado por el autor.

6.1.5. Visualización de resultados

La visualización de los resultados se realizó combinando gráficos científicos estáticos, generados con Matplotlib, y visualización interactiva de datos mediante Plotly.

Mientras que los gráficos estáticos garantizan una representación clara y reproducible de los resultados, la visualización interactiva permite una exploración visual avanzada de los datos, facilitando la interpretación de patrones, agrupamientos y separabilidad entre muestras (Figura X).




Figura 11: Esquema del módulo de visualización de resultados, combinando gráficos científicos estáticos y visualización interactiva de datos.

Fuente: Elaborado por el autor.

6.1.6. Arquitectura del programa y ejecución concurrente

Con el objetivo de mejorar la usabilidad de la aplicación sin afectar el análisis, se implementó una arquitectura basada en hilos independientes para la ejecución de tareas como la carga de archivos, el graficado y la aplicación de métodos de reducción de dimensionalidad.

Esta estrategia evita el bloqueo de la interfaz gráfica y permite la ejecución de cálculos pesados en segundo plano (Figura X).




Figura 12: Esquema de la arquitectura concurrente del programa para la mejora de la usabilidad sin afectar el análisis.

Fuente: Elaborado por el autor.

Capítulo 4

7. Resultados

En este capítulo se presentan los resultados experimentales y computacionales obtenidos a partir del análisis de las muestras de medicamentos mediante espectroscopía Raman y FTIR. Los datos fueron procesados utilizando el software EspectroApp, desarrollado en Python, el cual permitió realizar las etapas de preprocesamiento, análisis multivariado y fusión de datos. El objetivo principal de este capítulo es mostrar la evolución de los resultados en cada etapa del estudio, desde la adquisición de los espectros hasta la obtención de los modelos multivariados y su integración mediante fusión de datos, comparando los aportes de cada técnica por separado y de manera combinada.

Los resultados se presentan de manera estructurada, iniciando con la caracterización espectroscópica individual de Raman y FTIR, seguida de los procesos de preprocesamiento, los análisis estadísticos multivariados y finalmente la implementación de la fusión de datos, que permitió obtener una interpretación más robusta y complementaria de las muestras analizadas.

7.1. Resultados de los espectros Raman y FTIR

Para el desarrollo del experimento se utilizaron dos conjuntos de datos espectroscópicos correspondientes a las técnicas FTIR y Raman, respectivamente. Cada archivo contiene los valores espectrales obtenidos a partir de las muestras de medicamentos analizadas en la Facultad de Ciencias Exactas y Naturales. El archivo FTIR está conformado por 7469 filas y 151 columnas. En este conjunto de datos, la primera columna representa el eje X, correspondiente al número de onda expresado en (cm^{-1}), mientras que las columnas restantes contienen los valores de absorbancia asociados a cada muestra. De manera análoga, el archivo Raman presenta 1824 filas y 151 columnas, donde la primera columna también corresponde al eje X, que en este caso representa el desplazamiento Raman (cm^{-1}), y las columnas siguientes registran las intensidades de dispersión inelástica de cada muestra. En ambos conjuntos, la primera fila contiene las etiquetas o nombres de las muestras, lo cual permite identificar cada espectro de manera individual. La tabla 3 muestra un ejemplo de la estructura de los archivos empleados, donde puede observarse la organización de los valores espectrales y los encabezados correspondientes. Esta disposición uniforme fue fundamental para permitir la integración posterior de ambos conjuntos de datos durante la etapa de fusión de datos, asegurando la correspondencia entre los puntos espectrales y las etiquetas de las muestras.

RAMAN FTIR	MUESTRA	MUESTRA	MUESTRA	MUESTRA
148.32	65535	65535	65535	148.32
150.70	65535	54614.6	65535	150.70
153.07	55757.7	45402.1	65535	153.07
155.45	49374.4	40244.8	65535	155.45
157.82	44661.4	37004.7	64471.2	157.82
160.20	40975.2	33929.1	61088.1	160.20

Tabla 3: Datos espectroscópicos Raman/FTIR de distintas muestras.

7.2. Descripción de los Espectros obtenidos sin procesar

La interfaz de grafica fue implementada en Python utilizando las librerías PySide6 para la construcción de la interfaz y PyQtGraph para la visualización de los espectros. Esta clase permite representar múltiples espectros Raman o FTIR en un mismo gráfico, asignando colores distintivos a cada tipo de muestra y evitando la duplicación de leyendas. Los datos son procesados a partir de un DataFrame de pandas, y los valores de desplazamiento Raman se manejan mediante NumPy para optimizar la representación numérica.

7.2.1. Espectros Raman

Los espectros mostrados corresponden a las mediciones originales obtenidas mediante espectroscopía Raman para las muestras de aspirina, ibuprofeno y paracetamol. En esta etapa los datos aún no fueron procesados, Estos espectros reflejan la intensidad en función de la longitud de onda, lo cual es característico de las vibraciones moleculares de las diferentes muestras de fármacos estudiadas. En este gráfico podemos observar una gran cantidad de picos distribuidos a lo largo del rango espectral, los cuales corresponden a las señales características de las moléculas presentes en las muestras. Sin embargo, también se observan diferencias en las intensidades entre los espectros y ruidos




Figura 13: Grafico Espectros Raman sin procesar.

Fuente: , adaptado por los autores, 2026.

7.2.2. Espectros FTIR

Los espectros FTIR mostrados en la Figura 14 corresponden a las señales originales obtenidas de las muestras de aspirina, ibuprofeno y paracetamol. En esta etapa, los datos aún no fueron sometidos a ningún tipo de filtrado ni corrección, por lo que es posible observar variaciones en la intensidad de las bandas.




Figura 14: Grafico Espectros FTIR sin procesar.

Fuente: , adaptado por los autores, 2026.

Estos resultados iniciales permiten visualizar el comportamiento espectral general de las muestras y sirven como punto de partida para el posterior preprocesamiento y análisis comparativo.

7.3. Procesamiento de los datos espectroscópicos

Para corregir las irregularidades presentes en los espectros originales y mejorar la calidad de los datos, se aplicaron técnicas de preprocesamiento sobre las intensidades. Como primer paso, se realizó una normalización por la media ($\mu = 0$, $\sigma^2 = 1$), con el objetivo de centrar los valores de intensidad y eliminar diferencias debidas a escalas instrumentales. Posteriormente, se aplicó un suavizado de Savitzky–Golay con una ventana de 3 puntos y un orden polinómico igual a 2, lo que permitió reducir el ruido sin distorsionar significativamente la forma de los picos espectrales.

Finalmente, se calculó la primera derivada de los espectros, con el propósito de eliminar el efecto de fondo y resaltar los cambios locales de pendiente asociados a las bandas características de cada técnica espectroscópica.

El resultado de este procedimiento se presenta en la Figura A (espectros FTIR) y en la Figura B (espectros Raman), donde se observa una mejora en la definición de las señales, una reducción notable del ruido de fondo y una mayor diferenciación entre las curvas correspondientes a cada muestra analizada.




Figura 15: Comparación de los espectros FTIR y Raman tras el preprocesamiento por normalización, suavizados mediante Savitzky–Golay (ventana 3, orden 2) y primera derivada.

Fuente: Elaboración propia, adaptado por los autores (2026).


7.4. Análisis multivariado: PCA y K-Nearest Neighbors (KNN)

Una vez obtenidos los espectros normalizados, se procedió a aplicar técnicas de análisis multivariado con el objetivo de explorar la estructura de los datos y evaluar la capacidad de clasificación de las muestras a partir de sus características espectrales.


En primer lugar, se realizó un Análisis de Componentes Principales (PCA) tanto sobre los datos crudos como sobre los datos preprocesados. Esta técnica permite reducir la dimensionalidad del conjunto de datos conservando la mayor parte de la varianza original, facilitando la visualización de patrones y agrupamientos entre las muestras. Los gráficos de las Figuras X(a) y X(b) muestran los resultados del PCA aplicado a los espectros FTIR y Raman antes y después del preprocesamiento, respectivamente. Se observa que la aplicación de las etapas de normalización, suavizado y derivada mejora la separación de los grupos y la definición de las tendencias en el espacio de componentes principales. Posteriormente, se aplicó el método de K-Nearest Neighbors (KNN) para la clasificación supervisada de las muestras. Este algoritmo determina la clase de una muestra desconocida considerando la distancia a sus K vecinos más cercanos en el espacio de características. Por ejemplo, si se establece $K=5$, el modelo identifica los cinco espectros más próximos y asigna la clase predominante entre ellos a la muestra analizada.

La eficacia del modelo se evaluó mediante el porcentaje de aciertos, que mide la proporción de predicciones correctas respecto al total de muestras. Por ejemplo, si el modelo clasifica correctamente 9 de 10 muestras, la precisión obtenida será del 90 %.

Este enfoque combina el análisis exploratorio (PCA) con la clasificación supervisada (KNN), permitiendo evaluar tanto la coherencia de los datos como la capacidad predictiva del modelo respecto a la diferenciación entre los tipos de muestras analizadas.



(A) PCA de FTIR aplicado a los datos espectrales crudos.



(B) PCA de FTIR aplicado a los datos normalizados y suavizados.

Figura 16: Comparación del análisis PCA antes y después del preprocesamiento de los espectros FTIR.


Fuente: Elaboración propia, adaptado por los autores (2026).

En la Figura 9 se presenta la comparación del análisis de Componentes Principales (PCA) aplicado a los espectros FTIR antes y después del preprocesamiento.


En el PCA aplicado a los datos crudos (Figura 16 A) se observa una dispersión considerable de las muestras y una superposición entre los diferentes grupos, lo que se traduce en una porcentaje de acertividad del 57.78 %. Este valor relativamente bajo indica que las variaciones instrumentales y el ruido de fondo presentes en los espectros sin procesar dificultan la discriminación efectiva entre los tipos de compuestos analizados.

En contraste, el PCA aplicado a los datos normalizados y suavizados (Figura 16 B) muestra una mayor separación entre los grupos y un incremento notable de la precisión del modelo (93.33 %). Este resultado evidencia la importancia del preprocesamiento, ya que la normalización y el suavizado de Savitzky–Golay contribuyen a eliminar las diferencias sistemáticas y el ruido, permitiendo que el análisis multivariado capte de forma más eficiente las variaciones reales de las muestras.

En conjunto, estos resultados confirman que el preprocesamiento mejora significativamente la capacidad del PCA para diferenciar los tipos de espectros FTIR, incrementando la coherencia de los agrupamientos y la robustez del modelo de clasificación.



(A) PCA de RAMAN aplicado a los datos espectrales crudos.



(B) PCA de RAMAN aplicado a los datos normalizados y suavizados.

Figura 17: Comparación del análisis PCA antes y después del preprocesamiento de los espectros RAMAN.


Fuente: Elaboración propia, adaptado por los autores (2026).

En la Figura 17 se muestra el análisis de Componentes Principales (PCA) aplicado a los espectros Raman antes y después del preprocesamiento.

En el PCA aplicado a los datos crudos (Figura 17A) se observa una tendencia parcial a la agrupación de las muestras, aunque con cierta superposición entre las clases correspondientes a los tres compuestos analizados. El modelo alcanza un porcentaje de acertividad del 88.89 % , lo que indica una capacidad moderadamente buena de diferenciación pese a la presencia de ruido instrumental y variaciones de intensidad. Tras aplicar el preprocesamiento —que incluyó la normalización por la media y el suavizado de Savitzky–Golay— el PCA procesado (Figura 17B) muestra una separación clara y definida entre los grupos, alcanzando una acertividad del 100 %.

Este incremento de precisión confirma que el tratamiento previo de los espectros mejora significativamente la calidad de los datos, eliminando variaciones no relacionadas con la composición de las muestras y permitiendo que el modelo de PCA capture de manera más fiel las diferencias estructurales entre los compuestos (Aspirina, Ibuprofeno y Paracetamol). En consecuencia, el análisis demuestra que los métodos de preprocesamiento aplicados no solo reducen el ruido y los efectos de fondo, sino que también potencian la capacidad del PCA para discriminar correctamente entre las muestras en función de sus características espectrales.

7.5. Análisis multivariado: TSNE y K-Nearest Neighbors (KNN)



(A) TSNE de FTIR aplicado a los datos espectrales crudos.

(B) TSNE de FTIR aplicado a los datos normalizados y suavizados.


Figura 18: Comparación del análisis TSNE antes y después del preprocesamiento de los espectros FTIR.

Fuente: Elaboración propia, adaptado por los autores (2026).

En la Figura 18 se presentan los resultados del t-SNE aplicado a los espectros FTIR antes y después del preprocesamiento. En el caso de los datos crudos (Figura 18A), el modelo t-SNE logró un porcentaje de acertividad del 90.00 %, mostrando una tendencia general a la separación entre los tres grupos (Aspirina, Ibuprofeno y Paracetamol), aunque aún se evidencian zonas de superposición parcial entre clases. Esto indica que, sin un tratamiento previo, las variaciones instrumentales y el ruido de fondo dificultan la correcta agrupación de las muestras.

Tras aplicar el preprocesamiento que incluyó la normalización por la media y el suavizado de Savitzky–Golay se observa una mejor definición de los grupos en el espacio bidimensional, alcanzando una acertividad del 93.33 % (Figura 18B). La distribución de las muestras es más compacta dentro de cada clase y más separada entre clases, lo que evidencia que el preprocesamiento favorece la reducción del ruido y mejora la calidad de la proyección generada por t-SNE.

En conjunto, estos resultados demuestran que el método t-SNE, al igual que el PCA, se beneficia significativamente de las etapas de preprocesamiento, permitiendo representar de forma más clara los datos FTIR y facilitando la discriminación entre las distintas sustancias analizadas.



(A) TSNE de RAMAN aplicado a los datos espectrales crudos.

(B) TSNE de RAMAN aplicado a los datos normalizados y suavizados.

Figura 19: Comparación del análisis RAMAN antes y después del preprocesamiento de los espectros FTIR.

Fuente: Elaboración propia, adaptado por los autores (2026).

En la Figura 19 se muestran los resultados del método t-SNE aplicado a los espectros Raman antes y después del preprocesamiento.

En el caso de los datos sin procesar (Figura 19A), el modelo t-SNE alcanzó un porcentaje de acertividad del 96.67 %, evidenciando una adecuada capacidad de separación entre las tres clases analizadas. No obstante, aún se observan ligeras zonas de superposición entre grupos, atribuibles a variaciones experimentales o a la presencia de ruido en los espectros originales.

Luego del preprocesamiento de los datos espectrales que consistió en la normalización por la media y el suavizado mediante el filtro de Savitzky–Golay, el modelo mostró una mejor definición de los clústeres correspondientes a cada tipo de compuesto, alcanzando una acertividad del 100 % (Figura 19B).

Este incremento confirma que el preprocesamiento mejora la calidad de los datos al reducir el ruido y las fluctuaciones de intensidad, permitiendo que el algoritmo t-SNE represente con mayor fidelidad las relaciones de similitud entre los espectros Raman. En consecuencia, la técnica demostró un excelente poder discriminante, siendo capaz de separar completamente las clases de muestras en el espacio bidimensional.

7.6. Análisis del Análisis de clúster jerárquico (HCA)


El análisis de agrupamiento jerárquico fue aplicado a los espectros Raman previamente preprocesados, incluyendo las etapas de normalización y suavizado, con el objetivo de evaluar la similitud espectral entre las muestras correspondientes a Aspirina, Ibuprofeno y Paracetamol. Para la construcción del dendrograma se empleó el método de enlace de Ward en combinación con la distancia euclidiana, estrategia que permite minimizar la

variabilidad dentro de los grupos y favorecer la formación de agrupamientos internamente homogéneos.

El dendrograma obtenido evidencia una separación clara en tres ramas principales, las cuales se asocian directamente a cada uno de los compuestos analizados. Las muestras de Aspirina, Ibuprofeno y Paracetamol se agrupan de manera coherente dentro de sus respectivos clústeres, reflejando una elevada homogeneidad interna y una clara diferenciación entre los distintos analgésicos estudiados.

Asimismo, la estructura jerárquica revela la presencia de subdivisiones internas dentro de cada grupo principal, atribuibles a variaciones menores en la intensidad relativa o en la forma de los espectros Raman. Estas variaciones no comprometen la consistencia global del agrupamiento, sino que reflejan diferencias experimentales sutiles entre muestras de una misma sustancia.

La concordancia observada entre los resultados del HCA y los obtenidos mediante el análisis de componentes principales (PCA), donde también se evidenció una separación completa entre los grupos, confirma la robustez del enfoque adoptado. En conjunto, estos resultados demuestran que el preprocesamiento espectral mejora significativamente la capacidad de discriminación, permitiendo una representación jerárquica más definida y consistente de los datos Raman.



(A) HCA aplicado a los datos espectrales procesador.

Figura 20: HCA del PCA figura 10 B.


Fuente: Elaboración propia, adaptado por los autores (2026).

7.7. Fusion de Datos

Para la etapa de fusión de datos, se analizaron inicialmente los espectros Raman y FTIR obtenidos en los ensayos experimentales. Como se observa en la Figura X (Raman) y en la Figura X (FTIR), ambos espectros presentan su mayor concentración de información útil en el intervalo comprendido aproximadamente entre 450 y 1800 (cm^{-1}), región donde se localizan las bandas vibracionales más representativas para los compuestos farmacéuticos estudiados.

Con el fin de mejorar la calidad de la representación multivariante y aumentar la capacidad discriminante del modelo, se procedió a acotar ambos conjuntos de datos dentro de este intervalo común. La acotación permite reducir ruido espectral, eliminar regiones sin información significativa y concentrar el análisis únicamente en las bandas que aportan mayor relevancia. El modelo resultante fue evaluado mediante análisis multivariante, obteniéndose un porcentaje de asertividad preliminar del 84,44 %. Este resultado inicial es esperado, ya que la matriz fusionada aún no ha sido sometida a las etapas de preprocesamiento posteriores, tales como normalización, suavizado, corrección de línea base o cálculo de derivadas.

Por ello, este valor no representa aún el rendimiento óptimo del sistema, sino únicamente una referencia base del comportamiento del modelo utilizando los datos crudos acotados. En la Figura 21 se presenta la matriz resultante luego de la fusión de datos y su primera representación gráfica, previa a sus transformaciones espectrales.




(A) Low Level 450 a 1800 sin procesar.

Figura 21: PCA del Low Level figura 14

Fuente: Elaboración propia, adaptado por los autores (2026).

Luego de aplicar la segunda derivada y repetir el procedimiento de fusión Low-Level seguido del análisis PCA, se obtuvo una separación mucho más clara entre las tres clases farmacéuticas, eliminando prácticamente todo el solapamiento observado en el modelo previo. Este refinamiento en la calidad de los datos se refleja directamente en el rendimiento del modelo, alcanzándose un porcentaje de asertividad del 100 %, evidenciando la efectividad del preprocesamiento derivativo en la mejora del poder discriminante como se observa en la figura 22.



(A) Low Level 450 a 1800 con segunda derivada.

Figura 22: PCA del Low Level figura 15

Fuente: Elaboración propia, adaptado por los autores (2026).

La aplicación de la segunda derivada a los espectros Raman y FTIR antes de la fusión permitió eliminar las diferencias de escala entre ambas técnicas, resaltar las características espectrales relevantes y equilibrar las varianzas entre los bloques. Gracias a este preprocesamiento, se evitó el fenómeno de dominancia del bloque Raman y se logró que las dos técnicas aportaran información útil al modelo de fusión.

En los espectros Raman y FTIR utilizados en este trabajo se observaron diferencias muy significativas en la escala de intensidades originales. Los espectros Raman presentaban valores de hasta 65,000 unidades arbitrarias, mientras que los espectros FTIR mostraban absorbancias del orden de 0.03. Estas diferencias de varios órdenes de magnitud afectan de forma crítica la estrategia de fusión a nivel bajo, ya que la concatenación directa de ambas matrices genera un fenómeno conocido como dominancia de bloque. En este escenario, el bloque con mayor varianza (Raman) controla por completo la construcción del modelo multivariante, mientras que el bloque con menor escala (FTIR) aporta muy poca o incluso ninguna información al análisis.

Para evitar este efecto no deseado, se aplicó la segunda derivada a los espectros de ambas técnicas antes de la fusión. La segunda derivada produce varios beneficios simultá-

neos como corregir de manera natural las diferencias de escala entre técnicas, resaltar los cambios en la forma de los picos en lugar de las intensidades absolutas y reducir de forma drástica la amplitud numérica de los datos, permitiendo que las varianzas de los bloques Raman y FTIR queden en un orden de magnitud comparable.

Como consecuencia directa de este preprocesamiento, la matriz fusionada deja de estar sesgada hacia Raman y permite que ambos bloques contribuyan de manera equilibrada a la construcción del modelo multivariante. Este comportamiento se refleja en los resultados del PCA: luego de aplicar las derivadas, las componentes principales comienzan a capturar información conjunta proveniente de Raman y FTIR, lo que evidencia que la fusión deja de ser degenerada y pasa a ser plenamente informativa.

En resumen, la segunda derivada actuó como un mecanismo de normalización estructural, equilibrando las escalas de ambos bloques y favoreciendo una fusión efectiva. Este enfoque resulta especialmente útil cuando se integran técnicas espectroscópicas con unidades, dinámicas de señal o sensibilidades muy diferentes, y es ampliamente recomendado en metodologías contemporáneas de Low-Level Data Fusion.

Capítulo 5

8. Discusión

Se evidencian que la integración de datos espectroscópicos FTIR y Raman mediante estrategias de fusión de datos a nivel bajo mejora de forma significativa la discriminación y clasificación de muestras, en comparación con el uso individual de cada técnica. Este comportamiento concuerda con lo reportado en la literatura reciente, particularmente con el estudio de Ahmmed et al.[35], quienes demostraron que la fusión de datos Raman e infrarrojos permite aumentar la precisión en la detección y cuantificación de adulterantes en aceites marinos premium, en comparación con modelos basados en una sola técnica espectroscópica .

En el trabajo de Ahmmed et al.[35], los autores aplicaron fusión de datos a nivel bajo mediante la concatenación directa de las intensidades espectrales FTIR y Raman, observando mejoras significativas en la exactitud de los modelos de clasificación. De manera análoga, en el presente estudio se observó que la fusión de datos implementada en EspectroApp genera una separación más definida entre las muestras farmacéuticas analizadas, tanto en los espacios de reducción de dimensionalidad obtenidos mediante PCA como en los resultados de los algoritmos de agrupamiento jerárquico, en comparación con los modelos construidos a partir de FTIR o Raman de forma independiente. Estos resultados refuerzan la idea de que la información contenida en ambas técnicas no es redundante, sino complementaria.

El análisis de componentes principales (PCA) desempeñó un papel fundamental en la evaluación del impacto de la fusión de datos sobre la estructura de los conjuntos espectroscópicos. En los modelos construidos a partir de FTIR o Raman de forma individual, se observó un mayor solapamiento entre grupos de muestras, lo que sugiere que la información aportada por una sola técnica resulta insuficiente para describirlo completamente en el sistema. En contraste, al aplicar PCA sobre los datos fusionados, se obtuvo una separación más clara en los primeros componentes principales, indicando que una mayor proporción de la varianza relevante fue capturada en un número reducido de dimensiones. Este comportamiento es indicativo de una mejora en la calidad de la información utilizada para el análisis multivariado.

De manera consistente con los resultados de PCA, el análisis de agrupamiento jerárquico evidenció una mayor coherencia en la formación de clústeres cuando se emplearon datos fusionados. Los dendrogramas obtenidos a partir de FTIR o Raman por separado mostraron agrupamientos menos definidos. Por el contrario, la integración de ambas fuentes espectrales permitió obtener clústeres más compactos y representativos, lo que sugiere que la similitud entre muestras es mejor descrita cuando se consideran simultáneamente ambas técnicas espectroscópicas. Estos resultados refuerzan la utilidad de la fusión de

datos en análisis no supervisados orientados a la exploración y clasificación de muestras.

Un aspecto clave de coincidencia entre el presente trabajo y los estudios previos es el rol crítico del preprocesamiento espectral. Ahmmed et al[35]. destacan que la corrección de línea base, la normalización y la selección de regiones espectrales relevantes son etapas fundamentales para evitar la dominancia de una técnica sobre la otra durante la fusión de datos. En este sentido, los resultados obtenidos confirman que la aplicación de técnicas de preprocesamiento como la normalización, el suavizado Savitzky–Golay y el uso de derivadas espectrales contribuye significativamente a reducir la variabilidad instrumental y a resaltar diferencias químicas reales entre muestras, favoreciendo el desempeño de los modelos multivariados.

Resultados concordantes fueron reportados por Liu et al.[36], quienes aplicaron fusión de datos FTIR y Raman para la determinación simultánea de índices de calidad en aceites comestibles sometidos a procesos de oxidación térmica. En dicho estudio, los autores demostraron que los modelos basados en datos fusionados presentan mejores indicadores estadísticos, como mayores coeficientes de determinación y menores errores de predicción, en comparación con aquellos construidos a partir de una sola técnica espectroscópica. Aunque el objetivo del trabajo de Liu et al. difiere en cuanto a la naturaleza de las muestras analizadas, los resultados obtenidos en ambos estudios confirman que la fusión de datos FTIR con Raman constituye una estrategia generalizable y eficaz para el análisis de sistemas complejos.

Asimismo, Robert et al[37]. evaluaron distintas estrategias de fusión de datos (nivel bajo, medio y alto) para combinar espectros Raman e infrarrojos, concluyendo que la fusión a nivel bajo ofrece un equilibrio favorable entre simplicidad, interpretabilidad y desempeño, siempre que se acompañe de un preprocesamiento adecuado. Esta observación respalda la estrategia adoptada en el presente trabajo, donde la concatenación directa de los datos espectrales permitió mejorar la discriminación entre muestras sin introducir una complejidad excesiva en el modelado.

Si bien los resultados obtenidos son alentadores, es importante reconocer algunas limitaciones del presente estudio. En primer lugar, el análisis se centró en un conjunto específico de muestras farmacéuticas, por lo que la extrapolación de los resultados a otros tipos de matrices debe realizarse con cautela. Además, la fusión de datos a nivel bajo incrementa la dimensionalidad del conjunto de datos, lo que puede requerir la implementación de estrategias adicionales de selección de variables o reducción de dimensionalidad en aplicaciones con un mayor número de muestras o variables espectrales.

Desde una perspectiva aplicada, el desarrollo de EspectroApp representa una contribución relevante al integrar en una única plataforma informática las etapas de preprocesamiento, análisis multivariado y fusión de datos espectroscópicos. Esta integración facilita la exploración y el análisis de datos complejos, reduce la dependencia de software costosos y promueve la adopción de estrategias avanzadas de análisis espectroscópico en

entornos académicos y de laboratorio. En este contexto, los resultados obtenidos refuerzan el potencial de EspectroApp como una herramienta accesible y robusta para el análisis multivariado de datos FTIR y Raman.

Finalmente, los hallazgos de este trabajo refuerzan conclusiones previas de la literatura que indican que la fusión de datos FTIR y Raman constituye una alternativa robusta, rápida y de bajo costo frente a métodos analíticos más complejos para el análisis multivariado, siempre que se acompañe de un preprocesamiento adecuado y una correcta estrategia de integración de datos [37]. De este modo, el presente estudio no solo confirma resultados previamente reportados, sino que los extiende al ámbito del desarrollo de herramientas computacionales orientadas al análisis espectroscópico integrado.

Capitulo 6

9. Conclusiones

5.1 Trabajos futuros

10. Trabajos Futuros

A partir de los resultados obtenidos en este estudio, se identifican diversas líneas de investigación y desarrollo que podrían fortalecer y ampliar el alcance del trabajo realizado:

- **Explorar técnicas adicionales de fusión de datos.** Incluir estrategias de fusión a nivel de características (Feature-Level Fusion) y fusión a nivel de decisiones (Decision-Level Fusion), que permitirían comparar el rendimiento de diferentes arquitecturas de integración y optimizar la combinación de información espectral.
- **Aplicar algoritmos avanzados de aprendizaje automático.** Implementar modelos supervisados como SVM, Random Forest o redes neuronales profundas para evaluar si la fusión FTIR–Raman puede mejorar aún más el rendimiento de clasificación o predicción en sistemas químicos complejos.
- **Evaluar la metodología en otros tipos de materiales.** Aplicar la fusión FTIR–Raman a polímeros, compósitos, biológicos, agroquímicos u otros sistemas donde la complementariedad vibracional pueda aportar mejoras sustanciales en análisis multicomponente.
- **Estudiar el impacto del ruido y las variaciones instrumentales.** Simular diferentes niveles de ruido, fluorescencia o condiciones de medición, con el fin de analizar la robustez de la fusión frente a perturbaciones externas.

En conjunto, estas líneas de trabajo permitirán consolidar la fusión FTIR–Raman como una herramienta avanzada para el análisis de datos espectroscópico, así como ampliar la utilidad práctica de *EspectroApp* en entornos de investigación y control de calidad.

Referencias

- [1] Elena Hayes, Derek Greene, Colm O'Donnell, Norah O'Shea y Mark A. Fenelon. "Spectroscopic technologies and data fusion: Applications for the dairy industry". En: *Frontiers in Nutrition* 9 (2023), pág. 1074688. DOI: 10.3389/fnut.2022.1074688. URL: <https://doi.org/10.3389/fnut.2022.1074688>.
- [2] F. Castanedo. "A review of data fusion techniques". En: *The Scientific World Journal* 2013 (2013), pág. 704504. DOI: 10.1155/2013/704504.
- [3] A. Biancolillo. "Data fusion strategies in food analysis". En: *Data Handling in Science and Technology*. Ed. por M. Cocchi. Elsevier, 2019, págs. 271-310. DOI: 10.1016/B978-0-444-63984-4.00010-7.
- [4] T. Casian, B. Nagy, B. Kovács, D. Galata, E. Hirsch y A. Farkas. "Challenges and opportunities of implementing data fusion in process analytical technology: a review". En: *Molecules* 27.15 (2022). DOI: 10.3390/molecules27154846.
- [5] Z.-Y. Zhang. "The statistical fusion identification of dairy products based on extracted Raman spectroscopy". En: *RSC Advances* 10 (2020), págs. 29682-29687. DOI: 10.1039/D0RA06318E.
- [6] L. Huang, J. Zhao, Q. Chen e Y. Zhang. "Nondestructive Measurement of Total Volatile Basic Nitrogen (TVB-N) in Pork Meat by Integrating near Infrared Spectroscopy, Computer Vision and Electronic Nose Techniques". En: *Food Chemistry* 145 (2014), págs. 228-236. DOI: 10.1016/j.foodchem.2013.06.073.
- [7] Bo Li, Lu Rong, Qing Shi, Wei Zhang, Yanfei Xu y Meng Sun. "Comparison of Different Preprocessing Methods for Raman Spectroscopy". En: *Applied Spectroscopy* 74.9 (2020), págs. 1101-1112. DOI: 10.1177/0003702820923991. URL: <https://doi.org/10.1177/0003702820923991>.
- [8] Å. Rinnan, F. van den Berg y S. B. Engelsen. "Review of the Most Common Preprocessing Techniques for Near-infrared Spectra". En: *Trends in Analytical Chemistry* 28.10 (2009), págs. 1201-1222. DOI: 10.1016/j.trac.2009.07.007.
- [9] A. Savitzky y M. J. E. Golay. "Smoothing and Differentiation of Data by Simplified Least Squares Procedures". En: *Analytical Chemistry* 36.8 (1964), págs. 1627-1639. DOI: 10.1021/ac60214a047.
- [10] R. Gautam, S. Vanga, F. Ariese y S. Umashathy. "Review of multidimensional data processing approaches for Raman and infrared spectroscopy". En: *EPJ Techniques and Instrumentation* 2.1 (2015). DOI: 10.1140/epjti/s40485-015-0018-6.
- [11] Steven W. Smith. *The Scientist and Engineer's Guide to Digital Signal Processing*. First. San Diego, CA: California Technical Publishing, 1997. Cap. 15. URL: <http://www.dspguide.com/>.

- [12] J. Kong y S. Yu. “Fourier Transform Infrared Spectroscopic Analysis of Protein Secondary Structures”. En: *Acta Biochimica et Biophysica Sinica* 39.8 (2007), págs. 549-559. DOI: 10.1111/j.1745-7270.2007.00320.x.
- [13] C. A. Lieber y A. Mahadevan-Jansen. “Automated Method for Subtraction of Fluorescence from Biological Raman Spectra”. En: *Applied Spectroscopy* 57.11 (2003), págs. 1363-1367. DOI: 10.1366/000370203322554518.
- [14] J. Végh. “Baseline Correction for XPS Spectra Based on a Novel Iterative Procedure”. En: *Surface and Interface Analysis* 38.5 (2006), págs. 461-466. DOI: 10.1002/sia.2275.
- [15] D. A. Shirley. “High-Resolution X-Ray Photoemission Spectrum of the Valence Bands of Gold”. En: *Physical Review B* 5.12 (1972), págs. 4709-4714. DOI: 10.1103/PhysRevB.5.4709.
- [16] B. C. Smith. *Fundamentals of Fourier Transform Infrared Spectroscopy*. CRC Press, 2011.
- [17] E. Smith y G. Dent. *Modern Raman Spectroscopy: A Practical Approach*. Wiley, 2019.
- [18] C. V. Raman. “A New Radiation”. En: *Indian Journal of Physics* 1.1 (1928), págs. 377-385.
- [19] D. A. Long. “Raman Spectroscopy: An Introduction”. En: *Chemistry International* 24.4 (2002), págs. 24-29. DOI: 10.1515/CI.2002.24.4.24.
- [20] A. Hashimoto et al. “Complementary Vibrational Spectroscopy”. En: *Microscopy* (2019).
- [21] H. Lösel, J. Brockelt, F. Gärber, J. Teipel, T. Kuballa, S. Seifert y M. Fischer. “Comparative Analysis of LC-ESI-IM-qToF-MS and FT-NIR Spectroscopy Approaches for the Authentication of Organic and Conventional Eggs”. En: *Metabolites* 13 (2023), pág. 882. DOI: 10.3390/metabo13100882.
- [22] Peter Larkin. *Infrared and Raman Spectroscopy: Principles and Spectral Interpretation*. 2nd. Elsevier, 2017. ISBN: 978-0128041628.
- [23] D. Preadi et al. “Applications of FTIR Spectroscopy in Geosciences”. En: *Vibrational Spectroscopy* 75 (2014), págs. 1-12. DOI: 10.1016/j.vibspec.2014.08.003.
- [24] Yukihiro Ozaki et al. *Molecular Spectroscopy: Modern Research*. Springer, 2021. ISBN: 9789811560797.
- [25] I. T. Jolliffe. *Principal Component Analysis*. Springer, 2002.
- [26] M. Ringné. “What is Principal Component Analysis (PCA)?” En: *Nature Biotechnology* 26.3 (2008), págs. 303-304. DOI: 10.1038/nbt0308-303.

- [27] Y. Hong, N. Birse, B. Quinn, Y. Li, W. Jia, P. McCarron, D. Wu, G. R. Da Silva, L. Vanhaecke, S. Van Ruth et al. “Data Fusion and Multivariate Analysis for Food Authenticity Analysis”. En: *Nature Communications* 14 (2023), pág. 3309. DOI: 10.1038/s41467-023-39085-7.
- [28] L. van der Maaten y G. E. Hinton. “Visualizing Data Using t-SNE”. En: *Journal of Machine Learning Research* 9 (2008), págs. 2579-2605.
- [29] R. Ríos-Reina, S. M. Azcarate, J. M. Camiña y H. C. Goicoechea. “Multi-Level Data Fusion Strategies for Modeling Three-Way Electrophoresis Capillary and Fluorescence Arrays Enhancing Geographical and Grape Variety Classification of Wines”. En: *Analytica Chimica Acta* 1126 (2020), págs. 52-62. DOI: 10.1016/j.aca.2020.05.052.
- [30] S. C. Johnson. “Hierarchical Clustering Schemes”. En: *Psychometrika* 32.3 (1967), págs. 241-254. DOI: 10.1007/BF02289588.
- [31] B. S. Everitt, S. Landau, M. Leese y D. Stahl. *Cluster Analysis*. 5.^a ed. Wiley, 2011.
- [32] F. Murtagh y P. Contreras. “Algorithms for hierarchical clustering: an overview”. En: *WIREs Data Mining and Knowledge Discovery* 2.1 (2012), págs. 86-97.
- [33] J. H. Ward. “Hierarchical Grouping to Optimize an Objective Function”. En: *Journal of the American Statistical Association* 58.301 (1963), págs. 236-244. DOI: 10.1080/01621459.1963.10500845.
- [34] Aidan A. Gowen, Colm P. O'Donnell, Patrick J. Cullen, Gerard Downey y Jesus M. Frias. “Hyperspectral Imaging – An Emerging Process Analytical Tool for Food Quality and Safety Control”. En: *TrAC Trends in Analytical Chemistry* 30.7 (2011), págs. 1196-1212. DOI: 10.1016/j.trac.2011.03.001.
- [35] Fatema Ahmmed, Daniel P. Killeen, Keith C. Gordon y Sara J. Fraser-Miller. “Rapid Quantitation of Adulterants in Premium Marine Oils by Raman and IR Spectroscopy: A Data Fusion Approach”. En: *Molecules* 27.14 (2022), pág. 4534. DOI: 10.3390/molecules27144534. URL: <https://doi.org/10.3390/molecules27144534>.
- [36] Huan Liu, Yi Chen, Ce Shi, Xinting Yang y Donghai Han. “FT-IR and Raman spectroscopy data fusion with chemometrics for simultaneous determination of chemical quality indices of edible oils during thermal oxidation”. En: *LWT - Food Science and Technology* 119 (2020), pág. 108906. DOI: 10.1016/j.lwt.2019.108906. URL: <https://doi.org/10.1016/j.lwt.2019.108906>.
- [37] C. Robert, W. Jessep, J. J. Sutton, T. M. Hicks, M. Loeffen, M. Farouk, Sara J. Fraser-Miller y Keith C. Gordon. “Evaluating Low-, Mid- and High-Level Fusion Strategies for Combining Raman and Infrared Spectroscopy for Quality Assessment of Red Meat”. En: *Food Chemistry* 361 (2021), pág. 130154. DOI: 10.1016/j.

foodchem.2021.130154. URL: <https://doi.org/10.1016/j.foodchem.2021.130154>.