



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA

DESARROLLO Y EVALUACIÓN DE UN SISTEMA DE
RECOMENDACIÓN EVOLUTIVO Y PROBABILÍSTICO
MULTIOBJETIVO DE MULTIPOBLACIÓN, BASADO
EN MÉTODOS DE CLUSTERIZACIÓN Y
ALGORITMOS GENÉTICOS

TRABAJO FINAL DE GRADO

OSVALDO JOSÉ CAJE DUARTE

SAN LORENZO - PARAGUAY

2024



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA

DESARROLLO Y EVALUACIÓN DE UN SISTEMA DE
RECOMENDACIÓN EVOLUTIVO Y PROBABILÍSTICO
MULTIOBJETIVO DE MULTIPOBLACIÓN, BASADO
EN MÉTODOS DE CLUSTERIZACIÓN Y
ALGORITMOS GENÉTICOS

TRABAJO FINAL DE GRADO

Autor:

Oswaldo José Cajé Duarte

Tutor:

D.Sc Ing. Christian von Lücken

SAN LORENZO - PARAGUAY

2024

Dedicatoria

A mis padres, cuyo amor y esfuerzos han sido el pilar fundamental que me ha permitido alcanzar esta etapa y hacer realidad este sueño.

Oswaldo Cajé

Agradecimientos

A mi hermana, compañeros y amigos, que me apoyaron en distintas áreas hasta alcanzar este objetivo.

A mi tutor D.Sc. Ing. Christian von Lücken, por su dedicación y esfuerzo en cada reunión y corrección de este trabajo, siempre apuntando a mejorarlo y brindándome orientaciones enriquecedoras durante todo el proceso.

Resumen

Los sistemas de recomendación son herramientas diseñadas para ofrecer sugerencias de elementos enfocándose ya sea en uno o varios objetivos simultáneamente. Cuando se toman en cuenta múltiples objetivos, generalmente estos se encuentran en conflicto entre sí, por lo cual se exploran diversos métodos que sean capaces de encontrar soluciones óptimas tomando en cuenta todos los objetivos al mismo tiempo, como por ejemplo el algoritmo HP-MOEA que es un sistema de recomendación comercial con el objetivo de optimizar las ganancias comerciales al mismo tiempo que la novedad para el usuario. En este trabajo, utilizando métodos de clusterización y algoritmos genéticos se propone un sistema de recomendación evolutivo multi-objetivo de multipoblación, el cual es una extensión al sistema de recomendación HP-MOEA y los resultados son comparados a través del espacio objetivo cubierto. El algoritmo presentado en este trabajo obtiene una mejor media aritmética del hipervolumen en comparación a HP-MOEA.

Índice general

Dedicatoria	I
Agradecimientos	I
Resumen	II
Índice de Figuras	VII
Índice de tablas	IX
Acrónimos y Símbolos	IX
1. Introducción	1
1.1. Objetivos	5
1.1.1. Objetivo general	5
1.1.2. Objetivos específicos	5
1.2. Organización del Trabajo	5
2. Sistemas de recomendación: Clasificación y Optimización Multiobjetivo	7
2.1. Clasificación de sistemas de recomendación	7
2.2. Optimización multiobjetivo en sistemas de recomendación	9
2.2.1. Dominancia de Pareto	9
2.2.2. Conjunto óptimo de Pareto	10
2.2.3. Frente de Pareto	11
2.2.4. Hipervolumen	11

2.3. Algoritmos Genéticos Multiobjetivo	12
2.3.1. Operadores genéticos	13
2.3.2. NSGA-II	15
2.3.3. SMS-EMOA	17
3. Hybrid Probabilistic Multi Objective Evolutionary Algorithm	19
3.1. Técnicas evolutivas utilizadas	19
3.2. Framework de HP-MOEA	22
3.3. Objetivos a optimizar	25
3.3.1. Total Expected Profit	26
3.3.2. Novelty	27
4. Algoritmo Propuesto	29
4.1. K-means	30
4.1.1. Método del codo	31
4.2. Población inicial	33
4.2.1. Individuo max profit	34
4.2.2. Individuo max novelty	34
4.2.3. Individuos aleatorios	35
4.3. Operadores genéticos	35
4.3.1. Mutación	35
4.3.2. Cruce	36
4.4. Fitness	36
4.4.1. Normalización	36
4.5. Opciones de películas para el usuario	37
4.6. Arquitectura de la población	38
5. Análisis experimental	42
5.1. Conjunto de datos	42
5.2. Cantidad de clústeres	43
5.3. Configuraciones	43

<i>ÍNDICE GENERAL</i>	VI
5.4. Resultados	46
6. Conclusiones y trabajos futuros	51
6.1. Conclusiones	51
6.2. Trabajos futuros	54
Bibliografía	55

Índice de figuras

2.1. Conjunto de soluciones en un espacio objetivo	10
2.2. Ejemplo del hipervolumen	12
2.3. Ciclo evolutivo en los algoritmos genéticos	14
2.4. Selección de la población	16
2.5. Ordenamiento no dominado (a) y distancia de hacinamiento (b) . .	17
2.6. Ejemplo de contribución al hipervolumen	18
3.1. Operador de cruce aplicando la probabilidad genética en HP-MOEA	21
3.2. Definición de un individuo en HP-MOEA	23
3.3. Framework de HP-MOEA	24
4.1. Agrupación en K-means	31
4.2. Codo en la gráfica, para K=4	32
4.3. Definición de un individuo	33
4.4. Ejemplo del individuo max profit	34
4.5. Ejemplo del individuo max novelty	35
4.6. Ejemplo del operador de mutación	35
4.7. Opciones de películas para un usuario	38
4.8. Arquitectura multipoblación del algoritmo propuesto	39
4.9. Arquitectura de la población de HP-MOEA	40
4.10. Flujo general del algoritmo propuesto	41
5.1. Tabla de calificaciones del dataset de movielens	43
5.2. Gráfico del método del codo del algoritmo propuesto	44

5.3. Lista generada para el clúster N°4	49
---	----

Índice de tablas

5.1. Comparación de parámetros de algoritmos	44
5.2. Media aritmética del hipervolumen de HP-MOEA y algoritmo pro- puesto	46
5.3. Resultados de HP-MOEA	47
5.4. Resultados del algoritmo propuesto	47
5.5. Comparación combinada de resultados HP-MOEA y el algoritmo pro- puesto.	48

Acrónimos y Símbolos

NSGA-II	Non-dominated Sorting Genetic Algorithm II
GA	Genetic Algorithm
MOEA	Multi-Objective Evolutionary Algorithm
HP-MOEA	Hybrid Probabilistic Multi-Objective Evolutionary Algorithm
EvoRecSys	Evolutionary Recommender System
MOEA-ProbS	Multi-Objective Evolutionary Algorithm with Probabilistic Spreading Method
PMOEA	Probabilistic Multi-Objective Evolutionary Algorithm
MOEA-EPG	Multi-Objective Personalized Recommendation Algorithm using Extreme Point Guided Evolutionary Computation
MF	Matrix Factorization
RRSGA	Revolutionary Recommender System with Genetic Algorithm
EBMRS-WPS	Emotion Based Music Recommendation System using Wearable Physiological Sensors
SMS-EMOA	S-Metric Selection Evolutionary Multi-Objective Algorithm

Capítulo 1

Introducción

En el contexto del rápido crecimiento del comercio electrónico, servicios de streaming y redes sociales, los sistemas de recomendación han adquirido un papel fundamental en la mejora de la experiencia del usuario y en la maximización de los ingresos empresariales [1]. Estos sistemas son herramientas diseñadas para ofrecer elementos relevantes para los usuarios, basándose típicamente en la interacción previa entre los individuos y los elementos recomendados [2], tales como los que utilizan Netflix [3] y Amazon [4].

Existen varios desafíos a los que se enfrentan los sistemas de recomendación [5]. Uno de los principales es el inicio en frío (cold start) [6], que ocurre cuando no hay suficiente información histórica para hacer recomendaciones precisas [2]. Este problema es frecuente cuando se introducen nuevos elementos en el sistema, ya que los mismos carecen de calificaciones previas, lo que dificulta identificar el nivel interés de cada cliente sobre los mismos [6]. De manera similar, este problema también se presenta con la incorporación de nuevos usuarios para los cuales se dificulta la personalización de las recomendaciones al no tener un historial anterior en el sistema [7].

Junto con el inicio en frío, los sistemas de recomendación también corren el riesgo de la sobre-especialización, que puede resultar en una falta de novedad dentro de las sugerencias realizadas al usuario [8]. Este fenómeno ocurre cuando los sistemas no tienen forma de descubrir algo nuevo y sus recomendaciones sólo son relacionadas

a elementos sobre los cuales usuario ya ha demostrado interés [8]. Si no se toma en cuenta la novedad en las sugerencias, los usuarios podrían aburrirse al recibir constantemente recomendaciones similares a las que ya han tenido anteriormente, afectando negativamente la experiencia del usuario [2].

La literatura reporta varios algoritmos que buscan optimizar la experiencia del usuario al recibir recomendaciones más relevantes y útiles, evaluando su rendimiento a través de distintos criterios [9]. A continuación se citan algunos de estos:

1. Precisión de las recomendaciones [2]: se refiere al porcentaje de elementos recomendados que realmente resultan ser relevantes (es decir, consumidos por el usuario). Esto implica que la precisión mide el grado en que las recomendaciones coinciden con las preferencias reales del usuario.
2. Diversidad de los elementos recomendados [10]: es la diferencia entre los elementos recomendados. Asegura que los usuarios reciban una variedad de recomendaciones en lugar de solo sugerencias similares entre sí [2]. Esta métrica busca evitar la repetitividad y mejorar la satisfacción del usuario al ofrecerle una gama más amplia de opciones, con lo cual no solo mejora la experiencia del usuario, sino que también aborda el problema de la sobre-especialización al introducir elementos variados [8].
3. Novedad para el usuario [2]: evalúa la probabilidad de que el sistema sugiera elementos que el usuario no conoce o no ha visto antes. Las recomendaciones novedosas a menudo aumentan la capacidad del usuario para descubrir elementos que pueden gustarle o no, de los cuales previamente no tenía conocimiento [2]. Sin embargo, estas recomendaciones novedosas implican un mayor grado de incertidumbre sobre si serán bien recibidas por el usuario, en comparación con aquellas basadas en elementos previamente conocidos, lo que genera un conflicto entre la innovación en las recomendaciones y la aceptación del usuario, pudiendo resultar en un rechazo de parte del mismo [11].
4. Ganancia o profit [6]: indica el valor comercial del elemento en el sistema. En varios casos, los elementos más consumidos son los que generan menos

ganancias para el comerciante, y los elementos menos frecuentes producen las mayores ganancias [2]. Un sistema de recomendación comercial espera obtener altas ganancias y no solamente recomendaciones precisas, pero generalmente estas dos métricas están en conflicto, ya que un elemento más valioso para el comerciante suele ser menos popular en comparación a uno que produce mayores ganancias [6].

Los primeros sistemas de recomendación se basaron principalmente en el Filtrado Colaborativo y Filtrado Basado en Contenido [12]. El Filtrado Colaborativo utiliza datos de comportamiento de otros usuarios para realizar recomendaciones al usuario objetivo, aprovechando las similitudes en sus comportamientos [5]. Empresas como Amazon han estado utilizando el Filtrado Colaborativo para recomendar productos a sus clientes [4], mientras que Netflix [3] impulsó avances en esta tecnología mediante el concurso Netflix Prize, ofreciendo un millón de dólares como incentivo para mejorar su sistema de recomendación [12].

El Filtrado Basado en Contenido se enfoca en obtener los intereses del usuario a través de las características o descripciones de los elementos que ya han sido seleccionados por el mismo, recomendando artículos similares a aquellos en los que este ya ha mostrado interés [6].

Con el tiempo, en el desarrollo de los sistemas de recomendación se han incorporado otras técnicas como el Aprendizaje Automático (Machine Learning) y los Algoritmos Evolutivos (EAs) [1]. Estas mismas han sido aplicadas para diversos objetivos como por ejemplo asistir a los usuarios a capturar imágenes de alta calidad, recomendar música, reducir recomendaciones innecesarias o aumentar la precisión [5].

El Aprendizaje Automático se centra en el desarrollo de algoritmos que permiten a las computadoras aprender a partir de datos, y realizar predicciones o tomar decisiones basadas en ellos [13]. En el contexto de los sistemas de recomendación, el Aprendizaje Automático es utilizado para analizar grandes volúmenes de datos sobre el comportamiento del usuario, permitiendo predecir sus preferencias [1].

Los Algoritmos Evolutivos son un conjunto de métodos inspirados por la natu-

raleza [1]. Un algoritmo evolutivo comienza con una población inicial de soluciones candidatas al problema a resolver, la cual es optimizada a lo largo del ciclo evolutivo en base al objetivo de dicho problema [1].

Cada solución generada por un un Algoritmo Evolutivo es evaluada mediante una función de aptitud, que determina su probabilidad de supervivencia [1]. Las soluciones con mejor desempeño tienen mayor probabilidad de sobrevivir y reproducirse, transmitiendo sus características a las siguientes generaciones [13]. Con el paso del tiempo, la población gradualmente mejora de manera iterativa, acercándose progresivamente hacia mejores soluciones [14].

En los sistemas de recomendación, los algoritmos evolutivos no solo optimizan soluciones de acuerdo a una métrica, sino que también son capaces de abordar múltiples objetivos simultáneamente, como la novedad y la precisión de las sugerencias [1]. Al tener en cuenta múltiples objetivos, los sistemas de recomendación logran ofrecer sugerencias enfocándose no sólo en mejorar la precisión, sino también otros objetivos como por ejemplo la novedad y las ganancias comerciales [5].

Un ejemplo de recomendación multiobjetivo es el trabajo Hybrid Probabilistic Multiobjective Evolutionary Algorithm (HP-MOEA) que propone un sistema de recomendación comercial optimizando al mismo tiempo las ganancias comerciales, la precisión y la novedad de las sugerencias [6]. Este trabajo es presentado con mayor detalle en el Capítulo 3.

Dado que el sistema de recomendación HP-MOEA ha demostrado ser efectivo en la generación de sugerencias comerciales [6], y considerando el potencial de los algoritmos genéticos discutidos previamente, en el trabajo presentado en este libro se ha propuesto una optimización a dicho sistema de recomendación. Los resultados muestran que el algoritmo propuesto es efectivo para mejorar la precisión, las ganancias y la novedad en comparación con otros algoritmos, como el Filtrado Colaborativo [15], MOEA-ProbS [16], PMOEA [17], MOEA-EPG [18] y MF [19].

En este trabajo se utiliza el Filtrado Colaborativo en conjunto con el algoritmo K-means descrito en el Capítulo 4, para desarrollar un algoritmo evolutivo multipoblación. En este enfoque, las poblaciones evolucionan independientemente y cuentan

con sus propios parámetros óptimos, explorando la generación de soluciones optimizadas para cada grupo de usuarios.

Este nuevo trabajo también abre camino a futuras investigaciones, permitiendo estudiar nuevas direcciones. Entre las posibles líneas de investigación, se sugiere la definición de objetivos distintos para cada población, a modo que analizar la generación de un conjunto óptimo de soluciones para cada uno de los objetivos establecidos. Posteriormente, se sugiere elegir la población cuyo balance entre ganancia y novedad sea el más favorable entre las distintas soluciones optimizadas.

1.1. Objetivos

1.1.1. Objetivo general

Mejorar el algoritmo HP-MOEA [6] para optimizar las soluciones del sistema de recomendación con el propósito de conseguir mejores resultados en las recomendaciones del usuario.

1.1.2. Objetivos específicos

1. Realizar un análisis bibliográfico exhaustivo sobre las técnicas de algoritmos evolutivos aplicadas en sistemas de recomendación.
2. Definir los objetivos de optimización específicos para el sistema de recomendación.
3. Modelar los datos de entrada y definir las restricciones del problema integrando técnicas de agrupación con K-means y filtrado colaborativo.
4. Evaluar el rendimiento del algoritmo propuesto en comparación a HP-MOEA utilizando métricas de rendimiento basadas en los objetivos de optimización.

1.2. Organización del Trabajo

El siguiente esquema hace referencia a cómo se encuentran estructurados los capítulos de este libro:

- **Capítulo 1: Justificación**

Presenta una introducción a los sistemas de recomendación, su utilidad y algunos de los problemas a los que se enfrentan, y detalla el objetivo general y los objetivos específicos .

- **Capítulo 2: Sistemas de recomendación**

Describe diferentes enfoques en los que se basan los sistemas de recomendación para ofrecer elementos y desarrolla el problema de la optimización multi-objetivo en los sistemas de recomendación junto con los algoritmos genéticos aplicados en dichos sistemas.

- **Capítulo 3: Hybrid Probabilistic Multi Objective Evolutionary Algorithm**

Se aborda el algoritmo HP-MOEA para recomendaciones comerciales, que es la base del algoritmo presentado en este trabajo y se presentan los operadores genéticos, el marco de trabajo, las técnicas evolutivas utilizadas y los objetivos que optimiza.

- **Capítulo 4: Algoritmo propuesto**

Describe el algoritmo presentado en este trabajo, explica cómo se utiliza K-means para agrupar a los usuarios, la generación de la población inicial, la estructura de la población, los operadores genéticos utilizados, las diferencias con HP-MOEA y las posibilidades de recomendaciones para el usuario.

- **Capítulo 5: Análisis experimental**

Presenta los resultados obtenidos con el algoritmo propuesto y los compara con los resultados del trabajo HP-MOEA. Además, evalúa brevemente la lista de recomendación generada.

- **Capítulo 6: Conclusiones y Trabajos Futuros**

Detalla las conclusiones en base a los objetivos del trabajo presentado en este libro, y discute las posibles direcciones para futuros trabajos de investigación.

Capítulo 2

Sistemas de recomendación: Clasificación y Optimización Multiobjetivo

Los sistemas de recomendación están diseñados para predecir las preferencias o gustos de un usuario, ya sea a través de interacciones directas (como clics, compras, o calificaciones) o de otros usuarios con comportamientos similares [2].

Hoy en día, los sistemas de recomendación se utilizan ampliamente en plataformas de comercio electrónico, servicios de streaming, redes sociales, e incluso en el ámbito médico [20], para mejorar la experiencia del usuario mediante la personalización de productos o contenidos [21].

En este capítulo, se describen los tipos de sistemas de recomendación, incluyendo el filtrado colaborativo, el filtrado basado en contenido, los enfoques híbridos y otras técnicas basadas en diferentes métodos. Además, se presenta una discusión sobre los algoritmos evolutivos multiobjetivo aplicados en la construcción de estos sistemas.

2.1. Clasificación de sistemas de recomendación

Los sistemas de recomendación se basan en diferentes enfoques para generar recomendaciones, los más comunes incluyen [1]:

1. Filtrado Colaborativo [12]: se basa en el análisis de la interacción del usuario con el sistema, como las calificaciones o comportamientos de otros usuarios del sistema. Existen dos tipos de métodos comúnmente utilizados en el filtrado colaborativo [2]:
 - a) Filtrado Basado en Usuarios [12]: Genera recomendaciones basadas en usuarios que tienen comportamientos de calificaciones similares.
 - b) Filtrado Basado en Contenido [1]: las recomendaciones se generan analizando las características de los elementos que el usuario prefirió en el pasado y se sugieren otros que comparten características similares. Este enfoque se centra en las propiedades del contenido, como las categorías, descripciones o atributos de los elementos [2].
2. Sistemas Demográficos [9]: realizan recomendaciones basándose en características demográficas del usuario, tales como la edad, el género o la ubicación geográfica, basándose en la premisa de que los usuarios con perfiles demográficos similares podrían compartir intereses comunes.
3. Sistemas Sensibles al Contexto [9]: Ajustan sus recomendaciones basándose en la información que define la situación específica en la que se realizan las recomendaciones. Las situaciones pueden incluir factores como la hora del día, la ubicación geográfica del usuario o su información social, por ejemplo si existe algún día festivo o conmemoración que afecte la actividad del cliente [2].
4. Sistemas Basados en Factores Latentes [1]: utilizan técnicas como la factorización de matrices para identificar patrones ocultos en los datos de preferencia del usuario [22]. A través de la descomposición de las interacciones en factores latentes el sistema predice las calificaciones [22].
5. Sistemas Híbridos [2]: Combinan múltiples técnicas de recomendación, como la combinación de filtrado colaborativo y basado en contenido, con el fin de aumentar la precisión y la cobertura de las recomendaciones, aprovechando las fortalezas de cada una de las técnicas incluidas.

6. Métodos Basados en el Conocimiento [1]: Estos sistemas utilizan un enfoque basado en reglas para recomendar elementos que satisfacen necesidades específicas del usuario, basándose en el conocimiento explícito tanto de las preferencias del usuario como de las características de los elementos recomendados.

2.2. Optimización multiobjetivo en sistemas de recomendación

Los sistemas de recomendación multiobjetivo producen recomendaciones optimizadas por múltiples métricas, como por ejemplo podrían ser la precisión, la novedad y la diversidad [9].

Los problemas de optimización multiobjetivo consisten en una variedad de objetivos que suelen estar en conflicto entre sí [6]. Suponiendo un problema de maximización, formalmente tenemos la siguiente definición [6]:

$$\text{máx } F(x) = (f_1(x), f_2(x), \dots, f_m(x)), \quad \text{tal que } x \in \Omega \subset R^n \quad (2.1)$$

donde m es la cantidad de funciones objetivo, $x = (x_1, x_2, \dots, x_n)$ es un vector de decisión n -dimensional en el espacio R^n y Ω es el espacio de decisión [9].

Como usualmente los objetivos se contraponen entre sí esto dificulta encontrar una solución con todos los valores de los objetivos al máximo, por lo cual se pueden comparar las soluciones a un problema multiobjetivo través del concepto de la dominancia de Pareto [6].

2.2.1. Dominancia de Pareto

Con la presencia de múltiples objetivos en un problema, en vez de tener una única solución óptima pueden aparecer un conjunto de estas, las cuales son conocidas como las soluciones óptimas de Pareto [23].

Una solución es llamada óptima de Pareto si no existe otra solución en el espacio objetivo que pueda dominarla [6]. La dominancia de Pareto se describe en los

siguientes términos: una solución A domina a otra solución B si A es al menos tan buena como B en todos los objetivos considerados, y mejor en al menos uno de ellos [24]. Esto último es expresado matemáticamente como [6]:

$$\forall i \in \{1, \dots, m\}, f_i(x_A) \geq f_i(x_B), \exists j \in \{1, \dots, m\}, f_j(x_A) > f_j(x_B). \quad (2.2)$$

donde f_i y f_j son las i -ésima y j -ésima funciones objetivo respectivamente, la solución $F(x_A)$ domina a $F(x_B)$ denotado como $F(x_A) \succ F(x_B)$.

En la Figura 2.1, se presenta un ejemplo de un conjunto de soluciones en un espacio objetivo con dos funciones a optimizar. La zona azul contiene a las soluciones que dominan a las que se encuentran en la zona roja superior derecha, que son las soluciones dominadas [25].




Figura 2.1: Conjunto de soluciones en un espacio objetivo [25]

2.2.2. Conjunto óptimo de Pareto

La mayoría de los problemas del mundo real en el contexto de los sistemas de recomendación trabajan con múltiples objetivos que a menudo entran en conflicto entre sí [6]. El objetivo es obtener un conjunto de soluciones donde ninguna solución

sea dominada por otra, la cual es conocida como el conjunto óptimo de Pareto [6].

Una solución forma parte del conjunto óptimo de Pareto si no existe ninguna otra solución que mejore al menos un objetivo sin empeorar otro [24]. En el contexto de los sistemas de recomendación, se utilizan algoritmos evolutivos multiobjetivo para encontrar múltiples soluciones óptimas de Pareto [24].

En la Figura 2.1 el conjunto óptimo de Pareto está formado por los puntos más cercanos a la curva que representa el Frente de Pareto [25].

2.2.3. Frente de Pareto

El frente de Pareto se refiere al conjunto de todas las soluciones no dominadas cuando se proyectan en el espacio de los objetivos [9]. En otras palabras, el frente de Pareto es la representación en el espacio objetivo de las soluciones que son óptimas de Pareto [6].

Un ejemplo del Frente de Pareto es presentado en la Figura 2.1. La curva atraviesa las soluciones en las áreas amarillas y azul, pasando por los puntos que representan las soluciones no dominadas [25].

2.2.4. Hipervolumen

El hipervolumen es una medida utilizada en optimización multiobjetivo que representa el volumen del espacio objetivo dominado por un conjunto de soluciones [6] e indica si un conjunto de soluciones no dominadas es mejor que otra [6].

La Figura 2.2 muestra un ejemplo de cómo se calcula el hipervolumen en un problema de dos objetivos f_1 y f_2 , cada punto negro en el gráfico representa una solución no dominada, es decir, una solución que pertenece al frente de Pareto [26]. Las áreas sombreadas (Vol. 1, Vol. 2, Vol. 3, Vol. 4) representan las porciones del espacio de los objetivos que están dominadas por estas soluciones, obteniendo el hipervolumen total a través de la suma de estas áreas [26].




Figura 2.2: Ejemplo del hipervolumen [26]

2.3. Algoritmos Genéticos Multiobjetivo

Los Algoritmos Genéticos comienzan con una población de posibles soluciones, que se somete a un proceso iterativo, donde se evalúa la aptitud de las soluciones en base a una función que determina qué tan cercana está cada solución al objetivo a optimizar [1]. A través de múltiples iteraciones, dichos algoritmos generan una nueva población de candidatos, con el objetivo de que cada generación sea progresivamente mejor [13].

Los sistemas de recomendación multiobjetivo tienen como propósito optimizar varias métricas de recomendación simultáneamente [9]. Para abordar este problema, se han utilizado Algoritmos Genéticos debido a su capacidad para encontrar soluciones de Pareto [9]. En estos sistemas, los conjuntos de recomendaciones evolucionan iterativamente, evaluándose según múltiples funciones objetivo [6].

Un ejemplo de la aplicación de algoritmos genéticos en sistemas de recomendación multiobjetivo es el trabajo HP-MOEA [6], que presenta un algoritmo probabilístico híbrido para sistemas de recomendación comerciales. Este enfoque utiliza unos algoritmos genéticos multiobjetivo que buscan optimizar la ganancia esperada y la novedad, logrando así recomendaciones novedosas para el usuario y a la vez

generando ganancias comerciales [6].

Además de HP-MOEA, existen otras aplicaciones de algoritmos genéticos en sistemas de recomendación multiobjetivo. Por ejemplo, RRS GA [8] se enfoca en la recomendación de películas, mejorando la diversidad del contenido sugerido para evitar la sobre-especialización. EvoRecSys [14] por otra parte está orientado a ofrecer recomendaciones de actividades físicas y hábitos alimenticios personalizados para mejorar la calidad de vida de los usuarios.

2.3.1. Operadores genéticos

Los Algoritmos Genéticos utilizan tres operadores principales: selección, cruce y mutación [13]. La selección determina qué individuos de la población sobrevivirán y se reproducirán en la siguiente generación, favoreciendo a aquellos con mejor desempeño de acuerdo a una función de aptitud [13].

La función de aptitud (fitness) es una métrica que determina las probabilidades de supervivencia de cada individuo en la población [13]. Dicha función refleja qué tan buena es la solución que representa un individuo en función de los objetivos del problema a resolver [6]. La aptitud de un individuo está directamente relacionada con su capacidad para resolver el problema, y las soluciones más aptas tienen más probabilidades de ser seleccionadas para reproducirse y generar descendencia [13].

El cruce es el proceso mediante el cual se intercambian segmentos de los cromosomas de dos individuos seleccionados, llamados padres, para producir descendientes [13]. Los cromosomas representan posibles soluciones al problema a resolver, y el intercambio de segmentos permite no solo explorar nuevas áreas del espacio de soluciones, sino también combinar las características más fuertes de los padres, con el objetivo de mejorar las soluciones generadas [13].

Finalmente, la mutación altera aleatoriamente algunos genes en los cromosomas de los descendientes, lo que permite explorar nuevas áreas del espacio de búsqueda y evita que el algoritmo quede atrapado en óptimos locales [13]. Los óptimos locales suponen un desafío porque representan puntos en el espacio de búsqueda donde todas las soluciones cercanas son inferiores, pero no garantiza que dicha solución

sea la mejor posible dentro del conjunto completo [9].

La Figura 2.3 representa el ciclo evolutivo de los algoritmos genéticos. En primer lugar se tiene la población de individuos, que son seleccionados a través de su función de aptitud en el proceso de selección, el cual es probabilístico [13]. En la selección, los individuos con mayor aptitud tienen más probabilidades de ser elegidos para pasar a la siguiente etapa [13]. Los sobrevivientes avanzan a las fases de cruce, recombinación y mutación, lo que da lugar a una nueva población de individuos [13]. Este ciclo evolutivo se repite iterativamente hasta que se cumpla una cierta condición de terminación [13].




Figura 2.3: Ciclo evolutivo en los algoritmos genéticos [13]

2.3.2. NSGA-II

El NSGA-II (Non-dominated Sorting Genetic Algorithm II) es un algoritmo evolutivo multiobjetivo diseñado para superar las limitaciones de su predecesor, el NSGA, y de otros algoritmos similares [23]. Su aplicación en sistemas de recomendación se basa en la capacidad del NSGA-II para manejar múltiples objetivos, como la precisión de las sugerencias, la diversidad y la novedad [6].

Características

El NSGA-II particiona y clasifica a la población en varios frentes de acuerdo con el nivel de dominancia, donde cada solución es comparada con las demás para determinar su nivel de no dominancia [23].

Para mantener la diversidad utiliza un operador de comparación basado en la densidad local de soluciones alrededor de un individuo en el espacio objetivo [23]. Las soluciones con una mayor distancia de hacinamiento son preferidas, lo que promueve la diversidad en la población [6].

Durante el proceso de selección, entre dos soluciones se prefiere aquella con un menor rango de no dominancia o si ambas soluciones están en el mismo frente se prefiere a la que tenga una mayor distancia de hacinamiento [6]. El rango de no dominancia se refiere a la clasificación de los individuos en los frentes de Pareto [23], como por ejemplo un primer contiene las soluciones no dominadas (rango 1), un segundo frente contiene soluciones dominadas únicamente por las del primer frente (rango 2), y así sucesivamente [6].

Selección de individuos para el cruce

Se utiliza un torneo binario para seleccionar los padres [23]. En cada torneo, se eligen dos individuos de la población de manera aleatoria, y se selecciona el individuo con menor rango de no dominancia, repitiéndose este proceso hasta que se hayan seleccionado suficientes padres para el cruce [23].

Reemplazo de la Población

Las poblaciones de padres e hijos se combinan en un conjunto temporal para luego realizar un proceso de ordenamiento no dominado, clasificando los individuos

según su frente de Pareto [23]. Los individuos del primer frente son preferidos, ya que representan las soluciones más aptas [6]. Si el número de individuos en el primer frente es menor que el tamaño de la población deseada, se incluyen todos y se procede a considerar los individuos en los siguientes frentes hasta completar la población [23]. En caso de que se alcance el límite de la población antes de completar un frente, se utiliza un criterio adicional basado en la distancia de hacinamiento, que es la medida en la que los individuos están espaciados entre sí, para mantener la diversidad y asegurar que los individuos seleccionados estén distribuidos uniformemente en el espacio de los objetivos [6].

La Figura 2.4 muestra el proceso de selección de la población. Los individuos en los primeros frentes son preferidos [27]. Sin embargo, al alcanzar el límite de la población, representado por la línea de puntos que atraviesa el frente 3 (F_3), se utiliza la distancia de hacinamiento (Figura 2.5) para seleccionar los individuos más espaciados entre sí, de modo que sean ellos los que pasen a la siguiente población [27].




Figura 2.4: Selección de la población [27]




Figura 2.5: Ordenamiento no dominado (a) y distancia de hacinamiento (b) [27]

2.3.3. SMS-EMOA

El SMS-EMOA (S-Metric Selection Evolutionary Multi-Objective Algorithm) combina ideas tomadas de otros algoritmos evolutivos multiobjetivo, como por ejemplo el NSGA-II, entre otras estrategias [28]. Este algoritmo se basa principalmente en las siguientes características [29]:

1. Se usa la clasificación no dominada como un criterio de clasificación y,
2. La contribución al hipervolumen se aplica como criterio de selección para descartar al individuo que menos contribuye en el frente de peor rango.

El SMS-EMOA, elimina solamente el individuo que menos contribuye al hipervolumen o el que tenga el mayor número de dominancia en cada generación, luego genera un nuevo individuo mediante operadores genéticos [6].

Características

El SMS-EMOA utiliza el algoritmo de clasificación no dominada del NSGA-II para particionar la población en varios frentes de acuerdo con el nivel de dominancia [29].

En el proceso de reducción de la población, se aplica el concepto de clasificación no dominada del NSGA-II para identificar el frente de peor rango y seleccionar el individuo que menos contribuye al hipervolumen para ser eliminado [29]. El objetivo

es mantener la calidad del conjunto de soluciones al asegurar que las soluciones no dominadas se mantengan en la población mientras se optimiza el hipervolumen cubierto por el conjunto de soluciones, preservando la diversidad [29].

En la Figura 2.6 se ejemplifica la contribución al hipervolumen. Las soluciones y_8 e y_9 pertenecen al segundo frente de Pareto R_2 . El área turquesa representa el hipervolumen dominado por y_8 e y_9 . Las áreas con rayas muestran las regiones en las que existen puntos que dominan a y_8 o y_9 respectivamente. Aunque ambas soluciones pertenecen al mismo frente, y_8 contribuye más significativamente al hipervolumen, cubriendo una mayor porción del espacio objetivo en comparación con y_9 [29].




Figura 2.6: Ejemplo de contribución al hipervolumen [29]

Reemplazo de la Población

Si existen individuos dominados, se reemplaza el que tenga el mayor número de dominancia. En el caso contrario, se reemplaza el individuo con la menor contribución al hipervolumen [6].

Capítulo 3

Hybrid Probabilistic Multi Objective Evolutionary Algorithm

El trabajo HP-MOEA [6] presenta el Algoritmo Evolutivo Probabilístico Híbrido Multi-Objetivo, el cual es un sistema de recomendación comercial. Este algoritmo introduce una función objetivo llamada ganancia esperada, que busca optimizar junto con la novedad de las recomendaciones [6].

3.1. Técnicas evolutivas utilizadas

HP-MOEA combina los algoritmos NSGA-II y SMS-EMOA, descritos en el Capítulo 2, para aprovechar sus fortalezas individuales en la maximización del hipervolumen y la preservación de la diversidad [6].

El NSGA-II es particularmente eficaz en las primeras etapas de la evolución, ya que permite un rápido incremento del hipervolumen y genera una amplia diversidad en las soluciones. Sin embargo, en las etapas tardías, este algoritmo puede quedar estancado en la generación de las soluciones. Esto se debe a que su mecanismo de selección tiende a concentrarse en ciertas regiones del frente de Pareto, lo que puede frenar la mejora continua del hipervolumen a pesar de que el proceso evolutivo sigue avanzando [6].

El algoritmo SMS-EMOA proporciona una mejora más consistente del hiper-

volumen en las etapas tardías del proceso evolutivo, ya que su enfoque se centra directamente en maximizar esta métrica. A pesar de que su rendimiento puede ser más lento en las primeras etapas, el algoritmo asegura una mayor convergencia y diversidad en las soluciones finales. Por esta razón se utiliza NSGA-II en las primeras etapas del proceso, donde se requiere un rápido incremento del hipervolumen, mientras que se recurre al SMS-EMOA en las etapas más avanzadas del proceso evolutivo [6].

HP-MOEA inicialmente utiliza el NSGA-II para aprovechar su incremento acelerado en el hipervolumen, y luego de un punto de inflexión, determinado por la falta de mejora del hipervolumen durante varias generaciones, el algoritmo cambia al SMS-EMOA para continuar mejorando el hipervolumen de manera constante [6].

El sistema de recomendación HP-MOEA introduce también una variación en el operador genético de cruce, basada en una probabilidad genética adaptativa. Este operador de cruce asigna probabilidades más altas a los individuos más fuertes, y probabilidades más bajas a los más débiles [6].

El proceso de cruce comienza haciendo que el individuo hijo herede los genes presentes en ambos padres. Posteriormente, se calcula la probabilidad genética de los padres, y con base en este valor, se determina qué genes de los padres se pasan al hijo. El operador de cruce actúa de la siguiente manera en base a la probabilidad genética [6]:

1. Se inicia calculando la probabilidad genética $\lambda(A, B)$ de los individuos padre A y B. Esta probabilidad determina qué genes serán heredados de cada padre.
2. El individuo hijo S hereda primero los genes en común que están presentes en ambos padres.
3. Para cada uno los genes distintos restantes, se genera un número aleatorio entre 0 y 1. Si este número es menor que $\lambda(A, B)$, el gen se hereda del padre A; de lo contrario, se hereda del padre B.

La Figura 3.1 ilustra gráficamente la aplicación del operador de cruce. El gen común en ambos padres, 02, es heredado directamente por el hijo. En la posición

Algoritmo 1 Operador de cruce de HP-MOEA [6]**Entrada:** individuos padres A y B **Salida:** individuo hijo S

```

1: Calcular la probabilidad genética  $\lambda(A, B)$ 
2: for  $i = 0$  to  $|U|$  do
3:   Heredar los genes comunes en  $A$  y  $B$  a  $S$ 
4:   while  $S$  tenga espacio para heredar más genes do
5:     if  $\text{rand}(0, 1) < \lambda(A, B)$  then
6:       Heredar siguiente gen distinto de  $A$  a  $S$ 
7:     else
8:       Heredar el siguiente gen distinto de  $B$  a  $S$ 
9:     end if
10:  end while
11: end for
12: return  $S$ 

```

2, el número aleatorio generado es de 0.6, menor a la probabilidad genética de 0.7, por lo que se hereda el gen del padre A. En la posición 3, el número aleatorio es 0.8, mayor a la probabilidad genética, lo que resulta en la herencia del gen del padre B. Finalmente, en la última posición, el número aleatorio es 0.3, menor a la probabilidad genética, por lo que el gen heredado proviene del padre A [6].




Figura 3.1: Operador de cruce aplicando la probabilidad genética en HP-MOEA [6]

Probabilidad genética

En la etapa de NSGA-II, $\lambda(A, B)$ se calcula utilizando los criterios de rango de no dominancia y la distancia de hacinamiento. Si los individuos tienen rangos diferentes, la probabilidad genética será mayor para el individuo con el rango menor, favoreciendo su selección. Si ambos individuos pertenecen al mismo rango, se asignará una probabilidad mayor al que tenga la mayor distancia de hacinamiento, promoviendo así la diversidad en la población [6]:

$$\lambda(A, B) = \begin{cases} \frac{\text{rank}(B)}{\text{rank}(A) + \text{rank}(B)} & \text{si } \text{rank}(A) \neq \text{rank}(B) \\ \frac{\text{dist}(A)}{\text{dist}(A) + \text{dist}(B)} & \text{si } \text{rank}(A) = \text{rank}(B) \end{cases} \quad (3.1)$$

donde $\text{rank}(A)$ y $\text{dist}(A)$ son el rango de no dominancia y la distancia de hacinamiento del individuo A , respectivamente.

En la etapa de SMS-EMOA, $\lambda(A, B)$ se calcula utilizando el rango de no dominancia, la contribución al hipervolumen y el número de individuos dominantes. En general, se prefiere al individuo con el rango menor. Si ambos individuos tienen el mismo rango, se selecciona al que tiene la mayor contribución al hipervolumen o el menor número de individuos dominantes. Si todas las soluciones son no dominantes, se utiliza la contribución al hipervolumen de cada solución. Si todos los individuos son no dominantes, se prefiere al individuo con el menor número de individuos dominantes [6]:

$$\lambda(A, B) = \begin{cases} \frac{\text{rank}(B)}{\text{rank}(A) + \text{rank}(B)} & \text{si } \text{rank}(A) \neq \text{rank}(B) \\ \frac{\varphi(A)}{\varphi(A) + \varphi(B)} & \text{si } \text{rank}(A) = \text{rank}(B) \text{ y } \varphi \text{ está disponible} \\ \frac{d(A)}{d(A) + d(B)} & \text{si } \text{rank}(A) = \text{rank}(B) \text{ y } \varphi \text{ no está disponible} \end{cases} \quad (3.2)$$

donde $\varphi(A)$ es la contribución al hipervolumen de A y $d(A)$ es el número de individuos que dominan a A .

3.2. Framework de HP-MOEA

En HP-MOEA, primeramente se procesan las entradas, que consisten en las calificaciones de los usuarios sobre los elementos. A partir de estos datos, se emplea una técnica de filtrado colaborativo, que es detallada más adelante, para calcular la puntuación esperada (predicted rating) de las películas que el usuario aún no ha calificado. Luego, se genera una población inicial compuesta por tres tipos de individuos [6]:

1. Un individuo que genere el máximo profit.
2. Un individuo que genere el máximo novelty.
3. El resto individuos generados de manera aleatoria.

En la Figura 3.2, se detalla cómo está estructurado un individuo en el trabajo HP-MOEA [6]. Este se compone de L películas para cada usuario del sistema, y cada película corresponde a un gen del individuo [6].

	Pelíc. 1	Pelíc. 2	Pelíc. 3	Pelíc. 4	Pelíc....	Pelíc. L
Usuario 1	15	44	32	56	...	03
Usuario 2	56	39	87	24	...	31
			...			
Usuario $ U $	99	54	37	267	...	81

Figura 3.2: Definición de un individuo en HP-MOEA [6]

Una vez generada la población inicial, se inicia el ciclo de iteraciones del algoritmo. Este ciclo se ejecuta hasta cumplir con la condición de terminación ($\text{Terminate} = 3000$), que se refiere a la cantidad de iteraciones. Durante las primeras etapas, se utiliza el NSGA-II para evolucionar la población, pero si después de 500 iteraciones consecutivas ($\text{Turn} = 500$) no se observa una mejora en la población, se cambia al algoritmo SMS-EMOA para continuar mejorando el hipervolumen [6]:




Figura 3.3: Framework de HP-MOEA [6]

Las calificaciones predichas o puntuaciones esperadas se obtienen mediante el filtrado colaborativo, las cuales posteriormente se utilizan para generar listas de recomendaciones y calcular el beneficio total esperado de las mismas. La fórmula para predecir las calificaciones se define de la siguiente manera [6]:

$$\tilde{r}_{u,i} = \frac{\sum_{v \in S_{u,k}} \text{sim}_{u,v} \times r_{v,i}}{\sum_{v \in S_{u,k}} \|\text{sim}_{u,v}\|} \quad (3.3)$$

donde:

- sim_{uv} es la similitud entre los usuarios u y v .
- S_{uk} es el conjunto de los k usuarios más similares a u .
- r_{vi} es la calificación dada por el usuario v al ítem i .

La similitud entre diferentes usuarios se determina utilizando la métrica de la similitud del coseno [6]:

$$\text{sim}_{u,v} = \frac{r_u \cdot r_v}{|r_u| \cdot |r_v|} \quad (3.4)$$

donde $\mathbf{r}_u$ y $\mathbf{r}_v$ son los vectores de calificaciones de los usuarios u y v respectivamente.

3.3. Objetivos a optimizar

En la propuesta HP-MOEA [6], los dos objetivos a optimizar son la ganancia esperada total (total expected profit) y la novedad (novelty) de toda la lista de recomendaciones de los usuarios. En esta sección, se explican ambos objetivos en detalle, junto con el profit real total (real total profit), que se utiliza posteriormente para analizar los resultados del algoritmo.

En un sistema de recomendación, los elementos menos populares, es decir, aquellos que son consumidos por pocos usuarios, tienden a generar mayores márgenes de ganancia para el sistema. Esto se debe a que estos elementos pueden ser ofertados a precios más altos debido a su exclusividad o a un menor costo de adquisición por parte del sistema [2].

Los elementos más populares, consumidos por una mayor cantidad de usuarios, tienden a generar menores ganancias comerciales. Esto se debe a que la alta demanda usualmente conlleva una mayor competencia en el mercado, lo que reduce los márgenes de beneficio y hace que el sistema obtenga menores ganancias por cada transacción relacionada con estos elementos [2].

En el caso de HP-MOEA [6], los elementos recomendados son películas, y para optimizar las ganancias se utiliza la función del total expected profit. La validación de los resultados del algoritmo se realiza a través de la función del real total profit, que mide el beneficio concreto generado por los elementos aceptados por los usuarios en sus listas de recomendaciones [6].

Para las pruebas experimentales, se adoptó un sistema de calificaciones binario basado en *like* o *dislike* para determinar si la recomendación fue aceptada o no por el usuario. En este enfoque, si la calificación de una película es igual o superior a 3

se marca como *like*, y en el caso contrario se marca como *dislike* [6].

En valor de las ganancias comerciales o profit se deriva de la aceptación de los elementos y se correlaciona negativamente con la cantidad de veces que un elemento es aceptado. Por ejemplo, una película tiene un profit de 1 si fue aceptada el 100 % de las veces, y un valor de 10 si no fue aceptada ninguna vez [6]. Esto se traduce en la siguiente ecuación:

$$p_i = 1 + 9 \times \frac{\sum_{c=1}^n \mathbb{I}(r_c \geq 3)}{n} \quad (3.5)$$

donde, n el total de calificaciones de la película i , r_c es la calificación c de la película i y $\mathbb{I}$ es la función indicadora que devuelve 1 si la condición es verdadera y 0 si es falsa

3.3.1. Total Expected Profit

HP-MOEA introduce una nueva función objetivo llamada expected profit (ganancia esperada), a través de la combinación de la precisión y la ganancia comercial de los elementos, utilizada para mejorar las ganancias totales del proveedor del sistema de recomendación [6].

El expected profit se calcula para mejorar la precisión del sistema de recomendación al estimar la ganancia potencial de un elemento con base en la probabilidad de aceptación de un usuario. Esta probabilidad se modela a partir de la puntuación esperada que el usuario otorgaría a un artículo [6].

La fórmula utilizada para el expected profit toma la tasa entre la puntuación esperada y la puntuación máxima que el elemento ha recibido en el sistema. Luego, esta tasa se multiplica por el profit bruto de la recomendación (el valor comercial del elemento) para estimar el expected profit [6]:

$$\rho_{u,i} = \frac{\tilde{r}_{u,i}}{\tilde{r}_{max}} \times p_i \quad (3.6)$$

donde $\tilde{r}_{u,i}$ es la puntuación esperada del elemento i para el usuario u , $\tilde{r}_{max}$ es la puntuación máxima del elemento en el sistema, y p_i es el profit del elemento i .

Para calcular el total expected profit (la ganancia total del individuo), se halla la suma de todos los expected profits para cada elemento de la lista de recomendación de todos los usuarios [6]:

$$P_e = \sum_{u \in U} \sum_{i \in L_u} \rho_{u,i} \quad (3.7)$$

donde L_u es la lista de recomendación para el usuario u .

Real total profit

El profit real total (P_{real}) se entiende por la suma de las ganancias que producen cada uno de los elementos aceptados, es decir, aquellos artículos recomendados que los usuarios han aceptado basándose en sus calificaciones. HP-MOEA no toma en cuenta en sus objetivos a optimizar este valor, sino que lo utiliza en los resultados experimentales para analizar su rendimiento en términos de la ganancia comercial que genera su propuesta [6]. La fórmula del real total profit se define de la siguiente manera:

$$P_{real} = \sum_{u \in U} \sum_{i \in A_u} p_i \quad (3.8)$$

donde p_i es el profit del elemento i , A_u es el conjunto de elementos aceptados por el usuario u , y U representa el conjunto de todos los usuarios del sistema [6].

En el contexto de HP-MOEA, se considera que una película es aceptada si el usuario le da una calificación mayor o igual a 3. A partir de este criterio, el profit real se calcula sumando las ganancias de las películas que aparecen en la lista de recomendación de cada usuario, siempre y cuando estas hayan recibido una calificación de 3 o más. Este criterio se utiliza para medir el beneficio real generado por el sistema [6].

3.3.2. Novelty

En el contexto de HP-MOEA, una película que no ha sido vista por ningún usuario, como alguna que acaba de ingresar al sistema de recomendación (*newcomers*), se considera una películas novedosa. Este tipo de películas son elementos sobre los

cuales no se puede calcular un expected profit debido a que no hay calificaciones de otros usuarios (problema del inicio en frío).

Para tratar el problema del inicio en frío, la novedad se define como un objetivo específico, tal cual se observa de la siguiente manera [6]:

$$\text{novelty}(i) = \begin{cases} 1 & \text{si es un newcomer} \\ 0 & \text{en otro caso} \end{cases} \quad (3.9)$$

El novelty total de un individuo es [6]:

$$\text{novelty}_{\text{total}} = \sum_{u \in U} \sum_{i \in L_u} \text{novelty}(i) \quad (3.10)$$

Capítulo 4

Algoritmo Propuesto

El algoritmo propuesto en este trabajo se basa en una extensión de HP-MOEA [6], pero tomando un enfoque multipoblación, utilizando técnicas de clusterización y penalización de películas ya vistas por los usuarios en vez de eliminarlas de las recomendaciones. Los objetivos a optimizar también son los mismos que se buscan optimizar en HP-MOEA, los cuales ya fueron mencionados en el Capítulo 3.

La clusterización, es una técnica de aprendizaje automático utilizada para agrupar un conjunto de objetos en subgrupos o clústeres, de manera que los objetos dentro de un mismo clúster son más similares entre sí que con los objetos de otros clústeres. Este proceso tiene diversas aplicaciones, como por ejemplo el reconocimiento de patrones, la segmentación de mercados y la comprensión de datos, ya que permite identificar similitudes y diferencias, proporcionando información valiosa para la toma de decisiones [13].

El algoritmo K-means, descrito en la Sección 4.1, se emplea en sistemas de recomendación para identificar grupos de usuarios o elementos con características similares [30]. Al agrupar datos en clústeres, K-means permite a los sistemas de recomendación comprender mejor las preferencias de los usuarios al identificar patrones en sus comportamientos o en las características de los elementos. Esto facilita la creación de recomendaciones más precisas al sugerir elementos de clústeres similares a aquellos en los que el usuario ya ha mostrado interés [30].

En comparación al algoritmo HP-MOEA, el algoritmo propuesto en este trabajo

posee las siguientes modificaciones:

1. Clusterización: se utiliza K-means junto con el método del codo para crear múltiples clústeres de usuarios, descritos con mayor detalle en la Sección 4.1. Posteriormente, dentro de cada clúster se aplica el filtrado colaborativo [6] para calcular las calificaciones esperadas de cada película por usuario. El filtrado colaborativo es similar al utilizado en HP-MOEA, pero en este caso la diferencia es que es aplicado a cada clúster.
2. Penalización de películas ya vistas sin descartarlas: si durante el proceso de mutación del algoritmo aparece una película que el usuario ya ha visto, esta no se descarta, pero se penaliza en la función de fitness con un expected profit de 0. De esta forma se busca dejar que el proceso evolutivo decida si transferir el gen a otros individuos o eliminarlo posteriormente, ya que el proceso de selección favorece a los individuos más aptos [13].

4.1. K-means

El algoritmo K-means es un método ampliamente utilizado para la agrupación (clustering) de datos en el análisis estadístico y el aprendizaje automático. El algoritmo clasifica un conjunto de datos en un número predefinido de grupos k , donde cada grupo o clúster contiene objetos con características similares. El proceso básico del algoritmo K-means sigue estos pasos [30]:

1. Inicialización: se seleccionan k puntos aleatorios en el espacio de características como los centroides iniciales de los clústeres.
2. Asignación de clúster: cada punto de datos se asigna al clúster cuyo centroide es el más cercano.
3. Recomputación de centroides: después de asignar todos los puntos de datos, se recalculan los centroides como el promedio de todos los puntos en un clúster.
4. Se repiten los pasos 2 y 3 hasta que los centroides no cambien significativamente, lo que indica la convergencia del algoritmo.

En la Figura 4.1 se muestra un ejemplo de la agrupación con K-means. Se presenta la clasificación de los datos, representados en grupos a través de los colores rojo, verde y azul.




Figura 4.1: Agrupación en K-means [31]

4.1.1. Método del codo

El método del codo en K-means es una técnica utilizada para determinar el número óptimo de clústeres k en un conjunto de datos. Este método evalúa la suma de las distancias al cuadrado de cada punto dentro de un clúster con respecto a su centroide (conocido como Within-Cluster Sum of Squares o WCSS) [32]. La idea principal es calcular el WCSS para diferentes valores de k y representarlo en una gráfica. Conforme aumenta el valor de k , el WCSS disminuye porque los puntos están más cerca de sus centroides. Sin embargo, llega un punto en el que la disminución en WCSS se vuelve marginal, lo que se traduce en un ángulo o codo en la gráfica, como se puede apreciar en el ejemplo de la Figura 4.2. Este punto se considera el número óptimo de clústeres, ya que añadir más clústeres no mejora significativamente la calidad del agrupamiento [33].




Figura 4.2: Codo en la gráfica, para K=4 [34]

El WCSS se define como [35]:

$$WCSS = \sum_{i=1}^k \sum_{P_j \in C_i} \text{distancia}^2(P_j, C_i) \quad (4.1)$$

Donde P_j es un punto de datos en el clúster C_i , y $\text{distancia}(P_j, C_i)$ es la distancia entre el punto P_j y el centroide del clúster C_i .

Por ejemplo, si el valor de k es inicialmente 1, el WCSS será alto. A medida que k aumenta a 2 o 3, el WCSS disminuye considerablemente. Sin embargo, después de un cierto punto, el descenso en WCSS se estabiliza, indicando que aumentar k no mejora mucho la segmentación [32].

En resumen, para hallar el número óptimo de clústeres se siguen los siguientes pasos [35]:

1. Inicialización: ejecutar el algoritmo K-means para una variedad de valores de k .
2. Cálculo del WCSS: calcular el WCSS para cada valor de k .
3. Gráfico del WCSS: graficar el WCSS en función de k .
4. Identificación del Codo: identificar el punto donde la disminución del WCSS

comienza a aplanarse. Este punto representa el número óptimo de clústeres.

4.2. Población inicial

En este trabajo, el total de usuarios se divide en clústeres utilizando el algoritmo K-means. El número de clústeres se obtiene a través del método del codo, explicado en la sección 4.1.1. A cada uno de estos clústeres se les aplica el filtrado colaborativo utilizado en HP-MOEA 3, y de ese resultado se deriva la población inicial.

La estructura de un individuo es la siguiente:

- Tamaño de la lista de recomendación: 10 películas.
- Cantidad de usuarios en un individuo: Todos los usuarios del clúster.

Película 1	Película 2	Película ...	Película 10	Película 1	Película 2	Película ...	Película 10	Película 1	Película 2	Película ...	Película 10
15	44	...	24	56	39	...	64	99	54	...	48
Usuario 1				Usuario 2				Usuario U			

Cada gen corresponde a un ID Película

15

ID Película	Título
15	Mr. Holland's Opus (1995)
24	Rumble in the Bronx (1995)
39	Strange Days (1995)
44	Dolores Claiborne (1994)
48	Hoop Dreams (1994)
54	Outbreak (1995)
56	Pulp Fiction (1994)
64	Shawshank Redemption, The (1994)
99	Snow White and the Seven Dwarfs (1937)

Figura 4.3: Definición de un individuo

La población inicial que se tiene para la fase evolutiva por cada clúster se compone en total de los siguientes individuos:

1. Un individuo que aporta la ganancia máxima al sistema de recomendación (individuo max profit).
2. Un individuo que aporta el máximo novelty al sistema de recomendación (individuo max novelty).
3. N-2 Individuos con genes aleatorios, la configuración de N se detalla en el capítulo 5.

4.2.1. Individuo max profit

Se obtiene a partir de un individuo cuyos genes son las películas que, por cada usuario del clúster, aportan el mayor expected profit al sistema de recomendación. El expected profit de cada película para cada usuario se calcula de la misma manera que se explicó en el Capítulo 3. Este individuo contribuye al algoritmo maximizando la combinación de precisión y el beneficio de los elementos recomendados [6].

En el sistema de recomendación, una película tendrá un profit de 1 si fue gustada el 100 % de las veces, y un valor de 10 si no fue gustada en ninguna ocasión. En caso de que el sistema de recomendación se encuentre con una película que no tenga una puntuación esperada ni tampoco una puntuación del usuario, o sea la película sea un newcomer, se le asigna un expected profit de 1, que es el valor mínimo que puede tener una película en el sistema.

La Figura 4.4 presenta un ejemplo del individuo que maximiza la ganancia en el sistema. En este caso, los genes corresponden a las películas con el profit más alto disponible en todo el sistema.

$$\begin{array}{cccccccc}
 & [15 & 10 & 58 & \dots & 16 & 48 & 31] \\
 & | & | & | & | & | & | & | \\
 \text{Profit:} & 10 & + & 10 & + & 10 & + & \dots & + & 10 & + & 10 & + & 10 & = & 60 + \dots
 \end{array}$$

Figura 4.4: Ejemplo del individuo max profit

4.2.2. Individuo max novelty

Se obtiene a partir de un individuo cuyos genes son las películas nuevas en el sistema de recomendación (newcomers), incluyendo tantas como sea posible. Este individuo incrementa la probabilidad de sorprender a los usuarios al recomendarles elementos novedosos [6].

En la Figura 4.5 se muestra ejemplo del individuo que maximiza la novedad en el sistema. En este caso, los genes corresponden a las películas con el novelty más alto disponible en todo el sistema.

$$\begin{array}{ccccccc}
 & [25 & 61 & 64 & \dots & 31 & 44 & 84] \\
 \text{Novelty:} & \begin{array}{ccccccc} | & | & | & | & | & | & | \end{array} \\
 & 1 + 1 + 1 + \dots + 1 + 1 + 1 = 6 + \dots
 \end{array}$$

Figura 4.5: Ejemplo del individuo max novelty

4.2.3. Individuos aleatorios

Se obtienen generando individuos cuyos genes correspondan a películas tomadas de manera aleatoria de entre todas las disponibles (es decir, tanto películas ya presentes en el sistema como newcomers).

4.3. Operadores genéticos

4.3.1. Mutación

Como operador, se utiliza la mutación de punto único (single point). Este proceso, elige aleatoriamente un gen para cada individuo, y si un número generado aleatoriamente es menor que la probabilidad de mutación establecida (en este caso, $P_m = 1/L$), el gen es mutado y reemplazado por uno aleatorio. En el caso contrario, el gen permanece igual. Si el gen aleatorio ya se encuentra en la lista de recomendación, se vuelve a generar otro gen, repitiendo el proceso hasta encontrar uno que no esté en dicha lista [6]. En la Figura 4.6, se ejemplifica el funcionamiento del operador de mutación en el caso de que el número aleatorio generado es menor a P_m .

Gen aleatorio elegido: 4

[25 61 64 **31** 44 84 15 89 98 26]

$P_m = 1/10 = 0.1$

Número aleatorio generado = **0.05**

Como el **número generado es menor a P_m** , se procede a mutar el gen

Resultado: [25 61 64 **11** 44 84 15 89 98 26]

Figura 4.6: Ejemplo del operador de mutación

Los genes mutados son siempre diferentes de los ya existentes en la lista de

recomendación del usuario correspondiente. Sin embargo, a diferencia de HP-MOEA [6], en este trabajo se acepta que los genes introducidos puedan ser películas que ya han sido calificadas por el usuario, dejando que posteriormente el proceso evolutivo decida si transferirlo a otros individuos o eliminarlo.

4.3.2. Cruce

El operador de cruce utilizado en este trabajo, es el mismo que el empleado en HP-MOEA [6] sin ninguna modificación, tal como se describe en el Capítulo 3.

4.4. Fitness

Para un individuo, el fitness se compone del total expected profit y el total novelty, descritos en el Capítulo 3. Ambos criterios se normalizan a un valor de entre $[0, 1]$ para que tengan el mismo peso durante la optimización multiobjetivo. Esto significa que un valor de 0 en el novelty y 0 en el expected profit representa el peor rendimiento, mientras que un valor de 1 en ambos indica el mejor rendimiento posible, cubriendo así la totalidad del espacio objetivo en términos de hipervolumen.

4.4.1. Normalización

Para que todos los objetivos tengan el mismo peso en el cálculo del fitness, se realiza una normalización de ambos. Se dividen cada uno de los objetivos por sus valores máximos en cada clúster, con lo que se obtiene una escala de $[0, 1]$.

Para un individuo, el expected total profit máximo es calculado de la misma manera que en HP-MOEA [6]. Matemáticamente, el cálculo de esta métrica se define como sigue [6]:

$$P_M = \sum_{u \in U} \sum_{i \in I_u^M} \rho_{u,i} \quad (4.2)$$

donde U son todos los usuarios que pertenecen al individuo, I_u^M las primeras L películas ordenadas de mayor a menor por el expected profit para el usuario u , y

$\rho_{u,i}$ el expected profit del ítem i para el usuario u .

Para el novelty máximo, se sigue una lógica similar, utilizando todos los newcomers posibles, tantos como se puedan añadir a la lista de recomendación. Matemáticamente, se define de la siguiente manera [6]:

$$N_M = \sum_{u \in U} N_u^M \quad (4.3)$$

donde N_u^M es el número máximo de newcomers disponibles para la lista de recomendación del usuario u .

4.5. Opciones de películas para el usuario

Las opciones de películas que se sugieren al usuario son tres. Estas se detallan en la Figura 4.5 y se describen de la siguiente manera:

1. Newcomers: en este caso, del conjunto de datos original se eliminan las películas que tienen un total de calificaciones menor a 5, para luego ser utilizadas como newcomers en el sistema de recomendación. A estas películas se les asigna un profit de 1 (1/10) y automáticamente tienen novelty de 1 (1/1) debido a su naturaleza. Estos newcomers son posteriormente utilizados como conjunto de verificación del algoritmo.

Los newcomers, como son películas que en realidad forman parte del conjunto de datos original, pueden proceder de este mismo correspondiendo a una de las siguientes categorías:

- a) Películas ya vistas por el usuario: son películas que ya tienen una calificación por parte del propio usuario.
- b) Películas no vistas por el usuario: son las películas que el usuario realmente no ha visto y que se utilizan como newcomers.

2. Películas ya vistas: este tipo de películas, en caso de que aparezcan durante el proceso evolutivo debido a mutaciones, son penalizadas con un profit de 0, pero

no son retiradas de la lista de recomendación del usuario. Esto permite que el algoritmo utilice ese gen para algún otro usuario en el proceso de intercambio genético, a modo de dejar la posibilidad al proceso de decidir si ese gen se utilizará para algún otro usuario durante el intercambio genético.

3. Películas no vistas: estas son películas que el usuario no ha visto, pero que tampoco son newcomers. En este caso, se calcula el expected rating en base a los demás usuarios del clúster. Si ningún usuario del clúster ha visto la película, se le asigna un expected rating de 0 para todos los usuarios.




Figura 4.7: Opciones de películas para un usuario

4.6. Arquitectura de la población

El algoritmo propuesto se distingue del algoritmo HP-MOEA [6], en parte debido a la estructura de la población. En el trabajo presentado en este libro, los usuarios se agrupan en clústeres, sin embargo, en lugar de generar la misma lista de

recomendación para todos los usuarios de un clúster, el algoritmo ofrece sugerencias para cada usuario del clúster de manera individual.

En la Figura 4.8 se muestra de una forma visual la arquitectura multipoblación del algoritmo propuesto, y a modo de comparación se muestra en la figura 4.9 la arquitectura de HP-MOEA, la cual es de población única. La configuración de la población es detallada en el Capítulo 5.




Figura 4.8: Arquitectura multipoblación del algoritmo propuesto




Figura 4.9: Arquitectura de la población de HP-MOEA [6]

Flujo general del algoritmo propuesto

Finalmente, se adjunta en la Figura 4.10 el flujo general del algoritmo propuesto, que ofrece una explicación gráfica de lo mencionado en los párrafos anteriores.




Figura 4.10: Flujo general del algoritmo propuesto

Capítulo 5

Análisis experimental

En este capítulo se describen el conjunto de datos y la selección del número de clústeres utilizados en el desarrollo del algoritmo propuesto. Para las pruebas, se empleó el dataset MovieLens 100k, descrito en la Sección 5.1. Posteriormente, se presenta el resultado del proceso de determinación del número óptimo de clústeres mediante el método del codo, además de las configuraciones de los parámetros del algoritmo propuesto.

5.1. Conjunto de datos

El conjunto de datos (dataset) utilizado para las pruebas es el MovieLens 100k, que es un conjunto de datos de películas junto con las calificaciones de los usuarios, y es ampliamente utilizado para pruebas de algoritmos [2]. Se eligió este dataset debido a que también se utilizó en el trabajo HP-MOEA [6], y el trabajo de este libro se compara en base a sus resultados.

MovieLens 100k está disponible en el sitio web de GroupLens Research (www.grouplens.org), lanzado en abril de 1998 y se compone de 100.000 reseñas de un total de 1682 películas, calificadas por 943 usuarios [36].

En la Figura 5.1, se muestra una tabla con un ejemplo del archivo de calificaciones del dataset MovieLens. La columna `user_id` corresponde al identificador del usuario que realizó la calificación, `item_id` al identificador de la película calificada, `rating` a la calificación del usuario y `timestamp` es la fecha y hora en la que se realizó la

calificación representada como el número de segundos transcurridos desde el 1 de enero de 1970 a las 00:00:00 UTC [36].

	user_id	item_id	rating	timestamp
0	196	242	3	881250949
1	186	302	3	891717742
2	22	377	1	878887116
3	244	51	2	880606923
4	166	346	1	886397596
...	...	...	...	...
99994	378	78	3	880056976
99995	880	476	3	880175444
99996	716	204	5	879795543
99997	276	1090	1	874795795
99998	13	225	2	882399156

Figura 5.1: Tabla de calificaciones del dataset de movielens

5.2. Cantidad de clústeres

Utilizando el dataset MovieLens 100k, se ejecutó el algoritmo K-means y se estableció el número de clústeres en $k=5$ por el método del codo, como se visualiza en la Figura 5.2. Se observó que en cada clúster se incluyeron películas no calificadas por ningún usuario de dicho clúster, lo que abre la posibilidad de analizar si, en este contexto, estas películas podrían considerarse como newcomers, o si por el contrario serían las películas de menor interés para los usuarios de ese clúster en particular. Sin embargo, en este trabajo se toman como newcomers únicamente las películas que en el dataset MovieLens 100k tienen un total de calificaciones menor a 5, al igual que el trabajo HP-MOEA [6].

5.3. Configuraciones

Las configuraciones para el experimento de HP-MOEA [6] y el algoritmo propuesto en este trabajo son las siguientes:




Figura 5.2: Gráfico del método del codo del algoritmo propuesto

Algoritmo	Parámetros
HP-MOEA	$L=10$, $N=100$, $T=3000$, $pm=1/L$, $k=20$
Algoritmo propuesto	$L=10$, $N=100$, $T=300$, $pm=1/L$, $k=10$, $C=5$, $Tc=60$

Tabla 5.1: Comparación de parámetros de algoritmos

En la Tabla 5.1, L es la longitud de la lista de recomendación, N es el tamaño de la población (siendo en el algoritmo propuesto igual para todos los clústeres), T el número de iteraciones del algoritmo evolutivo, pm la probabilidad de mutación, k la cantidad de usuarios similares para el filtrado colaborativo, C la cantidad de clústeres y Tc el total de iteraciones por clúster.

Cabe destacar que, para la ejecución del algoritmo propuesto, como se utilizó el framework pymoo en su versión 0.6.1.3 [37] se definió la condición de terminación de los algoritmos genéticos (NSGA-II y SMS-EMOA) en 2 iteraciones debido a que es el valor mínimamente necesario para lograr ejecutar correctamente el algoritmo (parámetro termination de la función minimize de pymoo.optimize).

El algoritmo propuesto itera la fase evolutiva un total de 300 veces ($T = 300$), y para cada clúster se realizan 60 pasadas en total. Se optó por esta cantidad de iteraciones y no unas 3000 como en HP-MOEA [6] debido a que con las 300 iteraciones ya se logró el objetivo de mejorar los resultados del sistema de recomendación

como se explica en la sección 5.4.

Además de alcanzarse el objetivo de mejorar los resultados con sólo 300 iteraciones, como el umbral de cambio entre NSGA-II [23] y SMS-EMOA [29] es de 500 iteraciones en HP-MOEA [6] y tal como se visualiza en el gráfico 3.3, en el algoritmo propuesto no se llegó a utilizar SMS-EMOA en ninguna iteración del algoritmo para lograr el objetivo de mejorar los resultados del sistema de recomendación.

La estructura de la población final del algoritmo propuesto difiere de HP-MOEA [6], como se aprecia en el gráfico 4.8, por lo que es necesario realizar el análisis de rendimiento bajo el mismo tamaño de la población final. Sin embargo, como el algoritmo propuesto separa a los usuarios en clústeres y mantiene las diez películas recomendadas ($L = 10$) junto con los cien individuos por población ($N = 100$), la suma de las cinco poblaciones finales del algoritmo propuesto contiene la misma cantidad de usuarios y películas que la población final de HP-MOEA. A continuación se presenta la demostración, siendo A , B , C , D y E la cantidad de usuarios en los clústeres 1, 2, 3, 4 y 5 respectivamente:

$$(A + B + C + D + E) \times 10 \times 100 = \text{PoblaciónTotal}_{\text{algoritmo_propuesto}} \quad (5.1)$$

$$A + B + C + D + E = \text{Usuarios}_{\text{movielens}} \quad (5.2)$$

$$\text{Usuarios}_{\text{movielens}} \times 10 \times 100 = \text{Población}_{\text{HP-MOEA}} \quad (5.3)$$

5.1 y 5.2

$$\text{Usuarios}_{\text{movielens}} \times 10 \times 100 = \text{PoblaciónTotal}_{\text{algoritmo_propuesto}} \quad (5.4)$$

5.3 y 5.4

$$\Rightarrow \text{Población}_{\text{algoritmo_original}} = \text{PoblaciónTotal}_{\text{HP-MOEA}} \quad (5.5)$$

A partir del resultado obtenido en 5.5, se puede concluir que es posible comparar los resultados de HP-MOEA 3 y del algoritmo propuesto en un mismo gráfico, ya que el tamaño de la población total considerando todos los clústeres del algoritmo propuesto es igual al de población total en HP-MOEA.

5.4. Resultados

En esta sección, se explican los resultados obtenidos por el algoritmo propuesto en este trabajo y se comparan con los resultados de HP-MOEA [6]. Los trabajos MOEA-ProbS [16], PMOEA [17], MOEA-EPG [18], Filtrado Colaborativo [15] y MF [19] son contra los que se compararon HP-MOEA en su propio artículo al momento de su propuesta [6].

El real total profit es utilizado en las tablas de esta sección para denotar el valor real de las ganancias comerciales de los elementos [6]. El expected profit es calculado en base a la probabilidad de aceptación del elemento por parte del usuario como se explica en el capítulo 3, pero este valor no corresponde solamente a las ganancias comerciales que brinda el elemento al sistema, entonces por este motivo se incluye el real total profit, a modo de visualizar el valor de las ganancias comerciales de los resultados.

Se realizaron 30 ejecuciones independientes del algoritmo propuesto a modo de compararlo con HP-MOEA [6], el cual también realizó la misma cantidad de ejecuciones, y en la Tabla 5.2 se expone la media aritmética del hipervolumen de los resultados de HP-MOEA [6] y el Algoritmo propuesto. Se puede apreciar que el algoritmo propuesto alcanza el mayor valor, indicando que este logra un mejor rendimiento al optimizar la novedad y la ganancia esperada.

	HP-MOEA	Algoritmo propuesto
Media aritmética	0.51739	0.671335

Tabla 5.2: Media aritmética del hipervolumen de HP-MOEA [6] y algoritmo propuesto

Los resultados de HP-MOEA en el espacio objetivo son visualizados en la Tabla

5.3. Este algoritmo es comparado con MOEA-ProbS [16], PMOEa [17] y MOEA-EPG [18], optimizando los mismos objetivos que HP-MOEa. Además, se lo compara también con otras dos aproximaciones que optimizan solamente el expected profit, que son el Filtrado Colaborativo [15] y MF [19].




Tabla 5.3: Resultados de HP-MOEa [6]

Para el gráfico del expected total profit de la Tabla 5.4, cada punto del gráfico correspondiente al algoritmo propuesto representa la una población de un único clúster, no de todos los clústeres juntos.




Tabla 5.4: Resultados del algoritmo propuesto

En la Tabla 5.5 se observan los resultados combinados de HP-MOEa y los del algoritmo propuesto, para el expected total profit y el real total profit. El algoritmo propuesto logra mejorar el rendimiento del sistema de recomendación, obteniendo tanto un mayor expected profit como un mayor novelty.




Tabla 5.5: Comparación combinada de resultados HP-MOEA [6] y el algoritmo propuesto.

Al analizar la última iteración del algoritmo para cada clúster, se encontró que en promedio para las 30 ejecuciones independientes, el 99.989 % de la lista de recomendaciones estaba compuesta por películas que el usuario no había visto, de las cuales el 49.42 % fueron newcomers, y el resto correspondía a películas ya existentes en el sistema de recomendación pero que el usuario aún no había visto. El 0.011 % restante de la lista de recomendación correspondía a películas que el usuario ya había visto. Lo mencionado en este párrafo se puede resumir de la siguiente manera:

1. Total de películas ya vistas: 0.011 %
2. Total de películas no vistas: 99.989 %, de los cuales son newcomers el 49.42 %

Lista de recomendación proveída por el algoritmo propuesto

En la Figura 5.3 se presenta la lista de recomendaciones generada para el individuo N°6 de la población final del clúster N°2. Esta lista de recomendaciones está destinada a los usuarios con user_id 7 y 10:

item_id	user_id	expected rating	movielens rating	expected profit	expected profit (p/fitness)	profit en bruto	novelty	es película ya vista	rating promedio movielens	visualizaciones	%	rating mas alto	rating mas bajo	item_title
10	643.0	7	NA	4	NA	1.000000	3.250000	1	False	3.000000	0.424178	4	1	The Innocent (1994)
11	669.0	7	NA	1	NA	0.000000	7.923077	0	False	1.615385	1.378579	4	1	Body Parts (1991)
12	688.0	7	0.986223	NA	1.528646	1.528646	7.750000	0	False	1.840909	4.665960	5	1	Leave It to Beaver (1997)
13	838.0	7	NA	NcmrNA	NA	1.000000	5.500000	1	False	2.750000	0.424178	5	1	In the Line of Duty 2 (1987)
14	1342.0	7	NA	NcmrNA	NA	1.000000	5.500000	1	False	2.500000	0.212089	4	1	Convent, The (Convento, O) (1995)
15	1464.0	7	NA	NcmrNA	NA	1.000000	7.000000	1	False	2.333333	0.318134	4	1	Stars Fell on Henrietta, The (1995)
16	1493.0	7	NA	NcmrNA	NA	1.000000	10.000000	1	False	1.000000	0.106045	1	1	Modern Affair, A (1995)
17	1492.0	7	NA	NcmrNA	NA	1.000000	1.000000	1	False	4.000000	0.106045	4	4	Window to Paris (1994)
18	254.0	7	0.791825	NA	0.916984	0.916984	5.790323	0	False	2.451613	6.574761	5	1	Batman & Robin (1997)
19	247.0	7	0.791825	NA	1.298593	1.298593	8.200000	0	False	1.800000	0.530223	5	1	Turbo: A Power Rangers Movie (1997)
20	120.0	10	2.184099	NA	2.959943	2.959943	6.776119	0	False	2.238806	7.104984	5	1	Striptease (1996)
21	122.0	10	0.894208	NA	1.089922	1.089922	6.094340	0	False	2.339623	11.240721	5	1	Cable Guy, The (1996)
22	830.0	10	NA	NcmrNA	NA	1.000000	10.000000	1	False	1.000000	0.106045	1	1	Power 98 (1995)
23	1306.0	10	NA	NcmrNA	NA	1.000000	5.500000	1	False	3.000000	0.212089	5	1	Delta of Venus (1994)
24	1347.0	10	NA	NcmrNA	NA	1.000000	5.500000	1	False	2.750000	0.424178	5	1	Ballad of Narayama, The (Narayama Bushiko) (1958)
25	1484.0	10	NA	NcmrNA	NA	1.000000	4.000000	1	False	2.666667	0.318134	4	1	Jerky Boys, The (1994)
26	1424.0	10	NA	NcmrNA	NA	1.000000	4.000000	1	False	2.333333	0.318134	3	1	I Like It Like That (1994)
27	733.0	10	0.891438	NA	0.499205	0.499205	2.800000	0	False	3.200000	1.590668	5	1	Go Fish (1994)
28	913.0	10	NA	NcmrNA	NA	1.000000	5.500000	1	False	2.500000	0.212089	4	1	Love and Death on Long Island (1997)
29	1189.0	10	NA	NcmrNA	NA	1.000000	1.000000	1	False	5.000000	0.318134	5	5	Prefontaine (1997)

Figura 5.3: Lista generada para el clúster N°4

A partir de estos resultados, se observa que las películas recomendadas no generan un profit muy bajo en el sistema de recomendación, ni tienen una baja calificación en promedio. Además, se incluyen en las recomendaciones algunos newcomers del sistema.

El profit real se muestra en la columna *profit en bruto*, con resultados que varían entre 2.8 y 8.2, excluyendo los newcomers. Los newcomers son películas nuevas en el sistema, por lo que aún no se dispone de suficiente información para predecir con exactitud el profit que pueden generar. Se podría discutir la posibilidad de asignarles un profit de 10 debido a que ingresan recientemente al sistema, pero el

análisis del profit real en este trabajo se centra en calcular el profit únicamente en función de las calificaciones de la película, tal como se describió en el Capítulo 3.

La calificación promedio corresponde a la columna *rating promedio movielens*, y varía entre 1 y 5. Los newcomers están indicados en la columna *novelty*, donde un valor de 1 indica que la película es un newcomer, y un valor de 0 indica lo contrario.

Capítulo 6

Conclusiones y trabajos futuros

La principal contribución de este trabajo es la mejora en los resultados producidos por el sistema de recomendación HP-MOEA, y su importancia radica en los beneficios comerciales que este aporta [6]. Como resultado se obtuvo una mayor ganancia esperada y al mismo tiempo una mayor novedad en las recomendaciones de películas para los usuarios.

En este capítulo se detallan las conclusiones obtenidas teniendo en cuenta los objetivos del trabajo de investigación, y se proponen posibles trabajos futuros que permitan enriquecer o dar continuidad a este trabajo.

6.1. Conclusiones

Este trabajo extiende la propuesta realizada por HP-MOEA [6] incorporando el algoritmo K-means [30] identificando el número óptimo de clústeres con el método del codo [35] y penalizando las películas ya vistas por el usuario como se describe en el Capítulo 4.

Los objetivos que maximizan algoritmo propuesto y HP-MOEA [6] son la ganancia esperada total y la novedad total. La ganancia esperada total se calcula para mejorar la precisión del sistema de recomendación al estimar la ganancia potencial de un elemento con base en la probabilidad de aceptación de un usuario [6]. La novedad total se basa en las películas que acaban de ingresar al sistema de recomendación y suponen elementos novedosos en las recomendaciones ofrecidas [6].

En el algoritmo propuesto, la población total es dividida en clústeres utilizando el algoritmo K-means [30]. A cada uno de estos clústeres se les aplica el filtrado colaborativo [6] y de ese resultado deriva la población inicial. Dicha población para cada clúster se compone de los siguientes individuos:

1. Un individuo que maximiza la ganancia esperada total [6].
2. Un individuo que maximiza la novedad total [6].
3. 98 individuos aleatorios para alcanzar la población inicial de 100 [6].

El operador de mutación implementado elige aleatoriamente un gen para cada individuo, y si un número generado también aleatoriamente es menor que la probabilidad de mutación establecida, el gen es mutado y reemplazado por uno aleatorio [6].

Si durante el proceso de mutación del algoritmo propuesto aparece una película que el usuario ya ha visto, esta no se descarta, pero se penaliza en la función de fitness con un expected profit de 0. De esta forma se busca dejar que el proceso evolutivo decida si transferir el gen a otros individuos o eliminarlo posteriormente, ya que el proceso de selección favorece a los individuos más aptos [13].

El operador de cruce en HP-MOEA hereda primero al hijo los genes que están presentes en ambos padres, y para cada uno de los distintos genes restantes, se determina el gen a heredar en base a la probabilidad genética de ambos padres [6]. Este operador es implementado de esta misma manera en el algoritmo propuesto.

A continuación se detallan las conclusiones obtenidas por cada objetivo específico definido:

1. Para el análisis bibliográfico exhaustivo sobre las técnicas de algoritmos evolutivos aplicadas en sistemas de recomendación se consultaron múltiples referencias y se encontraron una variedad de implementaciones que buscan optimizar uno o múltiples objetivos, como por ejemplo son los trabajos MF [19], ClickSmart [38], HP-MOEA [6], PMOEA [17], EvoRecSys, [14], EBMRS-WPS[39], RRS GA [8]. NSGA-II es el algoritmo más utilizado para los MOEAs y puede generar rápidamente un conjunto de soluciones no dominadas [6].

2. Para la definición de los objetivos de optimización específicos para el sistema de recomendación, se utilizaron los mismos objetivos que HP-MOEA [6]. Esto es así debido a que el trabajo presentado en este libro es una extensión del mismo, y los mismos objetivos son utilizados en la comparación de los resultados finales a modo de determinar cuál de los dos obtiene un mejor rendimiento.
3. En el modelado de los datos de entrada y definición de las restricciones del problema, integrando técnicas de agrupación con K-means y filtrado colaborativo, se utilizó una lista de recomendación de 10 elementos para cada usuario. Cada elemento corresponde a un gen en el algoritmo genético, los cuales provienen del conjunto de datos de películas MovieLens 100k que es públicamente disponible y ampliamente utilizado para pruebas de algoritmos [2].

Para la agrupación con K-means se propuso utilizar el método del codo para definir la cantidad óptima de clústeres [33]. El total de los usuarios del conjunto de datos MovieLens 100k se divide en 5 clústeres utilizando este método. A cada uno de estos clústeres se les aplicó el filtrado colaborativo utilizado en HP-MOEA [6] y de ese resultado derivan sus poblaciones iniciales.

4. Para evaluar el rendimiento del algoritmo propuesto en comparación a HP-MOEA utilizando métricas de rendimiento basadas en los objetivos de optimización, se compararon los resultados de HP-MOEA y el algoritmo propuesto en el mismo espacio objetivo del expected profit total y el novelty total.

El algoritmo propuesto utilizando como entrada el conjunto de datos MovieLens 100k produjo mejores resultados en términos del hipervolumen [6] que HP-MOEA utilizando el mismo conjunto de datos, significando mayores ganancias al mismo tiempo que se proporciona novedad en las recomendaciones para el usuario.

6.2. Trabajos futuros

1. Se podría aplicar el enfoque del multi-population search [13], en el cual la población de cada clúster se somete a varias ejecuciones paralelas del algoritmo, cada una con sus propios parámetros. Posteriormente, las peores soluciones de una población pueden ser reemplazadas por las mejores soluciones de otra población.
2. En el algoritmo propuesto, una película tiene un profit de 1 si fue gustada el 100 % de las veces, y un valor de 10 si no fue gustada ninguna vez. Un enfoque alternativo podría considerar, además de basarse en este sistema, el análisis de la popularidad de las películas del sistema [9]. Esto se debe a que una película podría tener mayoritariamente puntuaciones favorables pero no ser muy popular, lo que llevaría a redefinir el profit de manera que los elementos menos populares generen profits más altos para el sistema de recomendación. Por otro lado, una película muy popular pero con una calificación promedio podría generar profits más bajos, dado que muchos usuarios estarían visualizándola, lo que implicaría mayores pagos en regalías a sus autores. En el algoritmo propuesto, el cálculo del profit se basa únicamente en el porcentaje de likes de la película, sin considerar su popularidad.
3. Debido a que se alcanzó el objetivo de mejorar el rendimiento de HP-MOEA [6] sin alcanzar la misma cantidad de iteraciones utilizadas en la fase experimental del mismo, en el algoritmo propuesto ya no se dio la oportunidad de cambiar el NSGA-II [23] por el SMS-EMOA [29] con la configuración de $Turn = 500$ como en HP-MOEA. Podría considerarse experimentar con las configuraciones de ejecución del algoritmo propuesto a modo de investigar posibles mejoras combinando la ejecución de SMS-EMOA y NSGA-II.
4. El algoritmo propuesto genera una variedad de individuos por cada clúster en la solución final. Se podría realizar un análisis sobre dichos individuos, con el objetivo de determinar cuál de ellos sería el más apto para usar como re-

comendación final para los usuarios. También podría considerarse un enfoque que sugiera listas de recomendaciones basadas en una combinación de los individuos de la población final.

Bibliografía

- [1] Qingfu Zhang, Jie Lu, and Yaochu Jin. Artificial intelligence in recommender systems. *Complex and Intelligent Systems*, 7(1), 2020.
- [2] Charu C. Aggarwal. *Recommender Systems: The Textbook*. Springer, Cham, Switzerland, 2016.
- [3] Netflix Research. Netflix research, 2024. Retrieved November 27, 2024, from <https://research.netflix.com/research-area/recommendations>.
- [4] Larry Hardesty. The history of amazon’s recommendation algorithm. *Amazon Science*, November 2024. Retrieved November 27, 2024, from <https://www.amazon.science/the-history-of-amazons-recommendation-algorithm>.
- [5] D. Roy and M. Dutta. A systematic review and research perspective on recommender systems. *J Big Data*, 9(59), 2022.
- [6] Guijin Wei, Qinglong Wu, and MengChu Zhou. A hybrid probabilistic multiobjective evolutionary algorithm for commercial recommendation systems. *IEEE Transactions On Computational Social Systems*, 8(3), 2021.
- [7] Bleta Lika, Kostas Kolomvatsos, and Stavros Hadjiefthymiades. Facing the cold start problem in recommender systems. *Expert Systems With Applications*, 41(4), 2014.
- [8] Oumaima Stitini, Sanae Kaloun, and Bencharef Omar. An improved recommender system solution to mitigate the over-specialization problem using genetic algorithms. *Electronics*, 11(2), 2022.

-
- [9] Y. Zheng and Wang D. A survey of recommender systems with multi-objective optimization. *Neurocomputing*, 474, 2022.
 - [10] Xingjuan Cai, Zhaoming Hu, Peng Zhao, WenSheng Zhang, and Jinjun Chen. A hybrid recommendation system with many-objective evolutionary algorithm. *Expert Systems with Applications*, 159:113648, 2020.
 - [11] Pearl Pu, Li Chen, and Hu Rong. Evaluating recommender systems from the user’s perspective: survey of the state of the art. *User Modeling and User-Adapted Interaction*, 22(4–5), 2012.
 - [12] M. D. Ekstrand. Collaborative filtering recommender systems. *Foundations and Trends In Human-computer Interaction/Foundations and Trends In Human Computer Interaction*, 2011.
 - [13] M. Kubat. *An Introduction to Machine Learning*. Springer, 2015.
 - [14] Hugo Alcaraz-Herrera, John Cartlidge, Zoi Toumpakari, Max Western, and Iván Palomares. Evorecsys: Evolutionary framework for health and well-being recommender systems. *User Modeling and User-adapted Interaction*, 2021.
 - [15] Jonathan L. Herlocker, Joseph A. Konstan, Loren G. Terveen, and John T. Riedl. Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, 22(1):5–53, January 2004.
 - [16] Y. Zuo, M. Gong, J. Zeng, L. Ma, and L. Jiao. Personalized recommendation based on evolutionary multi-objective optimization [research frontier]. *IEEE Comput. Intell. Mag.*, 10(1), 2015.
 - [17] L. Cui, P. Ou, X. Fu, Z. Wen, and N. Lu. A novel multi-objective evolutionary algorithm for recommendation systems. *Journal of Parallel and Distributed Computing*, 103, May 2017.
 - [18] Q. Lin et al. Multiobjective personalized recommendation algorithm using extreme point guided evolutionary computation. *Complexity*, 2018:18, Jan 2018.

- [19] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, Aug 2009.
- [20] Jayshree Piri Madhusree Kuanr, Puspanjali Mohapatra. Health recommender system for cervical cancer prognosis in women. *Proceedings of the Sixth International Conference on Inventive Computation Technologies [ICICT 2021]*, 2021.
- [21] Francesco Ricci, Lior Rokach, and Shapira Bracha. *Introduction to Recommender Systems Handbook*. Springer, 2011.
- [22] Z. Cui, P. Zhao, Z. Hu, Z. Cai, X. Zhang, and W. Chen. An improved matrix factorization based model for many-objective optimization recommendation. *Information Sciences*, 579, 2021.
- [23] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan. A fast and elitist multiobjective genetic algorithm: Nsga-ii. *IEEE Transactions on Evolutionary Computation*, 6(2), 2002.
- [24] Ankush Jain, Pramod Kumar Singh, and Dhar Joydip. Multi-objective item evaluation for diverse as well as novel item recommendations. *Expert Systems with Applications*, 139, 2020.
- [25] Edwin Pino-Vargas, Angely Valle, Condori Franz, Jesús Abel Mejía, Eduardo Chavarri, and Luis Alfaro. Diseño Óptimo de redes de distribución de agua usando un software basado en microalgoritmos genéticos multiobjetivos. *Ribagua*, 4:6–23, 2017.
- [26] Eduardo Coronel, Benjamin Baran, and Pedro Gardel. Optimización en la ubicación de seccionadores tele-comandados en sistemas de distribución de energía eléctrica con enfoque meta-heurístico y soporte de decisión multi-criterio. *Facultad Politécnica - UNE*, 2020.
- [27] M. Li, Z. Shang, X. Shen, C. Yue, H. Wang, Y. Dong, and H. Wan. Sample set reduction method based on neighborhood non-dominated crowding-distance

- sorting. In *2018 11th International Symposium On Computational Intelligence And Design*, 2018.
- [28] J. Knowles and Corne D. Approximating the nondominated front using the pareto archived evolution strategy. *Evolutionary Computation*, 8(2), 2000.
- [29] N. Beume, B. Naujoks, and M. Emmerich. Sms-emoa: Multiobjective selection based on dominated hypervolume. *European Journal of Operational Research*, 181(3):1653–1669, 2007.
- [30] Kyoung-jae Kim and Ahn Hyunchul. A recommender system using ga k-means clustering in an online shopping market. *Expert Systems with Applications*, 34(3), 2008.
- [31] P. Patil. K means clustering: identifying f.r.i.e.n.d.s in the world of strangers. *Medium*, May 2022.
- [32] E. M. S. Rochman M. A. Syakur, B. K. Khotimah and B. D. Satoto. Integration k-means clustering method and elbow method for identification of the best customer profile cluster. *IOP Conference Series: Materials Science and Engineering*, 336(1), 2018.
- [33] Purnima Bholowalia and Arvind Kumar. Ebk-means: A clustering technique based on elbow method and k-means in wsn. *International Journal of Computer Applications*, 105(9), 2014.
- [34] Alvaro. Segmentación utilizando k-means en python. *MachineLearningParaTodos.com*, October 2023.
- [35] Manish Soni Amit Kuraria, Nitin Jharbade. Centroid selection process using wcss and elbow method for k-mean clustering algorithm in data mining. *International Journal of Scientific Research in Science, Engineering and Technology*, 4(11), 2018.

-
- [36] F. Maxwell Harper and Joseph A. Konstan. The movielens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems (TiiS)*, 5(4):19:1–19:19, December 2015.
- [37] J. Blank and K. Deb. pymoo: Multi-objective optimization in python. *IEEE Access*, 8:89497–89509, 2020.
- [38] Yogesh S. Rawat and Mohan S. Kankanhalli. Clicksmart: A context-aware viewpoint recommendation system for mobile photography. *IEEE Transactions on Circuits and Systems for Video Technology*, 27:149–158, 2017. Accessed through IEEE Xplore.
- [39] Deniz Ayata, Yusuf Yaslan, and Mehmet Erdal Kamasak. Emotion based music recommendation system using wearable physiological sensors. *IEEE Transactions on Consumer Electronics*, 64(2):196–203, 2018. Accessed through IEEE Xplore.